分类号：

华中农业大学

HUAZHONG AGRICULTURAL UNIVERSITY

硕 士 学 位 论 文

MASTER'S DEGREE DISSERTATION

基于机器学习集成的园艺作物全基因组选择预测方法构建与应用

DEVELOPMENT AND APPLICATION OF ENSEMBLE MACHINE LEARNING METHODS FOR GENOMIC PREDICTION IN HORTICULTURAL CROPS

研 究 生：刘晓

CANDIDATE：LIU XIAO

学　　号：**2023305120019**

STUDENT NO.：

学位类别：农业硕士

DEGREE TYPE：MASTER OF AGRICULTURE

导　　师：王 昕 研究员

SUPERVISOR：PROFESSOR WANG XIN

中国 武汉

WUHAN，CHINA

二〇二六年六月

JUNE，2026

分类号：

华中农业大学硕士学位论文

基于机器学习集成的园艺作物全基因组选择预测方法构建与应用

Development and application of ensemble machine learning methods for genomic prediction in horticultural crops

研 究 生：刘晓

学　　号：2023305120019

指导教师：王　昕　研究员

学位类型：农业硕士

领　　域：农艺与种业

华中农业大学园艺林学学院

中国 武汉

College of Horticulture and Forestry Sciences

Huazhong Agricultural University

Wuhan, China

华中农业大学学位论文独创性声明及使用授权书

学位论文是否延迟上网	是	上网时间	2028 年 6 月 2 日

独创性声明

本人声明所呈交的论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得华中农业大学或其他教育机构的学位或证书而使用过的材料，指导教师对此进行了审定。与我一同工作的同志对本研究所做的任何贡献均已在论文中做了明确的说明，并表示了谢意。

研究生签名：刘晓　　时间：2026 年 6 月 2 日

学位论文使用授权书

本人完全了解华中农业大学关于保存、使用学位论文的规定，即学生必须按照学校要求提交学位论文的印刷本和电子版本；学校有权保存提交论文的印刷版和电子版，并提供目录检索和阅览服务，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。本人同意华中农业大学可以用不同方式在不同媒体上发表、传播学位论文的全部或部分内容，为存在馆际合作关系的兄弟高校用户提供文献传递和交换服务，同时本人保留在其他媒体发表论文的权利。

注：延迟上网学位论文达到上网时间后适用于本授权书。

学位论文作者签名：刘晓　　导师签名：王

签名日期：2026 年 6 月 2 日　　签名日期：2026 年 6 月 3 日

注：请将本表直接装订在学位论文的扉页和目录之间

目录

摘要 i
Abstract iii
缩略词表 v
1 前言 1
1.1 研究问题的由来 1
1.2 全基因组选择及其预测模型 2
1.2.1 全基因组选择概述 2
1.2.2 统计类预测模型及其在育种中的应用 2
1.2.3 贝叶斯类预测模型及其在育种中的应用 4
1.3 机器学习在全基因组选择中的应用 6
1.3.1 机器学习方法概述 6
1.3.2 常用机器学习基模型及其原理 7
1.3.3 机器学习在动植物基因组选择中的应用 7
1.3.4 机器学习在园艺作物育种中的应用现状 8
1.4 基于熵权-TOPSIS 的多准则综合评价方法 8
1.4.1 模型多指标综合评价的需求与挑战 8
1.4.2 熵权法的客观赋权原理 9
1.4.3 TOPSIS 算法原理及其与熵权法的结合 9
1.4.4 熵权-TOPSIS 在机器学习模型优选中的应用探究 10
1.5 集成学习与 Stacking 策略 11
1.5.1 集成学习方法概述 11
1.5.2 Stacking 集成策略及其优势 12
1.5.3 集成学习在园艺作物育种中的应用现状 12
1.6 研究目的与意义 13
2 材料与方法 15
2.1 数据预处理 15
2.1.1 表型处理 15
2.1.2 基因型数据的处理与质量控制 15
2.2 数据描述 15
2.2.1 六种代表性植物基准测试数据 15
2.2.2 西瓜、甜瓜、黄瓜低维数据 16
2.2.3 番茄、莴苣高维数据 17
2.3 数据降维 18
2.3.1 连锁不平衡 18
2.3.2 全基因组关联分析 *P* 值筛选 18
2.4 传统统计模型 19
2.4.1 GBLUP 19
2.4.2 rrBLUP 19
2.5 机器学习模型 20
2.5.1 SVR 20
2.5.2 KRR 22
2.5.3 KNN 23
2.6 机器学习模型的调用 24
2.7 基于熵权 TOPSIS 方法 24
2.8 Stacking 集成学习方法 26
2.9 计算平台与硬件环境 27
2.10 模型构建与效果评价 27
2.10.1 模型构建 27
2.10.2 交叉验证 29
2.10.3 预测效果评价指标 29

3 结果与分析 31
3.1 基于熵权 TOPSIS 的候选预测模型综合评价与筛选 31
3.1.1 多物种多性状的机器学习算法预测性能比较 31
3.1.2 TOPSIS 客观优选与经验选择的一致性验证 34
3.2 GPSE 在园艺作物低维基因组数据中的预测效果验证 36
3.2.1 GPSE 与机器学习模型的预测精度比较 36
3.2.2 GPSE 与传统统计模型的预测精度比较 42
3.3 GPSE 在园艺作物高维基因组数据中的预测效果验证 43
3.3.1 两种降维策略的标记分布特征分析 43
3.3.2 LD 与 GWAS-*P* 降维策略的全基因组预测效果对比 45
3.3.3 基于 GWAS-*P* 策略的 GPSE 与机器学习模型预测精度比较 47
3.3.4 基于 GWAS-*P* 策略的 GPSE 与传统统计模型预测精度比较 52
3.4 GPSE 在多分类任务的预测表现 54
3.5 SNP 数量对 GPSE 预测准确性的影响 55
4 讨论 57
4.1 单一基因组预测模型缺乏普遍适用性 57
4.2 基于熵权 TOPSIS 的算法综合评估 57
4.3 GPSE 集成学习的精度与多样性权衡 58
4.4 特征选择策略对全基因组预测效果的影响 59
4.5 GPSE 在园艺作物应用的可行性与局限 60
参考文献 62
附录 68
华中农业大学研究生学位论文图表原始记录存查表 70
致谢 73

摘要

近年来，随着测序成本的显著下降，园艺作物育种领域积累了海量的高维遗传数据。同时，由于其核心农艺性状往往具有复杂的遗传背景，传统的全基因组选择方法在处理此类数据时，直接面临着计算效率不足与预测精度受限的双重挑战。为此，机器学习凭借优异的非线性拟合与高维数据处理能力被逐步引入该领域。然而，在多物种、多性状的实际育种场景中，单一机器学习模型对不同遗传结构的性状存在显著的预测偏好，且当前主流的模型筛选机制过度依赖单一评价指标，难以契合实际应用需求。针对上述难题，本研究引入基于熵权的 TOPSIS 算法，多维度综合评价并精准筛选最优机器学习算法。在此基础上，依托 Stacking 集成学习框架深度融合优质模型，突破了单一模型精度上限，构建了全新的基因组预测框架—GPSE（Genomic Prediction and Selection Ensemble）。本研究取得的主要结果如下：

1. 本研究在 6 种代表性植物的多类农艺性状数据集上，系统评估了多种模型的预测性能，充分证实了单一预测模型存在显著的物种与性状特异性。针对传统评价体系的片面性，引入基于熵权的 TOPSIS 算法，通过综合考量模型的预测准确性与稳定性，有效克服了单一评价指标的局限，验证了该方法在客观评价与精准筛选优质基学习器方面的可行性。

2. 在筛选出最优基学习器的基础上，本研究构建了多阶段渐进式全基因组预测框架 GPSE。该框架前端集成自动化数据质控模块，后端依托 Stacking 集成策略，借助元学习器实现底层模型的最优融合，有效突破了单一模型的性能瓶颈，从根本上提升了全基因组预测的精度与泛化能力。

3. 在园艺作物低维基因组数据的 11 项性状验证中，GPSE 框架的总体预测性能优于 10 种单一机器学习模型及传统统计模型，准确率最高分别提升 6.67%和 8.38%。在应对园艺作物高维基因组数据时，本研究证实基于 GWAS-*P* 的降维策略显著优于 LD 策略。进一步 GPSE 框架联合 GWAS-*P* 策略对 16 个复杂表型进行评估，结果表明其在多数性状上突破了现有单一机器学习与传统统计模型的性能瓶颈，最高提升幅度分别可达 32.4%和 15.6%。

4. 针对多分类质量性状预测任务，GPSE 模型的特征曲线下面积（AUC）稳定在 0.90 左右，整体分类效能显著优于在该类性状预测中极具优势 RF 模型。

5. 随着 SNP 标记密度的增加，各模型的预测精度普遍呈现先上升后逐渐稳定的变化趋势。尤为关键的是，在 5%-20%的极低 SNP 覆盖度条件下，GPSE 框架的预测精度依然能够稳定在 0.638-0.699 之间。相比于在此区间内预测性能发生骤降的传统机器学习模型，GPSE 有效克服了 SNP 缺失带来的干扰，凸显出其在应对稀疏基因型数据时卓越的适应性与稳定性。

关键词：基因组选择；机器学习；园艺作物；集成学习；多维评价

Abstract

In recent years, with the significant decrease in sequencing costs, massive amounts of high-dimensional genetic data have been accumulated in the field of horticultural crop breeding. Meanwhile, since their core agronomic traits often possess complex genetic backgrounds, traditional genomic selection methods directly face the dual challenges of insufficient computational efficiency and limited prediction accuracy when processing such data. Therefore, machine learning, with its excellent capabilities in non-linear fitting and high-dimensional data processing, has been gradually introduced into this field. However, in practical breeding scenarios involving multiple species and traits, single machine learning models exhibit significant prediction preferences for traits with different genetic architectures, and current mainstream model screening mechanisms over-rely on a single evaluation metric, making it difficult to meet practical application needs. To address these challenges, this study introduces the entropy weight-based TOPSIS algorithm to comprehensively evaluate from multiple dimensions and accurately screen the optimal machine learning algorithms. On this basis, relying on the Stacking ensemble learning framework to deeply integrate high-quality models, the accuracy upper limit of single models is broken through, and a novel genomic prediction framework, GPSE (Genomic Prediction and Selection Ensemble), is constructed. The main results obtained in this study are as follows:

1. This study systematically evaluated the prediction performance of various models on datasets of multiple agronomic traits from 6 representative plants, fully confirming that single prediction models exhibit significant species and trait specificity. Aiming at the one-sidedness of traditional evaluation systems, the entropy weight-based TOPSIS algorithm was introduced. By comprehensively considering the prediction accuracy and stability of the models, it effectively overcame the limitations of single evaluation metrics and verified the feasibility of this method in objectively evaluating and accurately screening high-quality base learners.

2. Based on the screening of optimal base learners, this study constructed a multi-stage progressive whole-genome prediction framework, GPSE. The front end of this framework integrates an automated data quality control module, and the back end relies on the Stacking ensemble strategy, utilizing a meta-learner to achieve the optimal integration of underlying models. This effectively breaks through the performance bottlenecks of single models and

fundamentally improves the accuracy and generalization ability of whole-genome prediction.

3. In the validation of 11 traits using low-dimensional genomic data of horticultural crops, the overall prediction performance of the GPSE framework outperformed 10 single machine learning models and traditional statistical models, with maximum accuracy improvements of 6.67% and 8.38%, respectively. When dealing with high-dimensional genomic data of horticultural crops, this study confirmed that the GWAS-*P*-based dimensionality reduction strategy was significantly superior to the LD strategy. Furthermore, the GPSE framework combined with the GWAS-*P* strategy was evaluated on 16 complex phenotypes. The results showed that it broke through the performance bottlenecks of existing single machine learning and traditional statistical models on most traits, with maximum improvement margins reaching 32.4% and 15.6%, respectively.

4. For multi-class qualitative trait prediction tasks, the area under the curve (AUC) of the GPSE model stabilized at around 0.90, and its overall classification efficiency was significantly superior to the RF model, which is highly advantageous in predicting such traits.

5. With the increase in SNP marker density, the prediction accuracy of all models generally showed a trend of initial increase followed by gradual stabilization. Crucially, under the conditions of extremely low SNP coverage of 5%-20%, the prediction accuracy of the GPSE framework remained stable between 0.638 and 0.699. Compared to traditional machine learning models whose prediction performance plummeted within this range, GPSE effectively overcame the interference caused by missing SNPs, highlighting its excellent adaptability and stability when dealing with sparse genotypic data.

Keywords: Genomic selection; Machine learning; Horticultural crops; Ensemble learning; Multi-dimensional evaluation

缩略词表

缩写符号 Abbreviation	英文全称 English name	中文名称 Chinese name
TOPSIS	Technique for Order Preference by Similarity to Ideal Solution	逼近理想解排序法
GWAS-*P*	Genomic-Wide Association Study *P*-value screening	全基因组关联分析 *P* 值筛选
LD	Linkage Disequilibrium	连锁不平衡
RF	Random Forest	随机森林
SNP	Single Nucleotide Polymorphism	单核苷酸多态性
BLUP	Best Linear Unbiased Prediction	最佳线性无偏预测
MAS	Marker Assistant Selection	标记辅助选择
QTL	Quantitative Trait Locus	数量性状基因座
GS	Genomic Selection	基因组选择
GBLUP	Genomic Best Linear Unbiased Prediction	基因组最佳线性无偏预测
rrBLUP	Ridge Regression Best Linear Unbiased Prediction	岭回归最佳线性无偏预测
ABLUP	Pedigree-based Best Linear Unbiased Prediction	基于系谱矩阵的最佳线性无偏预测
GBM	Gradient Boosting Machine	梯度提升机
TGBLUP	Threshold Genomic Best Linear Unbiased Prediction	阈值基因组最佳线性无偏预测
ML	Machine Learning	机器学习
SVM	Support Vector Machine	支持向量机
GTB	Gradient Tree Boosting	梯度提升树
SVR	Support Vector Regression	支持向量回归
KRR	Kernel Ridge Regression	核岭回归
MLP	Multilayer Perceptron	多层感知机
GBDT	Gradient Boosting Decision Tree	梯度提升决策树

缩写符号 Abbreviation	英文全称 English name	中文名称 Chinese name
MCDM	Multi-Criteria Decision Making	多准则决策
XGB	eXtreme Gradient Boosting	极端梯度提升
LGBM	Light Gradient Boosting Machine	轻量级梯度提升机
Ada	Adaptive Boosting	自适应提升算法
KNN	K-Nearest Neighbors	K 近邻算法
Bagging	Bootstrap Aggregating	自助聚合
HGB	Histogram-based Gradient Boosting	直方图梯度提升
CatB	Categorical Boosting	类别型特征梯度提升
GM	Grain Moisture	籽粒含水量
DBH	Diameter at Breast Height	胸径
ST	Stability	稳定性
SD	Standard Deviation	标准差
YLD	Yield	产量
FT	Flowering Time	开花时间
HT	Height	株高
STAL	Stamen Length	雄蕊长度
OLD	Ovary Longitudinal Diameter	子房纵径
FSD	Fruit Stalk Diameter	果柄粗度
OTD	Ovary Transverse Diameter	子房横径
SPR	Sepal Length to Petal Length Ratio	萼片与花瓣长度比
FSL	Fruit Stalk Length	果柄长度
PL	Petal Length	花瓣长度
FRNS	Fruit Number on the Second Truss	第二果穗果实数
PN	Petal Number	花瓣数量
IL	Internode Length	节间长度
ROC	Receiver Operating Characteristic	受试者工作特征曲线
AUC	Area Under Curve	曲线下面积
LAC	Leaf Anthocyanin Coloration	叶片花青素显色
LT	Leaf Texture	叶片质地
LL	Leaf Lobing	叶缘缺刻
HF	Head Formation	结球性
OLT	Outer Leaf Tone	外叶颜色

1 前言

1.1 研究问题的由来

随着全球人口的持续增长和气候环境极端化带来的严峻挑战，现代农业对高产、优质、多抗农作物新品种的需求日益迫切。在园艺作物的育种实践中，传统的基于表型的育种方法不仅周期长、效率低，还容易受到环境因素的干扰，难以满足现代种业对新品种快速迭代的要求。为突破传统育种的局限性，全基因组选择作为新一代的育种技术应运而生，其通过利用高密度分子标记来估算个体的基因组估计育种值，从而能够较早地对优良个体进行选择（Meuwissen et al 2001）。该技术打破了传统育种的世代限制，显著提高了遗传增益，已成为当前园艺育种领域的核心技术与发展趋势。在全基因组选择中，预测模型的选择直接决定了育种值的准确性。现阶段，以 BLUP 类和贝叶斯类模型为代表的传统统计学预测模型在园艺育种中应用最为广泛。然而，此类模型多基于线性假设。鉴于园艺作物的品质与抗性等核心性状往往受复杂调控网络驱动，表现出强烈的非线性遗传效应，传统线性模型在捕捉这些复杂遗传交互时存在明显的局限性。随着测序成本的降低，园艺作物基因组数据呈爆炸式增长。这些数据普遍具有高维度与多重共线性的复杂特征，使得传统预测模型在处理海量信息时，面临计算效率低下与预测精度受限的双重困境。

为突破上述瓶颈，近年来，机器学习凭借其强大的非线性拟合能力和处理高维数据的优势，被广泛引入全基因组选择领域。然而随着其在多个物种和性状中的应用，研究人员发现单一的机器学习模型针对不同遗传背景和遗传结构的性状存在偏好性，单一模型的预测准确性已逐渐达到瓶颈。为突破这一限制，汇集多个单一机器学习算法优势的集成学习逐渐受到关注，并已在动物育种领域取得显著成果。然而，要构建高效的集成学习框架，前提是科学选择具有差异化优势的最优基模型。现有的模型评价往往仅依赖于相关系数等单一指标，缺乏对模型预测精度、泛化能力及稳健性等多维度的系统性量化评估体系，导致基模型的优选缺乏客观依据。因此，本研究拟引入多准则综合评价方法，建立一套科学的机器学习基模型量化筛选体系，并在此基础上耦合集成学习策略，展开深入探讨，从而构建一种新的园艺作物全基因组选择预测框架。

1.2 全基因组选择及其预测模型

1.2.1 全基因组选择概述

为了突破传统经验育种的局限，分子标记辅助选择（Marker-Assisted Selection, MAS）应运而生，这开启了分子育种时代（Ragot et al 1994）。针对由少数基因控制的质量性状，MAS 是一种极为高效的选育手段（Ribaut and Hoisington 1998）。然而，对于产量等具有重要经济价值的复杂表型，其往往由大量微效数量性状位点（QTL）共同调控，且极易受到环境因素的干扰。尽管这些微效 QTL 的累加效应对表型具有决定性影响，但由于其单位点效应极低，MAS 难以对这些微小效应进行有效捕捉与累加，导致其在复杂性状改良中面临瓶颈。（Kearsey and Farquhar 1998, Nakaya and Isobe 2012）。此外，MAS 高度依赖于前期的 QTL 定位与显著性检验。在实际育种中，试图将大量微效 QTL 聚合至优良遗传背景的尝试，不仅程序极其繁琐，且面临严重的重组率限制，导致育种效率低下。（Bernardo 2014, 2020）。为了从根本上克服 MAS 方法的局限性，Meuwissen 等人（Meuwissen et al 2001）提出了一种全新的范式——基因组选择（Genomic Selection, GS）。GS 不再预先筛选显著标记，而是将覆盖全基因组的所有分子标记同时纳入模型，以估计它们对复杂性状的综合效应。

GS 的基本统计预测模型可由以下方程式表示：

$$P = \sum g_i x_i + E \tag{1.1}$$

在该方程中，P代表个体的表型预测值，g_i是与第i个标记基因座基因型相关的等位基因效应值，x_i是量化编码后的标记基因型状态，而E则为环境及其他无法被模型解释的残差效应。由于高通量测序技术的发展，实际研究中获取的分子标记数量（p）往往数以万计，远超可供观测的表型个体或基因型数量（n）。这种$p \gg n$的数据结构打破了经典多元线性回归模型的基本适用条件，导致自由度耗尽和严重的多重共线性。为了解决这一统计学难题，研究者们基于对标记效应先验分布的不同假设，开发了多种降维或带惩罚项的统计训练模型（Liu et al 2018, Samal et al 2021, Wang et al 2018）。

1.2.2 统计类预测模型及其在育种中的应用

为实现育种值的精准估计，不仅需要优化遗传效应的预测，还需有效剔除环境等固定效应对表型观测值的干扰。基于此，最佳线性无偏预测（Best Linear Unbiased

Prediction, BLUP）方法应运而生，通过在统一线性模型下同时处理固定效应与随机效应，实现了对育种值的无偏估计（Goldberger 1962）。具体而言，BLUP 方法通过引入群体间遗传亲缘关系来估计育种值，并同时对表型数据进行系统发育效应的修正，实现了对育种值的无偏估计。Henderson 在 BLUP 的基础上进一步提出了基于混合模型方程组（Mixed Model Equations, MME）的统计框架，使其成为线性混合模型中估计和预测随机效应的核心算法（Henderson 1975）。在实际应用中，BLUP 能够对所有评估对象进行同步计算，通过拟合线性模型来校正不同对象间的固定效应，从而实现对目标性状的无偏估计。

随着全基因组选择技术的快速发展，已涌现出多种不同预测模型，但选择最合适的模型对于实现预测精度的最大化至关重要。在作物育种的实际应用中，BLUP 类模型是目前应用最为广泛的评估方法，其主要涵盖了基于系谱的传统 BLUP（ABLUP）、基因组最佳线性无偏预测（GBLUP）以及岭回归最佳线性无偏预测（rrBLUP）。其中 ABLUP 作为预测育种值的经典标准方法，其主要利用系谱信息推导个体间的关联性，并假设随机加性效应服从正态分布（Crossa et al 2010）。为进一步提高预测模型的准确度，GBLUP 在 ABLUP 的基础上进行了重大革新。GBLUP 弃用了传统的系谱关系矩阵（A 矩阵），转而使用基于全基因组分子标记构建的基因组关系矩阵（G 矩阵）来估计加性效应（Burgueño et al 2012, Kremer et al 2007, Wang et al 2014）。相较于 ABLUP，GBLUP 具有显著的潜在优势：它利用分子标记直接计算成对个体间真实的遗传相似度（即孟德尔抽样方差），取代了 ABLUP 中仅依靠家族历史推导的预期相似度，从而极大幅度降低了模型对系谱记录完整性及相关强假设的依赖（de Los Campos et al 2013）。

在全基因组选择的众多算法中，rrBLUP 与 GBLUP 是应用最为广泛的两种经典 BLUP 模型变体。在计算方法与数学本质上，rrBLUP 与 GBLUP 高度等价（Sahoo et al 2022b, Wang et al 2015），但两者的参数化路径有所不同。GBLUP 主要依赖基因组关系矩阵来估计加性遗传效应，而 rrBLUP 则是基于经典的岭回归模型（Hoerl and Kennard 1970），直接对全基因组范围内的分子标记效应进行求解。

rrBLUP 模型的核心统计学假设是：所有参与建模的分子标记均对目标性状具有效应，且这些标记效应服从均值为零、方差恒定的正态分布（Bernardo and Yu 2007, Burgueño et al 2012, Sahoo et al 2022a）。在模型求解过程中，rrBLUP 会对单核苷酸多态性（SNP）的效应值进行统一的收缩估计，其收缩程度既可通过 rrBLUP 的正则

化惩罚参数来决定，在数学上也等效于 GBLUP 中的方差组分比值（Heslot et al 2012）。基于这种等方差与微小效应的假设，当目标性状是由大量微效多基因共同调控的复杂数量性状时，rrBLUP 能够提供具有较高准确度的预测结果（Burgueño et al 2012, Onogi et al 2015）。然而，在实际的种质资源评估和遗传改良中，许多性状的遗传结构往往由少数主效基因和大量微效多基因共同构成。此时，所有标记方差相等的假设与实际生物学机理相悖（Sahoo et al 2023），为了更准确地反映真实的遗传变异分布，允许标记具有异质方差的贝叶斯模型应运而生。

在全基因组选择体系中，BLUP 及其衍生模型通过实现对基因组估计育种值（GEBV）的准确预测，显著提升了选育强度并缩短了育种周期，从而加速了多种作物的遗传增益获取与种质改良进程。在玉米育种中，将多性状 rrBLUP 与全基因组关联分析（GWAS）相融合，不仅能有效解析复杂的遗传结构，还在与随机森林等机器学习模型的交叉验证中，展现出对单倍体诱导系相关性状更高的预测准确性（Chen et al 2025）。在小麦育种方面，面对高维数据的分类性状预测需求，研究人员通过将基于阈值的贝叶斯 BLUP（TGBLUP）与梯度提升机（GBM）等集成学习算法进行系统性基准测试，为复杂环境下的模型筛选与预测性能提升提供了关键的方法论依据（Montesinos‐López et al 2022）。在水稻改良项目中，利用 GBLUP 提前预测并筛选高产优良品系，使得育种家能够在缺乏大规模田间表型数据的情况下进行早期精准选择，成功将育种周期缩短了约 1.5 年，这最终成倍提升了育种工作的年度遗传增益（Biswas et al 2023）。

1.2.3 贝叶斯类预测模型及其在育种中的应用

贝叶斯分析作为一种经典的统计推断方法，其核心在于将先验信息与样本观测数据相结合。通过贝叶斯定理，将对总体参数的初始认知更新为后验概率分布，从而实现对复杂遗传参数的精准估计（Van de Schoot et al 2021）。应用该模型的首要步骤是预先指定目标参数的概率分布，进而推导出参数的后验概率分布，这些后验分布为参数的最终估计提供了基础（Mila and Ngugi 2011）。在该方法中，覆盖全基因组的 SNP 被广泛应用于动植物的育种值估计。在统计分析中对 SNP 效应进行训练，使得我们能够在个体观测数量远小于海量 SNP 标记数量的情况下，依然能够有效估计标记效应（Habier et al 2011）。然而，该分析的一个核心环节是确定参数在总体中

的概率分布，由于贝叶斯方法允许引入主观和客观数据来预先设定这一分布，因此也有研究者认为贝叶斯分析缺乏一定客观性（Habier et al 2011）。

在模型对比方面，诸如GBLUP的直接方法通常是先构建SNP与个体间的关联，随后利用混合模型方程直接确定遗传价值。相比之下，贝叶斯方法往往比其他 QTL 和遗传值预测模型更为有效，因为该方法倾向于将许多无效应的 SNP 归并为无效状态（Meuwissen et al 2001）。此外，当大效应变异对复杂性状产生贡献时，贝叶斯方法能够为 SNP 效应的特定子集分配更高的方差，研究表明，在此类情况下其预测精度显著高于 GBLUP（Hayes et al 2010）。

基于标记效应存在先验分布的假设，研究者提出了多种贝叶斯模型。在这些分析中，对模型参数的最终推断均依赖于标记效应的后验分布。目前，应用于全基因组预测的贝叶斯模型已发展出多种形式，主要包括 Bayes A、Bayes B、Bayes Cπ 和 Bayes Dπ（Habier et al 2011, Meuwissen et al 2001），以及诸如贝叶斯 LASSO 等衍生方法。在具体应用场景上，不同模型展现出不同的优势。由于 Bayes A 和 Bayes Cπ 的收缩水平低于 Bayes B，这两种模型更适用于分析由多个基因共同控制的性状。相反，Bayes B 模型的预设前提是绝大多数基因座对目标性状毫无影响，因此在模型运行中不会考虑大部分的分子标记。当目标性状主要由少数贡献了较大遗传方差的主效 QTL 控制时，Bayes B 模型能够展现出极佳的预测性能。（Munkvold et al 2009）。此外，在处理真实数据时，Bayes Cπ 展现出了比 Bayes B 更强的适用性。与 Bayes B 不同，Bayes Cπ 允许直接从实验观测数据中确定模型参数，从而能够更灵活、客观地估算收缩水平，这使得它在实际数据分析中更具优势。

贝叶斯类模型在植物全基因组选择与复杂性状解析中展现出了极大的统计学优势，其应用可显著加速作物的遗传改良进程。在玉米育种中，跨地域、跨气候的表型预测始终是一大挑战。贝叶斯模型凭借其处理复杂交互作用的优势，被广泛用于解析基因型与环境（G×E）的互作效应。通过引入环境核矩阵构建多环境贝叶斯框架，研究者能够有效捕捉不同环境下的随机效应，从而显著提升玉米在跨环境测试中的预测准确性（Cuevas et al 2017）。在小麦育种中，产量与抗性等核心性状往往存在复杂的遗传相关性。基因组贝叶斯多性状多环境模型（Bayesian MTME）为协同改良这些性状提供了强有力的工具。该模型通过有效整合多维数据并捕捉性状间的协方差结构，能够精准解析性状间的遗传互作，从而显著提升了多目标育种下的基因组预测精度（Montesinos-López et al 2016）。而在水稻育种中，贝叶斯方法不仅用

于传统的育种值预测，还为解析性状间的因果关联提供了新视角。结合基因组贝叶斯验证性因子分析与贝叶斯网络，可精准构建水稻数十种农艺性状（如产量、花期、形态等）之间的条件依赖图谱，为水稻多性状的同步改良和间接选择提供可靠的统计学依据（Momen et al 2021）。

1.3 机器学习在全基因组选择中的应用

1.3.1 机器学习方法概述

机器学习（Machine Learning）作为计算机科学的一个重要分支，并非单一的技术，而是一个综合性极强的方法论体系。它通过构建统计模型并依托复杂的算法，从海量的大数据中深度挖掘、提取并总结出具有高价值的特征信息，进而实现精准预测（Grinberg et al 2020）。机器学习凭借在数据处理和建模方面的出色性能，现阶段已成功应用于生物、医学等多个领域，备受研究者青睐（Libbrecht and Noble 2015）。

随着测序技术的更迭，基因组数据量呈现爆发式增长。机器学习凭借其强大的自动化特征提取能力，能够从海量高维数据中高效筛选关键遗传变异。这种数据驱动的模式极大地简化了传统统计方法中繁琐的人工特征工程，在显著提升运算效率的同时，有效降低了科研与育种实践的成本。

从数据结构特性来看，海量的农业基因组数据具有极高的维度，且在特征空间内表现出复杂的共线性与非线性相关性。为了便于计算机高效处理，必须通过特定的数学转换，将这些复杂的多维数据系统地格式化，并降维或转化为在各自维度上具有统一尺度的数学矩阵。在这一处理阶段，矩阵标准化方法的选择显得尤为关键。采用不同的标准化策略会直接导致底层数据分布的改变，进而影响最终计算的准确性（Grinberg et al 2020）。在与混合线性模型（Mixed Linear Model）等传统统计学方法进行性能对比时,机器学习还展现出了更为深层的优势。它不仅能够构建高效的模型来估计标记效应，从而覆盖与复杂性状相关的遗传变异；更重要的是，它不依赖于对数据分布或遗传模型的严格假设。这意味着机器学习能够以“黑箱模型”的方式，来处理传统方法难以应对的非线性与复杂的交互结构，从而在大群体样本的表型预测中表现出更高的准确度（Liu et al 2018）。

1.3.2 常用机器学习基模型及其原理

现有机器学习算法通常可分为三大类：监督学习、无监督学习和强化学习。监督学习从带有标签的数据中学习规律，其核心过程是通过最小化损失函数L来寻找最优预测器$f(x,\beta)$（其中β为模型参数向量），从而基于一组自变量（特征x）准确预测因变量y（Crisci et al 2012, Pereira and Borysov 2019）；根据目标变量的连续或离散性质，它被广泛应用于回归和分类问题，其延伸任务还包括结合部分有标签和无标签数据的半监督学习（Jordan and Mitchell 2015），常见模型有支持向量机（SVM）、随机森林（RF）、梯度提升机（GBM）等。无监督学习则主要处理无标签数据，旨在发现数据内部的潜在结构或聚类模式，因缺乏目标变量指导而常用于聚类分析和高维组学数据的特征降维，有主成分分析 PCA 等方法（Mahesh 2020, Sharma and Kumar 2017）。强化学习受生物系统启发，侧重于智能体与动态环境的交互，通过不断试错接收环境反馈的标量奖励或惩罚信号来动态优化行为策略，以实现累积奖励最大化如经典的 Q-学习和深度强化学习（Kaelbling et al 1996, Neftci and Averbeck 2019）。基因组预测的核心任务是构建基因型与表型间的映射关系。基于此，监督学习凭借其在处理此类回归任务中的天然优势，已成为当前育种预测的主流技术。相比之下，无监督学习更多用于数据降维或群体结构分析等预处理环节，而强化学习在这一领域的应用尚处于探索阶段。

1.3.3 机器学习在动植物基因组选择中的应用

凭借卓越的数据挖掘与预测能力，机器学习已成为解析高通量测序数据的核心工具。近年来，众多研究已成功将其引入动植物的基因组育种值（GEBV）预测中。目前，该领域常用的机器学习算法主要包括：支持向量回归（Support Vector Regression, SVR）（Gianola et al 2011）、随机森林（Random Forest, RF）（Libbrecht and Noble 2015）、核脊回归（Kernel ridge regression, KRR）（González‐Camacho et al 2018）、多层感知机（Multilayer Perceptron, MLP）（Zou et al 2019）、梯度提升决策（Gradient Boosting Decision Tree, GBDT）（Liu et al 2025）、极端梯度提升（Extreme Gradient Boosting, XGB）（Deng et al 2022）、轻量级梯度提升机（Light Gradient Boosting Machine, LGBM）（Yan et al 2021）、自适应提升（Adaptive Boosting, Ada）（Liang et al 2021b）、K 近邻（K-Nearest Neighbors, KNN）（Karacaören 2022）。

1.3.4 机器学习在园艺作物育种中的应用现状

全基因组选择已成为园艺作物复杂性状改良的核心策略。然而，传统线性统计模型主要侧重于加性效应的评估，在解析园艺作物中广泛存在的非加性效应（Liu et al 2021）以及应对海量高维数据时，往往存在局限。近年来，机器学习凭借其强大的非线性拟合与特征提取能力，为突破上述局限提供了高效的技术手段。

在西瓜枯萎病抗性的研究中，RF 等非参数机器学习模型对多基因抗性的预测准确率优于 Bayes 和 SVM 模型，与 GBLUP 表现相当甚至更优（Biswas et al 2025）。对于表型鉴定成本高昂的品质与形态性状，机器学习能够高效整合多维高通量数据以建立高精度预测模型。利用靶向代谢组学与消费者感官评价数据，XGB 等机器学习模型成功实现了对蓝莓和番茄复杂风味感知的高精度预测，并准确解析了挥发性有机物对风味变异的高贡献率（Colantonio et al 2022）。在茄科作物番茄和辣椒的形态与色泽性状预测中，机器学习模型结合高通量图像分析工具，使辣椒果实宽度的预测准确率达到了 0.89，并在训练集中合理引入野生种材料，有效提升模型对未知群体的泛化能力（Tong et al 2022）。在葡萄育种中，通过结合多组学技术获得关键的抗虫基因，然后基于机器学习构建的全基因组选择模型在预测葡萄抗虫性状时表现出极高的准确性（Gan et al 2025）。

园艺作物的经济价值高度依赖于产量、外观品质、风味、营养物质等受到多基因控制的数量性状，这些性状受到多个微效基因和环境的综合调控。随着各类园艺作物高质量参考基因组的破译和多组学数据的指数级增长，急需使用机器学习对海量数据进行高效降维和有效遗传信息捕捉。将机器学习应用在园艺作物的基因组选择育种中，不仅可以解决传统统计模型预测精度差的问题，更可以突破传统育种周期瓶颈。

1.4 基于熵权-TOPSIS 的多准则综合评价方法

1.4.1 模型多指标综合评价的需求与挑战

随着基因组选择技术的不断发展，研究人员引入了多种线性和非线性机器学习算法以期提升表型预测精度。然而，系统性对比研究表明，现阶段没有任何一种单一的机器学习模型能够具有普适性最优预测效果。例如，Azodi 等人利用包含不同标记密度和群体大小的 6 种植物的 18 个性状数据，系统评估了多种线性和非线性算

法，结果证实没有任何单一算法能在所有物种和性状组合中始终保持最佳表现（Azodi et al 2019）。这进一步说明，现有的基因组选择模型普遍存在显著的特异性偏差，其预测性能高度依赖于物种的特异性遗传背景、标记密度以及特定性状的遗传力（Crossa et al 2017, Howard and Lipka 2025, Montesinos-López et al 2025）。此外，当前的模型评价与选择往往依赖于孤立的单一指标，缺乏多维度的综合评估体系来确保模型在不同数据集上的稳健性（Waldmann 2019）。在实际的基因组预测中，一个模型可能在某一项评价指标上表现优异，但在另一项指标上表现极差，这种单一指标间的结果冲突给最优模型的科学筛选带来了极大挑战。因此，当前基因组选择研究迫切需要引入一种能够同时兼顾预测准确性、稳定性和泛化能力的多指标综合评价机制，以全面、客观地衡量不同算法模型的真实预测效能。

1.4.2 熵权法的客观赋权原理

熵的概念最初源于热力学，主要用于衡量系统状态的混乱程度以及评估热能转化为机械功的效率。1948 年，Shannon 首次将这一概念引入信息论（Shannon and Weaver 1948），提出了信息熵。随后，该概念被逐渐拓展应用于更广泛的研究领域，成为衡量随机变量不确定性的重要度量工具。在信息论中，信息熵反映了信息源的不确定程度，系统越有序，其熵值越小，所蕴含的有效信息量越大；反之亦然。基于这一理论，熵权法被发展为一种经典的客观赋权方法，其核心作用在于量化评估指标数据分布的离散程度。该方法的基本原理是：指标权重的赋值与其数据分布的离散程度呈正相关关系。具体而言，当某一评估准则（或指标）的数据变异程度较小（即各样本数据趋于一致，熵值较大）时，说明该指标在评价体系中能提供的有效甄别信息较少，从而导致其被赋予较低的权重（Jha and Singh 2008）。这种完全基于数据自身客观特征进行权重分配的机制，能够有效避免人为赋权带来的主观偏差。

1.4.3 TOPSIS 算法原理及其与熵权法的结合

为了弥补当前模型评估体系中单一指标的局限性并实现多维度综合评价，多准则决策分析（Multi-criteria decision-making, MCDM）提供了一种可靠的方法论框架。MCDM 专门用于解决包含多个属性和评价标准的复杂决策问题，通过特定的策略对备选方案进行综合评估、分类与排序，从而辅助决策者选出最优解（Pandey et al 2023）。在众多 MCDM 技术中，逼近理想解排序法（TOPSIS）因其高度的实用性而被广泛

应用，该方法通过计算各备选方案分别与正理想解和负理想解之间的距离，以此筛选出最接近正理想解且最远离负理想解的方案，从而实现方案从优到劣的科学排序（Hwang and Yoon 1981）。具体而言，正理想解代表所有评价指标均达到最优状态的虚拟方案，而负理想解则相反；TOPSIS 的核心决策逻辑即是寻找最贴近完美状态且最远离极差状态的备选模型。

随着该框架的不断拓展与完善，不同的赋权机制被引入以优化决策模型，例如将模糊层次分析法与模糊 TOPSIS 结合进行方案优选（Torfi et al 2010）。特别是在需要客观权重的决策场景中，基于熵权法确定的权重能够有效放大具有高度数据多样性（DAD）属性在决策过程中的作用，并削弱低差异性属性的干扰。Chen 正是利用了熵权的这一客观优势，证实了基于熵权的 TOPSIS 方法在处理包含多项复杂标准的综合评估问题时具有高度的可靠性（Chen 2021）。此外，Chen 进一步指出，在基于熵权的 TOPSIS 分析中，应优先采用向量标准化而非简单的标准化处理，以确保评价结果的科学性（Chen 2019）。因此，将这一基于客观数据驱动的多准则决策框架引入到基因组选择算法的评价中，有望突破当前过度依赖单一评价指标的盲区。通过构建多维度的综合评估体系，该方法能够为多种机器学习模型在不同数据集上的稳健性评估与科学择优提供强有力的分析工具，进而为育种实践中高效、精准地筛选最佳预测算法提供坚实的理论支撑。

1.4.4 熵权-TOPSIS 在机器学习模型优选中的应用探究

近年来，随着机器学习算法在各个领域的广泛应用，如何科学、客观地从众多候选模型中优选出最佳模型，已成为一项亟待解决的普遍难题。为了克服单一评价指标的局限性并消除人工主观赋权带来的偏差，熵权-TOPSIS 作为一种基于客观赋权的多准则决策框架，已被成功引入多个学科的机器学习模型评价体系中。在医疗诊断领域，模型评价往往面临多项相互冲突的指标。例如，针对 COVID-19 诊断模型的选择问题，已有研究通过构建包含 10 项评价指标和 12 种机器学习算法的决策矩阵，利用熵权法计算指标的客观权重并结合 TOPSIS 进行综合排序，最终有效筛选出了最优诊断模型（Mohammed et al 2020）。类似地，在糖尿病视网膜病变检测模型的基准测试中，采用该综合评价策略从 8 种候选机器学习模型中科学选定了最佳分类器，也成功解决了多维度指标下的权重分配难题（Ahmed et al 2021）。除了医疗领域，该评价框架在复杂的环境系统评估中同样表现出色。例如，有学者将熵权-

TOPSIS 模型与神经网络算法相融合应用于沿海城市洪涝灾害风险评估，不仅显著降低了模型评估过程中的主观性，还实现了比传统二元神经网络更精细的风险分级（Luo et al 2024）。上述跨领域的应用研究充分表明，熵权-TOPSIS 方法在处理包含多重复杂标准的机器学习模型优选问题时具有高度的科学性与可靠性。这些成功实践为本研究打破单一评价指标的局限，将该客观评价框架创新性地引入全基因组选择算法的多维综合优选之中，提供了坚实的理论依据与可行性支撑。

1.5 集成学习与 Stacking 策略

1.5.1 集成学习方法概述

集成学习（Ensemble learning）作为一种前沿的机器学习策略，近年来在全基因组选择领域展现出巨大的应用潜力。全基因组数据通常具有高维度与高复杂性的特征，单一的预测模型往往难以全面捕捉遗传变异与表型之间的复杂映射关系。为弥补单一模型的局限性，集成学习通过组合多个基础学习模型，能够有效整合多方信息，从而显著增强对复杂性状的预测能力。多项研究结果表明，通过结合多个不同特性的预测模型，能够有效抵消观测值与真实值之间的误差，进而实现预测性能的整体跃升（Farooq et al 2023, Kick and Washburn 2023）。此外，借助交叉验证等手段，集成学习不仅能大幅降低模型过拟合的风险、提升其在未知环境下的泛化能力，还可与监督或无监督学习无缝结合。特别是在处理来自不同种群和环境条件下的数据时，集成策略显著提高了模型在基因和环境互作预测中的鲁棒性（Wang et al 2024）。

在当前的基因组选择研究中，集成学习的三大主流策略包括套袋法（Bagging）、提升法（Boosting）以及堆叠法（Stacking）（Arora and Aidhy 2020, Wang et al 2022）。其中，Bagging 策略的核心在于并行化训练多个基础学习器。例如，RF（Breiman 2001）正是通过对原始数据集进行多次有放回的采样来构建多棵决策树，并最终通过取平均值或多数投票来输出最终预测，这一策略有效降低了模型的方差（Breiman 1996）。相对而言，Boosting 策略则采用串行的方式逐步优化模型。诸如 AdaBoost（Freund and Schapire 1997）和 GBM 等方法，其每一次迭代产生的新模型都旨在修正前一轮模型的预测误差。这些经典思想也进一步推动了集成神经网络等更为复杂的预测方法的发展（Li et al 2004, Liu and Li 2008, Zhou et al 2002）。在实际应用中，研究者常通过结合 SVM 和 RF 等多种基础模型进行集成，利用不同模型间的多样性来有效提

升预测效果（Liang et al 2021a）。虽然 Bagging 和 Boosting 策略分别通过并行和串行的方式有效降低了模型的方差与偏差，但在处理全基因组选择中高度复杂的遗传变异映射时，单一的集成架构有时仍显局限，这自然地引出了结构更为深度的 Stacking 策略。

1.5.2 Stacking 集成策略及其优势

相比于 Bagging 的并行和 Boosting 的串行策略，Stacking 进一步加深了基础学习器的层次结构，已逐渐成为全基因组选择领域的另一个核心研究热点（Heilmann et al 2023, Ibtisham et al 2017, Liang et al 2021a, Nascimento et al 2024, Tessema et al 2020）。Stacking 策略的核心原理是利用多个异质的基学习器（如 RF（Hassanali et al 2025）、SVR（Alzubi et al 2018）、GBM（Meharie et al 2022））对数据进行初步预测，随后将这些初步结果作为新特征输入，训练一个元学习器，比如线性回归或其他机器学习方法（Yoon and Kang 2023）进行最终预测。这种方法克服了单一模型的固有限制，在复杂性状的遗传预测中表现突出。例如，LIANG 等开发的 SELF 框架，成功集成了 SVR、KRR 和弹性网络（ENET）等模型，相较于传统的 GBLUP 方法，其预测精度提升了 7.7%（Liang et al 2021a）。类似地，GU 等提出的 ELPGV 框架将 BayesA/B/Cπ 与 GBLUP 模型相融合，在多性状的遗传评估中展现了优异的性能（Gu et al 2024）。YU 等的研究也进一步证实，合理的集成学习框架在提升模型泛化能力和预测精度方面具有巨大潜力（Yu et al 2021）。不仅如此，在特征层面，将不同来源（如 SNP、基因表达数据）的标记信息进行融合集成，更有助于获取全面立体的遗传图谱（Wang et al 2023）。正是这种能够跨越单一模型局限、深度融合多种异质模型与多源数据的核心优势，使得 Stacking 等集成策略在解析复杂性状方面表现出巨大的潜力，并顺理成章地成为了当前动植物育种全基因组预测中的核心技术手段。

1.5.3 集成学习在园艺作物育种中的应用现状

全基因组选择是现代动植物育种的关键环节，集成学习策略已逐渐从计算机科学领域深度拓展到动植物育种的实际应用中。尽管 Stacking 集成在基因组选择中取得了丰硕的成果，但在其实际构建与优化过程中仍面临着关键性挑战。首先，在 Stacking 集成学习的基础学习器（BLs）选择这一关键步骤上，现有研究普遍依赖主观经验来挑选固定数量和种类的模型（Nascimento et al 2024, Nukui and Onogi 2023）。

然而，既往研究已明确指出，不同的算法在应对不同物种和遗传架构时表现存在显著差异，迄今为止，没有任何一种单一算法能够在所有预测场景中占据绝对优势（Gill et al 2022, Ray et al 2023）。因此，摒弃固定配置，转而开发一种自适应的、数据驱动的筛选机制，根据数据自身特征从海量候选模型中动态选择最匹配的基学习器组合，是未来提升模型效能的关键方向。

针对草莓炭疽病抗性等复杂的抗病性状，集成学习模型展现出了处理高维基因组数据及挖掘复杂遗传架构的卓越能力。以 LGBM、RF 和 XGB 为代表的基于树的机器学习模型，在预测准确率上一致优于传统的线性方法。这种优势主要归功于树基集成算法在捕捉标记间的非线性上位性效应以及复杂的基因型与环境互作机制方面具备天然优势，而这正是传统线性假设模型难以企及的。研究表明，通过在集成框架中引入特征选择机制，剔除冗余标记并保留约 200 个核心 SNPs，不仅大幅降低了模型运算的复杂度，还有效克服了全基因组选择中常见的高维小样本难题。进一步地，结合数据增强策略，该集成框架能够在有限的表型样本量下，实现高达 0.991 的预测准确率（Jang et al 2025）。这一突破对于园艺作物育种具有重要的现实指导意义。与主要农作物相比，园艺作物往往面临着高度杂合、多倍体化或表型鉴定周期长且成本高昂等现实困境，导致高质量的训练样本获取极其困难。上述集成了特征降维与数据增强的机器学习方案，不仅在预测精度上实现了飞跃，更为园艺作物提供了一套兼具极高鲁棒性与高成本效益的 GS 评估体系。这也预示着，针对特定物种的遗传特性，量身定制并优化集成学习的数据预处理与模型融合策略，将成为加速园艺作物品种更新迭代的重要引擎。

1.6 研究目的与意义

全基因组选择的核心目的在于，利用覆盖全基因组的高密度分子标记信息，精准估算未知个体的育种值，从而实现对优良个体的早期高效选择。然而，聚焦于园艺作物，其重要的农艺性状往往具有复杂的遗传背景，对预测模型的要求极为苛刻。面对高维复杂的数据，传统的统计学模型难以取得理想的预测效果。尽管机器学习因其强大的非线性拟合能力被广泛引入该领域，但大量实证研究表明，并不存在一种能够普适于所有数据集的机器学习模型。这就引出了当前育种与数据科学交叉领域亟待突破的瓶颈：如何针对不同数据集进行自适应的模型选择。在现有的模型评估中，研究大多依赖估计育种值与真实表型间的皮尔逊相关系数作为单一评价指标。

这种体系往往无法全面衡量模型的绝对误差水平、泛化能力等多维度表现，难以贴合育种实践的实际应用需求。

针对上述痛点，本研究开发了一种全新的基因组选择预测框架 GPSE。该框架创新性地引入了基于熵权的 TOPSIS 算法，对不同的机器学习模型进行多维度综合评价，从而更加全面科学地选择出与不同数据集相适配的最优算法组合。在此基础上，GPSE 采用 Stacking 集成学习策略对优选出模型的预测结果实现深度融合，以突破单一机器学习模型的精度上限。通过对涵盖不同特征维度的多种园艺作物进行系统评估，结果表明 GPSE 框架在西瓜、黄瓜、甜瓜等低维数据集，以及番茄、莴苣等高维数据集上均展现出卓越的预测性能与稳定性。这充分证实了 GPSE 具备极强的跨物种适用性，可广泛推广至更多园艺作物的全基因组选择育种实践中。

2 材料与方法

2.1 数据预处理

2.1.1 表型处理

数据质量直接决定了算法性能的上限。表型数据中存在的异常值会显著干扰算法的预测效果，进而降低不同模型评估结果的有效性与准确性。因此，在构建预测模型之前，本研究首先对数据集的表型数据进行了预处理，具体步骤如下：

（1）对表型数据进行筛查，剔除异常观测值；

（2）剔除表型记录缺失的样本个体。

2.1.2 基因型数据的处理与质量控制

利用 PLINK 软件（Purcell et al 2007）完成核心质控过程。考虑到不同物种测序平台与群体遗传背景的差异，针对不同物种设定了差异化的过滤阈值，具体质控标准与流程如下所示：

（1）仅保留双等位基因的 SNP 位点；

（2）对于黄瓜、西瓜和甜瓜群体，剔除缺失率大于 0.5 和最小等位基因频率（MAF）小于 0.01 的位点；对于莴苣和番茄群体，则剔除缺失率大于 0.1 和最小等位基因频率（MAF）小于 0.05 的位点；

（3）用 BEAGLE 软件（Browning et al 2018）对缺失的基因型数据进行填充。

2.2 数据描述

2.2.1 六种代表性植物基准测试数据

该基因组预测基准测试集包括水稻、玉米、大豆、云杉、柳枝稷和高粱共 6 种代表性植物的基因型信息，且每种植物均包含了 3 个不同的复杂表型性状，共计 18 个表型数据集。

表 1 6 种植物基因组预测基准测试数据集
Table 1 Genomic prediction benchmark datasets for six plant species

物种	样本量	群体类型	标记类型	标记数量	性状
水稻(Rice)	327	Diversity Panel	GBS	57,543	HT,FT,YLD
玉米(Maize)	391	Diversity Panel	GBS	244,782	HT,FT,YLD
大豆(Soybean)	5014	NAM	SNP-Chip	4,235	HT,R8,YLD
云杉(Spruce)	1722	Partial DM	SNP-Chip	6,931	HT,DBH,DE
柳枝稷(Switchgrass)	514	Diversity Panel	GBS	217,151	HT,FT,ST
高粱(Sorghum)	451	Diversity Panel	GBS	56,300	HT,GM,YLD

HT：株高(Height)；FT：开花期(Flowering time)；YLD：产量(Yield)；GM：籽粒水分(Grain moisture)；R8：达到 R8 发育期的时间(Time to R8 developmental stage)；DBH：胸径(Diameter at breast height)；DE：木材密度(Wood density)；ST：抗倒伏性(Standability)

数据来源：https://doi.org/10.1534/g3.119.400498

2.2.2 西瓜、甜瓜、黄瓜低维数据

西瓜（*Citrullus lanatus*）的原始基因型数据集包含 1,365 个样品，包含有 61,520 个 SNPs。本研究选择性状主要为西瓜对不同病原体的抗性，具体包括茎部对白粉病的抗性（PM race stem）、叶片对白粉病生理的抗性（PM race leaf）以及果实对细菌性果斑病的抗性（BFB fruit）。经过数据的预处理后，最终保留 1,365 个个体和 25,308 个高质量 SNPs 位点。

数据来源：http://cucurbitgenomics.org/

甜瓜（*Cucumis melo*）的原始基因型数据集包含 2,084 个样品，包含 89,204 个 SNPs。本研究选择的性状为百粒重（100-seed weight）、果实宽度（Fruit width）、单果重（Fruit weight）以及可溶性固形物含量（Soluble solids content）。经过数据的预处理后，最终保留 2,084 个个体和 27,471 个高质量 SNPs 位点。

数据来源：http://cucurbitgenomics.org/

黄瓜（*Cucumis sativus*）的原始基因型数据集包含 1,234 个样品，包含有 113,854 个 SNPs。本研究选择的性状为霜霉病抗性（Downy mildew）、开花天数（Days to flower）、蔓枯病抗性（Gummy stem blight）以及炭疽病抗性（Anthracnose）。经过数据的预处理后，最终保留 1,234 个个体和 23,552 个高质量 SNPs 位点。

数据来源：ftp://cucurbitgenomics.org/pub/cucurbit/GBS_SNP/cucumber

2.2.3 番茄、莴苣高维数据

番茄（*Solanum lycopersicum*）的原始基因型数据集包含 606 个样品，包含 23,355,277 个 SNPs。本研究选择性状主要包括 10 个与花器官、果实及植株形态相关的表型指标：雄蕊长度（STAL, stamen length）、子房纵径（OLD, ovary longitudinal diameter）、果柄粗度（FSD, fruit stalk diameter）、子房横径（OTD, ovary transverse diameter）、萼片与花瓣长度比（SPR, sepal length to petal length ratio）、果柄长度（FSL, fruit stalk length）、花瓣长度（PL, petal length）、第二果穗果实数（FRNS, fruit number on the second truss）、花瓣数量（PN, petal number）以及节间长度（IL, internode length）。经过数据的预处理后，最终保留 606 个个体和 2,635,649 个高质量 SNPs 位点。

数据来源：https://doi.org/10.6084%2Fm9.figshare.13019237

莴苣（*Lactuca sativa*）的原始基因型数据集包含 351 个样品。本研究选择的性状主要包括 5 个与叶片形态相关的精细表型指标：叶片长度（Length）、叶片宽度（Width）、叶片表面积（Surface Area）、叶片卷曲度（Curliness）、叶夹角（Angle p1），以及沿叶片平整度（Flatness）。经过数据的预处理后，最终保留了 351 个个体和 22,981,020 个高质量 SNPs 位点。

数据来源：https://doi.org/10.6084/m9.figshare.28553273.v1

莴苣（*Lactuca sativa*）的分类表型数据集包含 268 个样品。本研究选择的性状主要包括 5 个与叶片形态及结球特征相关的分类表型指标：叶片花青素显色（Leaf anthocyanin coloration, LAC），分为无（Absent）、有（Present）、叶缘缺刻（Leaf lobes of margin, LL），分为无（Absent）、浅裂（Lobed）、深裂（Parted）、外叶颜色（Outer leaf color, OLT），分为无（Absent）、黄绿色（Yellowish green）、灰绿色（Grayish green）、红色（Red）、叶片质地（Leaf texture, LT），分为柔软（Soft）、脆（Crisp），以及结球性（Head formation, HF），分为不结球（Nonheading）、松散结球（Loose heading）、紧实结球（Tight heading）。经过数据的预处理后，最终保留了 268 个个体和 3,842,170 个高质量 SNPs 位点。

数据来源：https://doi.org/10.6084/m9.figshare.30017797

2.3 数据降维

2.3.1 连锁不平衡

本研究利用 PLINK 软件（Purcell et al 2007）对经基因型填充后的数据集进行了连锁不平衡（Linkage Disequilibrium, LD）修剪。修剪过程统一采用滑动窗口法，并根据两个物种不同的遗传背景，设定了特异性的修剪阈值。

（1）番茄：基于输入的 2,635,649 个 SNPs 位点，设定滑动窗口大小为 50 个 SNPs，步长为 10 个 SNPs，r^2阈值为 0.2。经修剪后，最终保留了 84,727 个 SNPs。

（2）莴苣：基于输入的 22,981,020 个 SNPs 位点，设定滑动窗口大小为 1,000 个 SNPs，步长为 1 个 SNP，r^2阈值为 0.02。经修剪后，最终保留了 223,462 个 SNPs。

2.3.2 全基因组关联分析 *P* 值筛选

本研究中番茄和莴苣群体的全基因组关联分析（GWAS）均采用 EMMAX 软件（Kang et al 2010）中的混合线性模型（MLM）进行。首先，使用 PLINKv1.90 将 VCF 格式的基因型数据转换为 TPED 格式；随后，通过 emmax-kin 基于 IBS 算法计算样本间的亲缘关系矩阵（Kinship matrix），以校正群体结构对关联检测可能造成的假阳性影响。关联分析的全局显著性阈值均采用 Bonferroni 校正。在此基础上，本研究采用了一种基于全基因组关联分析 *P* 值（Genome-Wide Association Study *P*-value, GWAS-*P*）的多性状联合筛选策略：针对每个单一表型，按关联分析的显著性（*P* 值）由小到大排序并提取最显著的候选 SNP，随后将同一群体内所有表型的候选位点进行跨表型合并与去重。具体群体的分析情况如下：

（1）番茄群体：对 27 个农艺性状分别进行关联分析，提取每个性状 *P* 值最小的前 5,000 个候选 SNPs，跨表型合并与去重后，最终获得 69,652 个候选 SNPs。

（2）莴苣群体：对 20 个农艺性状分别进行关联分析，提取每个性状 *P* 值最小的前 5,000 个候选 SNPs，跨表型合并与去重后，最终获得 68,923 个候选 SNPs。

（3）莴苣分类表型群体：对 27 个农艺性状分别进行关联分析，提取每个性状 *P*值最小的前 3,000 个候选 SNPs，跨表型合并与去重后，最终获得 77,530 个候选 SNPs。

2.4 传统统计模型

2.4.1 GBLUP

GBLUP 假设所有的遗传标记对于性状的影响是同等重要的，它将 Henderson 提出的 BLUP 模型（Henderson 1975）中的系谱矩阵 A 替换为基因型关系矩阵（GRM）。GBLUP 模型可以表示为：

$$y = Xb + Zu + e \tag{2.1}$$

y：长度为$n \times 1$的向量；b：固定效应向量；u：随机效应向量，u服从（$0, G\sigma_a^2$）正态分布；G：标记信息计算的代表个体间亲缘关系的矩阵；σ_a^2：随机效应方差；e：随机残差向量，效应分布服从（$0, I\sigma_e^2$）的正态分布，I：单位矩阵；σ_e^2：残差方差。

b与u的求解可以按照以下公式：

$$\begin{bmatrix} b \\ u \end{bmatrix} = \begin{bmatrix} X'X & X'Z \\ Z'X & Z'Z + \delta G^{-1} \end{bmatrix}^{-1} \begin{bmatrix} X'y \\ Z'y \end{bmatrix} \tag{2.2}$$

GBLUP 和 BLUP 之间的区别在于：GBLUP 用基于全基因组标记信息的亲缘关系矩阵G代替了基于系谱信息的亲缘关系矩阵A。虽然有多种算法可以从基因型数据中推导个体间亲缘关系G矩阵。但是文献中经常使用 VanRaden（VanRaden 2008）提出的高效的算法求解G矩阵，G矩阵推导公式如下：

$$G = \frac{ZZ'}{2\sum p_i(1 - p_i)} \tag{2.3}$$

其中Z是n行m列的中心矩阵（n：是个体数；m：标记数）；p_i：第i个标记的最小等位基因频率。

2.4.2 rrBLUP

rrBLUP 是全基因组选择中最经典的线性惩罚回归模型，最早由 Meuwissen 等人于 2001 年系统性提出（Meuwissen et al 2001）。在介绍 GBLUP 模型中，算法通过构建个体间的基因型关系矩阵（GRM）来隐式地直接估计个体的基因组育种值（GEBV）；而 rrBLUP 则是显式地对全基因组范围内所有分子标记（如 SNP）的效应进行直接估计。

rrBLUP 的核心假设是：所有遗传标记对性状的贡献都是同等且微小的，即假设所有标记效应都独立服从均值为零、方差相同的正态分布。rrBLUP 的线性混合模型可以表示为：

$$y = X\beta + Zg + e \tag{2.4}$$

其中，y为长度为$n \times 1$的表型观测值向量；β为固定效应向量，X为固定效应的关联矩阵；g为随机标记效应向量，假设其服从（$0, I\sigma_g^2$）的正态分布（I为单位矩阵，σ_g^2为单一标记效应方差）；Z为$n \times m$的个体基因型设计矩阵（通常依据等位基因频率编码）；e为随机残差向量，服从（$0, I\sigma_e^2$）的正态分布。

对于该模型，固定效应β和随机标记效应g可以通过求解以下的混合模型方程组来获得：

$$\begin{bmatrix}\hat{\beta}\\ \hat{g}\end{bmatrix} = \begin{bmatrix}X'X & X'Z\\ Z'X & Z'Z + I\lambda\end{bmatrix}^{-1}\begin{bmatrix}X'y\\ Z'y\end{bmatrix} \tag{2.5}$$

其中，λ为岭回归的正则化惩罚参数，其取值由残差方差与标记效应方差的比值决定：

$$\lambda = \frac{\sigma_e^2}{\sigma_g^2} \tag{2.6}$$

在获得所有标记效应的估计值$\hat{g}$后，对于只进行了基因型分型而没有表型记录的候选群体，只需结合其标记矩阵即可预测出个体的全基因组育种值。在数学理论上，当标记数据完整时，rrBLUP 与 GBLUP 的预测结果是完全等价的。两者的区别主要在于计算效率：当标记维度（m）远大于样本量（n）时，GBLUP 求解$n \times n$矩阵的逆更具计算优势；而当样本量大于标记数时，rrBLUP 求解$m \times m$矩阵更为高效。

2.5 机器学习模型

2.5.1 SVR

支持向量机（SVM）模型是一种广泛应用于分类和回归预测问题的机器学习算法。在分类问题中，SVM 模型的基本思想是在高维空间中寻找一个最优超平面，将不同类别的数据进行分割，使两类数据点到超平面的距离最大化来解决分类决策问题。在现实应用中，数据往往是线性不可分的，SVM 模型通过引入松弛变量，并利用核函数将数据映射到高维空间从而使模型可以捕捉复杂的非线性关系。而在回归预测问题中，SVM 被称为支持向量回归机（SVR），基于结构风险最小化原理和 VC 理论，SVR 模型在高维数据和小样本预测中有良好的预测精度（Cortes and Vapnik 1995）。SVR 模型的基本步骤如下：

训练样本为$D=\{(x_1,y_1),(x_2,y_2),\dots,(x_m,y_m)\}$，$y_i\in R$，希望通过建立回归模型使得$f(x)$与$y$可能接近，ω和$b$是待确定的模型参数。

引入松弛变量ξ_i和ξ_i^*，SVR 的目标函数为：

$$\min_{\omega,b}\frac{1}{2}\left||\omega|\right|^2+C\sum_{i=1}^{m}(\xi_i+\xi_i^*) \tag{2.7}$$

其中ξ_i和ξ_i^*的取值为：

$$\begin{gathered} s.t.\ y_i-\omega x-b\le\epsilon+\xi_i,\\ \omega x+b-y_i\le\epsilon+\xi_i^*\\ \xi_i\ge 0,\xi_i^*\ge 0,i=1,2,\dots m. \end{gathered} \tag{2.8}$$

为了最小化目标函数，根据约束条件构造拉格朗日函数：

$$\begin{aligned} L=&\frac{1}{2}\left||\omega|\right|^2+C\sum_{i=1}^{m}(\xi_i+\xi_i^*)-\sum_{i=1}^{m}\alpha_i(\epsilon+\xi_i-y_i+\omega x+b)\\ &-\sum_{i=1}^{m}\alpha_i^*(\epsilon+\xi_i^*+y_i-\omega x-b)-\sum_{i=1}^{m}(\eta_i\xi_i+\eta_i^*\xi_i^*)\\ &s.t.\quad \alpha_i,\alpha_i^*,\eta_i,\eta_i^*\ge 0 \end{aligned} \tag{2.9}$$

令 L 对ω，b，ξ_i，ξ_i^*的偏导为零可得：

$$\omega=\sum_{i=1}^{m}(\alpha_i^*-\alpha_i)x_i \tag{2.10}$$

上述过程需要满足 KKT 条件，同时引入核函数，假设对偶问题最优解为（$\alpha_1,\alpha_1^*,\alpha_2,\alpha_2^*,\dots,\alpha_m,\alpha_m^*$）则最终支持向量回归模型为：

$$f(x)=\sum_{i=1}^{m}(\alpha_i-\alpha_i^*)K(x_i,x)+b \tag{2.11}$$

由于在高维空间进行内积计算较为复杂，SVR 模型可以通过核函数将数据变换到低维空间计算，从而解决了高维空间运算的维数灾难问题。SVR 的常用的核函数主要有径向基核函数、多项式核函数、线性核函数和多层感知器核函数。

（1）径向基核函数

$$K(x,y)=\exp\left\{-\frac{\left||x-y|\right|^2}{2\sigma^2}\right\} \tag{2.12}$$

（2）多项式核函数

$$K(x,y)=(x\cdot y+1)^p,p=1,2,\dots,N \tag{2.13}$$

（3）线性核函数

$$K(x,y)=x\cdot y \tag{2.14}$$

（4）多层感知器核函数

$$K(x,y)=\tanh(kx\cdot y+\theta) \tag{2.15}$$

2.5.2 KRR

核岭回归（Kernel Ridge Regression, KRR）是一种结合了岭回归（Ridge Regression）与核技巧（Kernel Trick）的非线性回归算法（Exterkate et al 2016）。普通的线性岭回归在处理存在严重多重共线性的高维数据（如全基因组分子标记数据）时能够有效防止模型过拟合；然而，当输入特征与目标性状之间存在复杂的非线性关系（如基因间的上位性效应）时，纯线性模型往往难以捕捉这些信息。核岭回归通过引入非线性映射函数$\phi(x)$，将原始输入数据映射到高维特征空间，并在该空间内执行岭回归，从而赋予了模型强大的非线性拟合能力。

在映射后的高维空间中，给定包含n个样本的训练集，核岭回归的目标函数（包含L_2正则化项）可表示为：

$$\min_{w}\frac{1}{2}\sum_{i=1}^{n}\left(y_i-w^T\phi(x_i)\right)^2+\frac{\lambda}{2}\left||w|\right|^2 \tag{2.16}$$

其中，w为高维空间中的权重向量，λ为控制模型复杂度的正则化参数。

直接在高维甚至无限维空间中求解w是极其困难的。根据表示定理（Representer Theorem），最优的权重向量w可以表示为训练样本在特征空间中映射的线性组合：

$$w=\sum_{i=1}^{n}\alpha_i\phi(x_i) \tag{2.17}$$

其中，α_i为对偶变量（Dual variables）。将公式(2.17)代入目标函数(2.16)中，并引入核函数$K(x_i,x_j)=\phi(x_i)^T\phi(x_j)$，可将原问题的求解转化为求解对偶变量α。令目标函数对α的导数为零，可得到闭式解：

$$\alpha=(K+\lambda I)^{-1}y \tag{2.18}$$

其中，K为$n\times n$的核矩阵（Kernel matrix），其元素$K_{ij}=K(x_i,x_j)$；I为$n\times n$的单位矩阵；y为目标变量向量。

求解出α后，对于任意新的输入样本x，核岭回归模型的最终预测公式为：

$$f(x) = \sum_{i=1}^{n} \alpha_i K(x_i, x) \tag{2.19}$$

通过核函数的转换，KRR 避免了在高维空间中的显式内积计算，从而有效解决了维数灾难问题。

2.5.3 KNN

K 近邻（K-Nearest Neighbors, KNN）算法是一种经典的、基于实例的非参数监督学习算法，其理论基础最早由 Cover 和 Hart 在 1967 年系统性提出（Cover and Hart 1967）。与基于优化的参数化机器学习模型不同，KNN 属于典型的惰性学习（Lazy Learning）算法。该模型在训练阶段不显式地拟合内部参数或构建预测函数，而是直接保存所有训练样本。在预测阶段，算法通过计算待预测样本与所有已知训练样本在特征空间中的距离，寻找距离最近的K个邻居，并利用这K个邻居的已知信息来推断新样本的输出结果。凭借其无需假设数据基础分布的特性，KNN 在处理复杂的非线性模式时具有天然的灵活性。

在特征空间中，样本间相似度的度量通常依赖于距离函数。对于包含p维特征的输入空间，给定待预测样本x与训练集中的样本x_i，最常用的度量方式是欧氏距离（Euclidean distance），其计算公式为：

$$d(x, x_i) = \sqrt{\sum_{l=1}^{p} \left(x^{(l)} - x_i^{(l)} \right)^2} \tag{2.20}$$

其中，$x^{(l)}$和$x_i^{(l)}$分别表示待测样本x和训练样本x_i在第l个特征维度上的取值。

根据待解决问题的性质（回归或分类），KNN 采取不同的决策规则。假设$N_K(x)$表示在训练集中距离待预测样本x最近的K个邻居样本的集合。

在回归预测问题中，KNN 通常采用平均法（Average rule），即将K个最近邻居的目标变量观测值y_i的算术平均数作为最终的预测结果：

$$\hat{y} = \frac{1}{K} \sum_{x_i \in N_K(x)} y_i \tag{2.21}$$

在分类预测问题中，KNN 则采用多数表决机制（Majority Voting），即统计K个邻居中各个类别的出现频次，将频次最高的类别c赋给待预测样本：

$$\hat{y} = \arg\max_{c} \sum_{x_i \in N_K(x)} I(y_i = c) \tag{2.22}$$

其中，$I(\cdot)$为指示函数，当括号内条件成立时取值为 1，否则为 0。模型中超参数K的选择对预测性能至关重要：较小的K值容易受到局部噪声的干扰导致过拟合，而较大的K值则可能引入其他模式的样本，增加模型的预测偏差。

2.6 机器学习模型的调用

本研究中使用 10 种机器学习模型，所有机器学习模型的构建与评估均在 Python 3.8.20 编程环境下进行。为确保实验结果的稳定性和可重复性，本研究统一明确了所采用的算法依赖库及其版本信息，具体包括：scikit-learn（v1.1.1）、xgboost（v2.1.1）、lightgbm（v3.3.2）以及 catboost（v1.2.5）。机器学习模型对应的具体依赖库与核心调用类（表 2）。

表 2 候选机器学习模型的依赖库及调用类

Table 2 Dependencies and calling classes of candidate machine learning models

模型名称	依赖库	调用类
SVR	scikit-learn	LinearSVR
KRR	scikit-learn	KernelRidge
KNN	scikit-learn	KNeighborsRegressor
RF	scikit-learn	RandomForestRegressor
Ada	scikit-learn	AdaBoostRegressor
GBDT	scikit-learn	GradientBoostingRegressor
HGB	scikit-learn	HistGradientBoostingRegressor
XGB	xgboost	XGBRegressor
LGBM	lightgbm	LGBMRegressor
CatB	catboost	CatBoostRegressor

2.7 基于熵权 TOPSIS 方法

为克服单一评价指标带来的主观偏倚，本研究采用基于熵权的 TOPSIS 方法，对各机器学习候选算法的预测性能进行多维度综合评价与客观优选。该模型基于各评价指标数据的内部变异程度（即信息熵）进行客观赋权，其具体计算步骤如下：

假设共有m个评价样本（或实验方案），n个评价指标，原始数据矩阵记为$X = (x_{ij})_{m\times n}$。基于熵权的 TOPSIS 模型的具体计算步骤如下：

（1）数据标准化处理

为了消除不同评价指标在量纲和数量级上的差异，首先对原始矩阵进行极差标准化。

对于极大型（效益型，越大越好）指标：

$$y_{ij} = \frac{x_{ij} - \min(x_j)}{\max(x_j) - \min(x_j)} \tag{2.23}$$

对于极小型（成本型，越小越好）指标：

$$y_{ij} = \frac{\max(x_j) - x_{ij}}{\max(x_j) - \min(x_j)} \tag{2.24}$$

其中，x_j表示第j个指标所在列的所有样本观测值。

（2）计算信息熵与客观权重

首先，计算第i个样本在第j个指标下的比重p_{ij}：

$$p_{ij} = \frac{y_{ij}}{\sum_{i=1}^{m} y_{ij}} \tag{2.25}$$

接着，计算第j个指标的信息熵E_j：

$$E_j = -\frac{1}{\ln m}\sum_{i=1}^{m} p_{ij} \ln p_{ij} \tag{2.26}$$

根据信息熵，计算第j个指标的客观熵权W_j：

$$W_j = \frac{1 - E_j}{\sum_{j=1}^{n}(1 - E_j)} \tag{2.27}$$

（3）构建加权规范化矩阵并确定理想解

利用计算得出的客观权重W_j，构建加权规范化决策矩阵$Z = (z_{ij})_{m\times n}$，其中$z_{ij} = W_j \times y_{ij}$。

在此基础上，确定各指标的正理想解Z^+和负理想解Z^-：

$$Z^+ = (\max(z_1), \max(z_2), \ldots, \max(z_n)) \tag{2.28}$$

$$Z^- = (\min(z_1), \min(z_2), \ldots, \min(z_n)) \tag{2.29}$$

（4）计算欧氏距离与相对贴近度

计算每个样本到正理想解的距离D_i^+和到负理想解的距离D_i^-：

$$D_i^+ = \sqrt{\sum_{j=1}^{n}\left(z_{ij} - Z_j^+\right)^2} \tag{2.30}$$

$$D_i^- = \sqrt{\sum_{j=1}^{n}\left(z_{ij} - Z_j^-\right)^2} \tag{2.31}$$

最后，计算各样本的相对贴近度（即综合评价得分）C_i：

$$C_i = \frac{D_i^-}{D_i^+ + D_i^-} \tag{2.32}$$

C_i的取值范围在 0 到 1 之间，数值越大，表明该样本的综合表现越接近最优水平。

2.8 Stacking 集成学习方法

Stacking 算法于 1992 年由 Wolpert 提出（Wolpert 1992），其核心思想是通过构建多层模型结构，将上一层不同模型的预测结果作为元特征（Meta-features）输入到下一层进行再训练。这种多模型融合的机制能够有效克服手工分配权重的局限，通过深层次的特征提取与知识迁移，显著提升预测的泛化能力和精度。图 1 展示了本文基于该算法构建的多层（m 层）通用架构示意图；考虑到实际预测任务的复杂性与计算效率，本文在具体实验中将其设定为两层（m=2）结构。

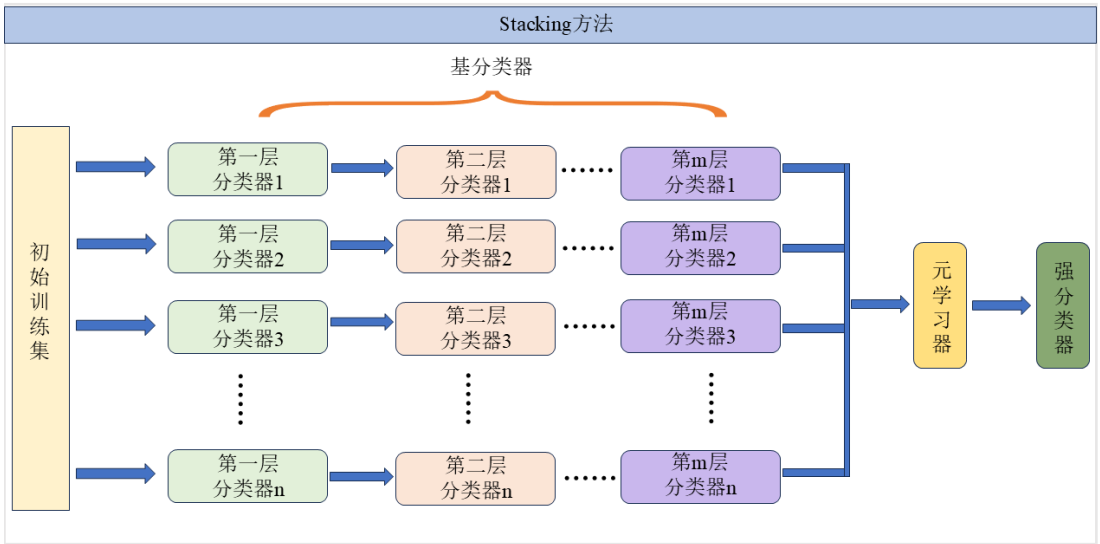

图 1 Stacking 模型结构图

Fig. 1 Stacking model structure diagram

如图 1 所示，本文的 Stacking 算法包含m层结构，每层设有n个基分类器（Base Classifier）。具体的训练与特征传递流程如下：

第一层训练与交叉验证：将初始数据集划分为训练集和测试集。在第一层中，运用k折交叉验证方法（k-foldcross-validation）训练n个基分类器。即每个基分类器在$k-1$个子集上拟合，在剩余的 1 个子集及独立的测试集上进行预测。

元特征构建与传递：将第一层n个基分类器在训练集上的预测结果拼接，生成包含n维元特征的新训练集；同理，将它们对测试集的预测结果求平均，生成新的测试集。这组新生数据将作为下一层的输入特征。

多层纵向迭代：上述训练-预测-特征传递的过程在后续的基分类器中不断迭代，直至第m层（在本研究的具体模型中，m取值为 2）。通过纵向堆叠，实现对数据深层次特征的持续提取。

元学习器拟合：第m层输出的最终特征将输入到末端的元学习器（Meta-Learner）中进行拟合。为防止模型随层数加深而过拟合，元学习器通常选用逻辑回归等复杂度较低的线性模型，并由其输出最终的强分类器（Strong Classifier）。

方法优势：该 Stacking 架构不仅通过每层多个异质或同质基分类器的横向组合增强了模型的泛化能力，还通过m层的纵向堆叠实现了深层特征的知识迁移。配合k-折交叉验证，该算法在提高模型预测稳定性和精度的同时，能有效防范过拟合现象的发生。

2.9 计算平台与硬件环境

戴尔 R740XD 服务器，具体配置为：处理器 6230R*2；内存 64GB*8；固态硬盘 960GB SSD*1；机械硬盘 16TB SAS*11；H750 阵列卡；冗余电源 1100W*2。

2.10 模型构建与效果评价

2.10.1 模型构建

本研究设计了一套多阶段渐进式基因组选择预测框架—GPSE（Genomic Prediction and Selection Ensemble）（图 2），通过系统性的模型性能探索与智能集成策略，充分挖掘 SNP 标记对复杂性状的预测潜力。该框架同时支持连续型性状的回归预测与离散型性状的分类预测两种任务模式，整体流程划分为数据预处理与特征工程、多模型并行训练、多准则模型评价以及集成融合四个递进阶段。

在数据预处理与特征工程阶段，系统通过格式检测模块自动识别输入基因型数据的格式类型，支持 VCF 和 PLINK 格式的基因型数据输入。首先，系统调用 PLINK

软件进行数据格式标准化与质量控制，依据预设的 SNP 缺失率、样本缺失率及最小等位基因频率（MAF）阈值过滤低质量数据；随后，调用 Beagle 软件对残余缺失值进行基因型插补。为有效降低基因型矩阵维度，用户可提供自定义的 SNP 位点列表，如基于 GWAS-*P* 和 LD 的两种特征选择策略以筛选核心 SNP 标记。最后，系统基于加性效应模型将基因型数据转换为 0、1、2 编码的数值矩阵，并与表型数据精准对齐，输出可供机器学习模型直接读取的规范化数据集。

在多模型并行训练阶段，系统旨在全面评估各类算法在基因组预测中的性能，将候选算法主要划分为线性/基础模型与树类模型两大类。针对回归任务，线性模型包含 SVR、KRR 与 KNN，树类模型涵盖 RF、GBDT、Ada、XGB、LGBM、CatB 和 HGB 等 7 种集成算法；针对分类任务，线性模型配置了 SVM 与 MLP，树类模型配置了 RF、XGB、LGBM 和 CatB，并支持根据二分类或多分类场景自适应调整目标函数。所有模型均采用重复 K 折交叉验证进行统一评估，其中回归任务记录皮尔逊相关系数（Pearson）、决定系数（R^2）、均方根误差（RMSE）和平均绝对误差（MAE），分类任务评估准确率（Accuracy）、F1 分数（F1-score）和 ROC 曲线下面积（AUC）等指标。此外，系统调用 Optuna 框架执行贝叶斯超参数优化，结合 TPE 采样与中位数剪枝（Median Pruner）策略，高效确定各模型的最优参数配置。

为全面评估模型性能，本研究在多准则评价阶段引入基于熵权的 TOPSIS 方法对候选模型进行综合排序。该方法在对成本型指标进行正向化处理后，通过计算各模型与正负理想解的欧氏距离得出综合评分，并据此筛选排名前N的最优模型。在随后的模型集成阶段，系统采用 Stacking 策略构建双层学习架构。底层基学习器即由前述筛选出的排名前N的模型组成，利用 K 折交叉验证的折外预测机制生成元特征矩阵以避免数据泄露。顶层元学习器针对回归与分类任务分别采用 Ridge 回归和 Logistic 回归，通过学习底层预测结果的最优线性组合权重，实现各基模型间的优势互补，进而提升整体的预测精度与泛化能力。

在本研究的具体实施中，GPSE 模型的构建策略如下：所有候选模型在基础评估阶段均采用默认参数配置（附表 1）以保证对比的基准公平。研究应用基于熵权的 TOPSIS 方法，将模型的预测准确性与基于标准差的稳定性作为评价准则进行综合打分，严格筛选出综合排名前三的最优模型作为基学习器。采用 Stacking 策略对这三个基学习器进行集成融合，完成 GPSE 最终预测模型的构建。

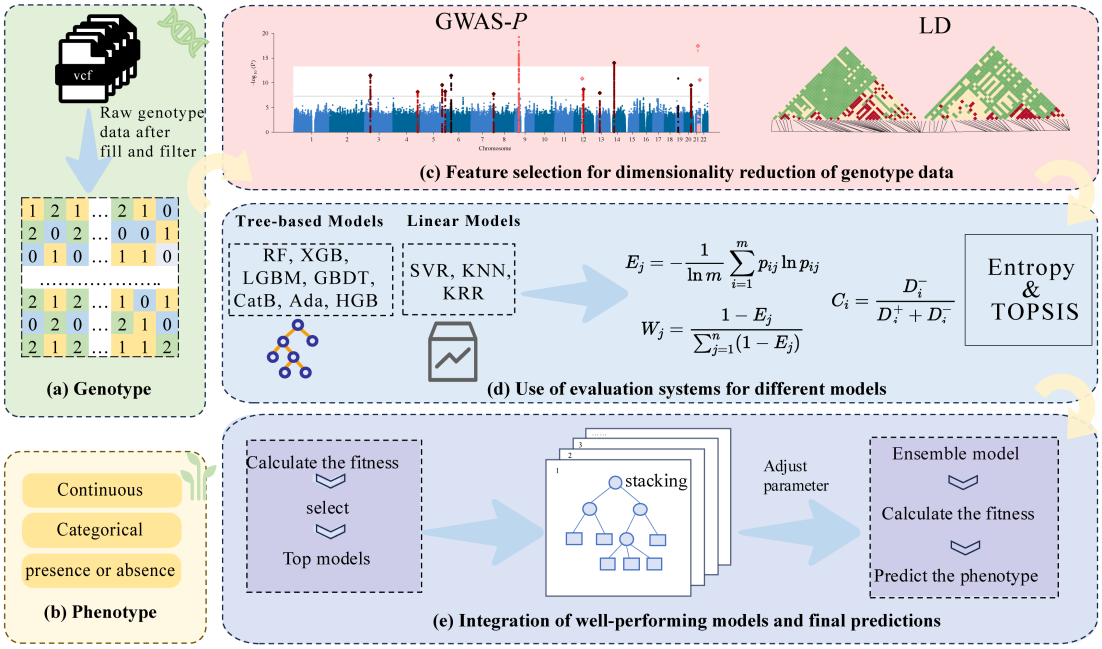

图 2 GPSE 技术路线图

Fig. 2 The technical roadmap of GPSE

2.10.2 交叉验证

所有的算法均采用重复五折交叉验证法（Repeated 5-fold cross-validation）来评估模型的预测性能与稳定性。对于每一套数据集，所有的个体被随机划分为 5 个组，每个组轮流作为测试集，剩余四组作为训练集。利用训练集中具有表型的个体，来预测测试集中仅输入基因型信息的个体的表型值。在算法程序中设定了相同的随机种子（Random seed），以保证所有模型在运行时所划分的训练集与测试集完全一致，从而进行公平对比。

2.10.3 预测效果评价指标

本研究以真实表型值与预测表型值之间的皮尔逊相关系数（Pearson correlation coefficient, r）作为核心指标，来衡量模型的预测准确性。为全面客观地评估模型性能，整个五折交叉验证的划分与预测步骤独立重复 50 次，最终取这 50 次迭代验证结果的平均值作为该算法的最终预测准确性。皮尔逊相关系数的计算公式如下所示：

$$r = \frac{cov(y, \hat{y})}{\sigma_y \sigma_{\hat{y}}} \tag{2.33}$$

式中，y为目标性状的真实表型值；$\hat{y}$为目标性状的预测表型值；$cov(y, \hat{y})$为真实值与预测值之间的协方差；σ_y与$\sigma_{\hat{y}}$分别为真实值与预测值的标准差。

为全面评估模型在不同数据划分下的鲁棒性，本研究引入标准差（Standard Deviation, SD）作为衡量预测稳定性的核心指标。通过计算上述 50 次独立重复交叉验证中皮尔逊相关系数的标准差，可以直观反映模型预测能力的波动情况。标准差越小，表明模型受样本划分差异的影响越小，泛化能力与预测性能越稳定。其计算公式如下所示：

$$SD = \sqrt{\frac{1}{N-1}\sum_{i=1}^{N}(r_i - \bar{r})^2} \tag{2.34}$$

式中，N为独立重复交叉验证的总次数（本研究中$N = 50$）；r_i为第i次迭代评估计算得到的皮尔逊相关系数；$\bar{r}$为N次迭代中皮尔逊相关系数的平均值，即最终预测准确性。

3 结果与分析

3.1 基于熵权 TOPSIS 的候选预测模型综合评价与筛选

3.1.1 多物种多性状的机器学习算法预测性能比较

本研究系统评估了 10 种机器学习算法（SVR、LGBM、HGB、KRR、KNN、XGB、GBDT、Ada、RF 和 CatB）在 6 个物种的 3 类性状上的预测性能。所选物种包括玉米（Maize, *Zea mays* L.）、水稻（Rice, *Oryza sativa* L.）、高粱（Sorghum, *Sorghum bicolor*）、大豆（Soybean, *Glycine max*）、云杉（Spruce, *Picea abies*）和柳枝稷（Switchgrass, *Panicum virgatum*），评估性状涵盖株高（Height）、发育期（Developmental Timing）、产量（Yield）；部分物种缺乏上述 1-2 类核心性状数据，因此补充对应物种的其他重要农艺性状（Other）作为补充评估对象。以预测准确性（*r*）作为评估指标，同时采用最佳性能占比（% best）评估算法的泛化能力。结果如图 3 所示。

株高性状的预测性能存在显著的物种与算法差异。物种层面，株高在高粱和柳枝稷中的预测精度最高，最优模型准确性（*r*）值均为 0.59，而在云杉中最优模型准确性仅为 0.36。算法层面，不同算法对株高的预测精度差异明显，其中 RF 最佳性能占比（% best）为 95%，表现出较好的稳定性，KRR 为 94%，CatB 为 91%，而 KNN 仅为 79%。

发育期性状的预测准确性在物种间的分化更为显著。其中柳枝稷的发育期性状在 SVR 算法下取得了所有表型中的最高预测准确性，达 0.88；玉米发育期性状的预测准确性次之，最优值为 0.71；相比之下，水稻和大豆的发育期性状预测上限较低，最高预测准确性仅分别为 0.52 和 0.45。算法层面，CatB 以 96%的最佳性能占比居于首位，LGBM 及其他树类算法也均保持了优异的预测效果。

产量性状的预测准确性受物种遗传背景影响显著。大豆数据集的表现在多种机器学习模型间最为稳定，多数模型（XGB、GBDT、KRR）的预测准确性均能达到 0.66，算法间性能差异较小。相比之下，水稻的产量预测表现最差，最高预测准确性仅为 0.27；其中 KNN 算法在水稻中的预测准确性低至 0.11，为本次测试的最低预测值。在该类别中，CatB 和 KRR 模型分别以 96%和 93%的最佳性能占比，均表现出较好的稳定性。

在其他性状类别中，包括高粱的籽粒含水量(GM)、云杉的胸径(DBH)和木材密度（DE）及柳枝稷的抗倒伏性（ST），算法的适配能力发生变化。KRR 适应性极强，最佳性能占比为 99%，在高粱和云杉的多个性状组合中均取得领先；而 SVR 则在柳枝稷抗倒伏性状中表现最佳，预测准确性达 0.68。此外，RF 以 94%最佳性能占比仍保持了较高的综合性能，而 Ada 算法表现最差最佳性能占比仅为 80%。

单一算法难以普遍适用于所有性状类别。KRR 算法在株高、产量与其他性状分类中的最佳性能占比高达 94%、93%和 99%，而在发育期性状预测中仅为 89%，反映出其对特定表型特征的捕捉能力存在局限。同一算法在不同物种间的预测准确性差异显著，SVR 算法在玉米株高表型的预测准确性达 0.49，而在云杉中仅为 0.24，突显了单一算法在跨物种预测场景中，泛化能力存在明显短板。此外，部分算法在整体预测性能上存在固有缺陷，例如 KNN 算法在多类性状预测中均未能展现出竞争优势，其最佳性能占比在各类别中仅维持在 69%-86%的区间，处于所有测试算法的最低水平，反映出该模型在处理本研究的农艺性状时适配性较差。物种层面，柳枝稷和高粱的整体预测效果显著优于云杉和水稻，这种差异可能源于群体遗传结构、标记密度，以及性状遗传力与上位性效应的复杂程度。

综上所述，机器学习算法在跨物种和多性状基因组预测中存在特定的局限性与适用边界。算法优势高度依赖具体物种和特定性状组合，这契合机器学习领域的没有免费的午餐定理（No Free Lunch Theorem）即没有任何算法能够跨越场景超越所有其他模型（Wolpert and Macready 2002）。

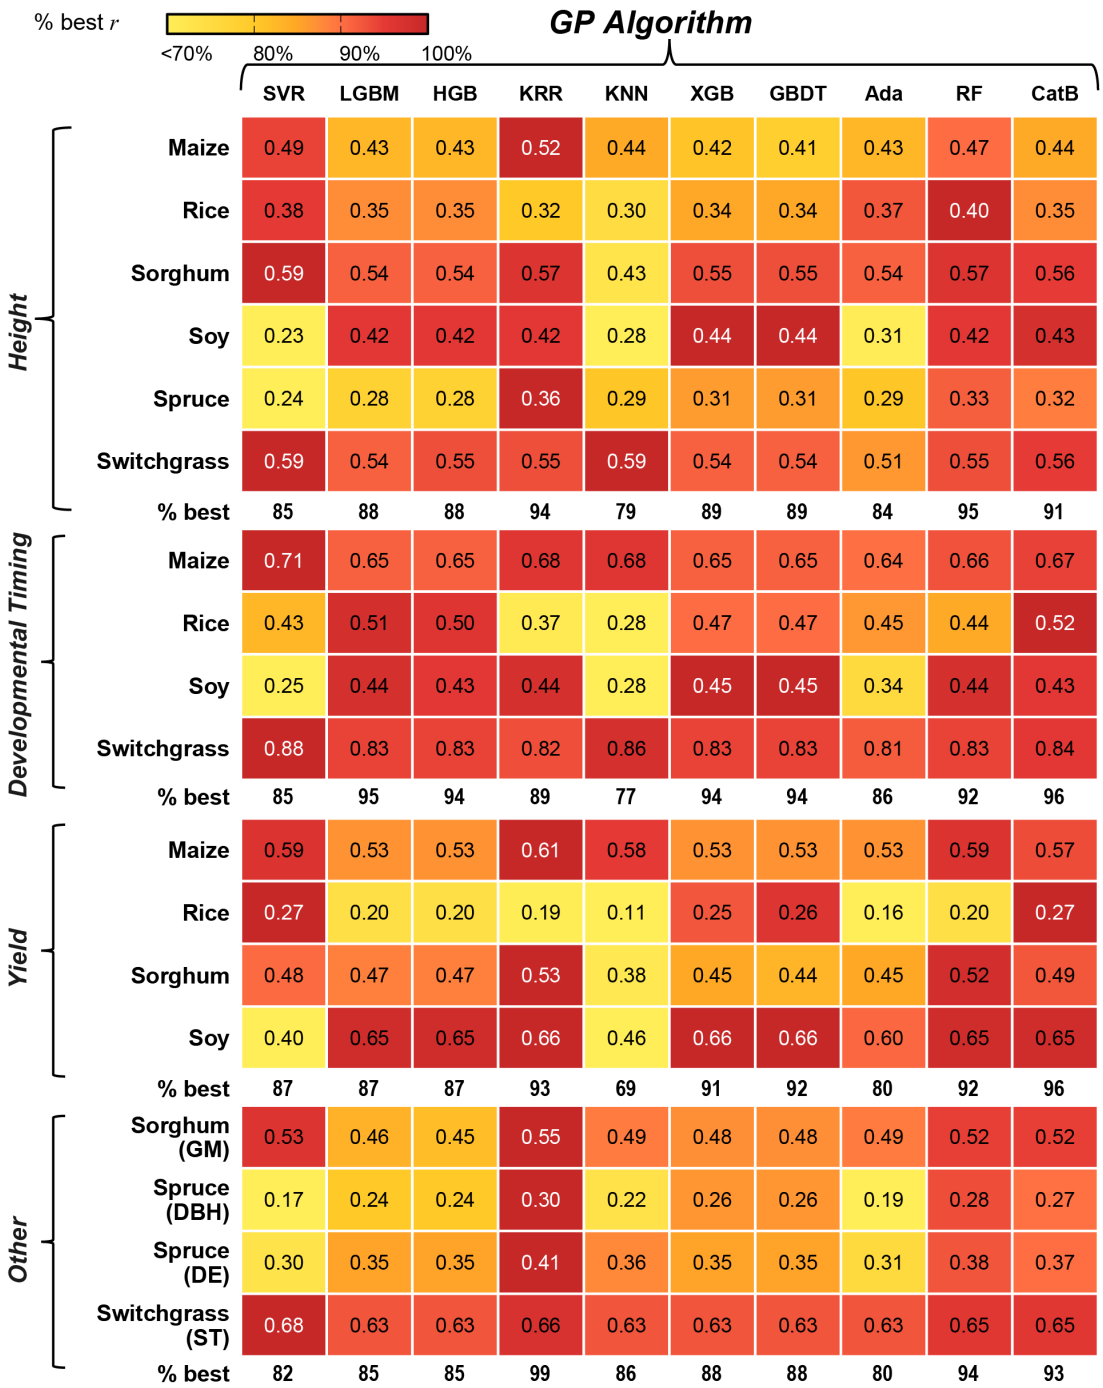

图 3 10 种机器学习算法在不同物种及性状上的性能比较

热图数值为预测准确度（皮尔逊相关系数 r）。方块颜色代表相较于当前物种性状组合最高预测性能的百分比（深红色=100%，偏黄<70%）。白色数值显示了在每个特定物种性状组合中表现最佳的算法的值。热图底部的% best 行则为各算法在该类性状中占最佳性能百分比（即该算法在对应物种性状组合中预测精度排名前 1 的占比）。

Fig. 3 Performance comparison of 10 machine learning algorithms across species and traits

Heatmap values show prediction accuracy (Pearson correlation coefficient r), block colors indicate the percentage relative to the maximum prediction performance for each species-trait combination (dark red = 100%, yellowish < 70%), white numbers mark the optimal algorithm's prediction accuracy per species-trait combination, and the bottom % best row presents the proportion of top-ranked performance for each algorithm in the corresponding trait category, i.e., how often the algorithm ranks first in prediction accuracy across relevant species-trait combinations.

3.1.2 TOPSIS 客观优选与经验选择的一致性验证

针对多物种、多性状、多算法构建的高维评估矩阵，仅凭单一的预测准确性（r）难以全面衡量算法在复杂场景下的性能。为此，本研究引入基于熵权 TOPSIS 的方法，综合考量预测准确性（r）与体现预测稳定性的标准差（SD）两个核心维度，对 10 种算法在 18 个物种、性状组合中的表现进行客观评价与排序。深度挖掘综合评价结果后发现三种典型的算法表现模式（图 4）。

准确性与稳定性双优模式（Accuracy & Stability Best），展现了特定算法在两个评估维度上的绝对优势。在高粱的籽粒含水量（GM）和产量（YLD）性状预测中，KRR 算法的预测准确性（r）分别为 0.5523 和 0.5346，标准差（SD）分别为 0.0014 和 0.0027，均位居所有算法之首。其对应的 TOPSIS 综合得分达到满分 1.000，显著优于其他候选模型。这表明对于遗传结构相对简单或效应分布较为均匀的性状，该算法能维持较高的预测精度与稳定性。

准确性主导模式（Accuracy Dominant），指当某一算法在预测精度上具有压倒性优势时，准确性维度将主导 TOPSIS 的最终排名。在玉米和柳枝稷的开花期（FT）性状中，SVR 算法凭借显著优于其他模型的准确性表现，稳居 TOPSIS 综合排名第一（图 4 E）。值得注意的是，在玉米的开花期性状评估里，排名前五的算法间 TOPSIS 得分极差仅为 0.0200，反映出在特定物种的复杂性状中，多种经典机器学习算法的综合预测效能可能趋于收敛。

稳定性导致排名逆转模式（TOPSIS Reversal），体现了当算法间预测精度相近时，模型的稳定性成为决定优劣的关键因素。在大豆的株高（HT）性状中，尽管 XGB 算法的准确性最高达到 0.4443，但其标准差（SD）为 0.0026，波动较大。相比之下，KRR 算法虽然预测精度略低为 0.4214，却凭借标准差（SD）仅为 0.0004 的极高模型稳定性在综合评价中实现逆袭并位列榜首（图 4 C），类似现象亦出现在大豆产量 YLD 性状中（图 4 F）。

上述三种算法表现模式表明，TOPSIS 的客观量化排序结果与常规经验选择保持了高度的一致性。前两种模式的 TOPSIS 排序与直观经验判断完全吻合，而在预测精度与稳定性出现矛盾的第三种模式中，TOPSIS 通过客观的数学计算，在保证较高预测精度的前提下做出了更侧重于模型稳定性的选择，这同样符合了实际育种的决策逻辑。有效克服了传统评价指标往往忽略模型在不同子抽样群体中稳定性的缺陷。

TOPSIS 多准则分析方法通过深度整合预测准确性与稳定性两个维度，能更全面地反映模型在实际育种应用中的潜在表现。分析结果再次印证不存在单一算法能够胜任所有预测任务，不同算法间存在明显的性能异质性与互补空间。因此，本研究提出了一种基于多准则评价驱动的集成学习框架 GPSE（图 2）。该框架针对每一个物种与性状的组合进行独立优化。依据 TOPSIS 综合排名，系统会筛选出表现最优的前三种算法作为基学习器，进而采用堆叠（Stacking）集成策略构建元学习模型。此机制利用多模型间的加权协同效应，全面捕获不同算法所提取的遗传特征信息。其核心目的在于打破单一机器学习模型的局限性，最终提升基因组预测的精度与跨环境泛化能力。

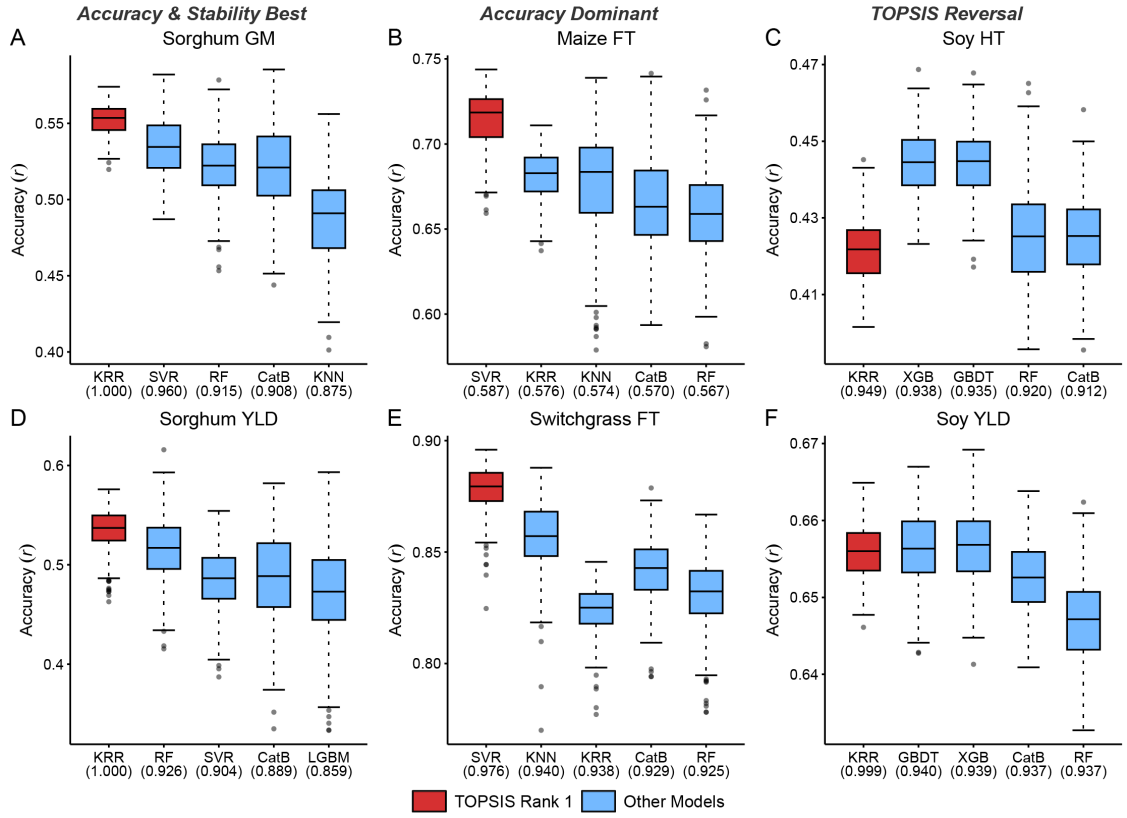

图 4 基于 TOPSIS 综合评价准确性与稳定性的三种典型模型模式

箱线图展示 50 次重复 5 折交叉验证的预测精度（皮尔逊相关系数 r）分布。横坐标列出排名前五的算法及其基于精度均值与稳定性（标准差）计算的 TOPSIS 得分（括号内数值）。红、蓝箱体分别代表 TOPSIS 排名第一的模型与其他模型。(A, D) 准确性与稳定性协同最优模式；(B, E) 准确性主导模式；(C, F) TOPSIS 逆转模式。

Fig. 4 Three typical model evaluation patterns based on the comprehensive TOPSIS evaluation of accuracy and stability

Boxplots show predictive accuracy (Pearson's *r*) distributions from 50 repeated 5-fold cross-validations. The x-axis lists the top five algorithms and their TOPSIS scores (in parentheses), calculated from mean accuracy and stability (standard deviation). Red and blue boxes denote the Rank 1 TOPSIS model and other models,respectively. (A, D) Accuracy & stability best pattern (B, E) Accuracy dominant pattern (C, F) TOPSIS reversal pattern.

3.2 GPSE 在园艺作物低维基因组数据中的预测效果验证

为了验证GPSE在园艺作物低维基因组数据集上的表现，本研究选取了黄瓜（*Cu. sativus*）、甜瓜（*Cu. melo*）及西瓜（*Ci. lanatus*）三个典型园艺作物，共涵盖 11 项关键的农艺与抗病性状。本研究将 GPSE 框架与 SVR、RF、CatB 等 10 种经典机器学习算法进行了系统对比，旨在解析集成策略在低标记密度场景下的预测增益及其跨物种适应性。本小节将重点围绕预测准确性与模型泛化能力展开评估，并同步引入传统统计模型进行横向比较，从而全面验证 GPSE 在低维数据环境下的实际效能。

3.2.1 GPSE 与机器学习模型的预测精度比较

在黄瓜、甜瓜及西瓜三个典型园艺物种共 11 个关键农艺及抗病性状的预测中，GPSE 均取得了最高或并列最高的预测准确性，但其提升幅度因性状遗传结构的不同而存在显著差异。

对黄瓜的 4 个核心性状霜霉病抗性（Downy mildew）、开花期（Days to flower）、蔓枯病抗性（Gummy stem blight）以及炭疽病抗性（Anthracnose）进行预测（图 5）。不同性状模型预测准确性存在显著差异，整体算法对霜霉病抗性的预测能力最强，而炭疽病抗性的预测准确度普遍偏低。在参与评估的十一种机器学习算法中，GPSE 模型在所有测试表型中均展现出最优的预测性能，其准确性全面超越了其他单一算法与集成学习算法。具体而言，GPSE 模型在预测难度最大的炭疽病抗性中准确度达到 0.427，相较于该表型下表现优异的 RF 模型进一步提升了约 6.67%。在开花期和蔓枯病抗性的预测中，GPSE 模型的准确性分别为 0.593 和 0.577，较表现次优的 SVR 模型分别实现了 3.35%和 2.90%的性能增长。此外在预测基准较高的霜霉病抗性中，GPSE 模型也以 0.674 的最高准确度排名第一。从算法整体表现的规律来看，集成学习模型如 RF、CatB 以及 GBDT 等展现出较为稳健的预测能力，在多数性状中均优于 KNN 与 KRR 等基础方法。需要关注的是，部分模型对特定表型具有适应性，SVR 在开花天数和蔓枯病抗性中展现了出色的拟合效果，而 RF 则在霜霉病抗性和炭疽病抗性中具备较强优势。综合以上结果，GPSE 模型在不同性状中均实现了稳定且显著的准确性跃升，展现出卓越的预测性能。

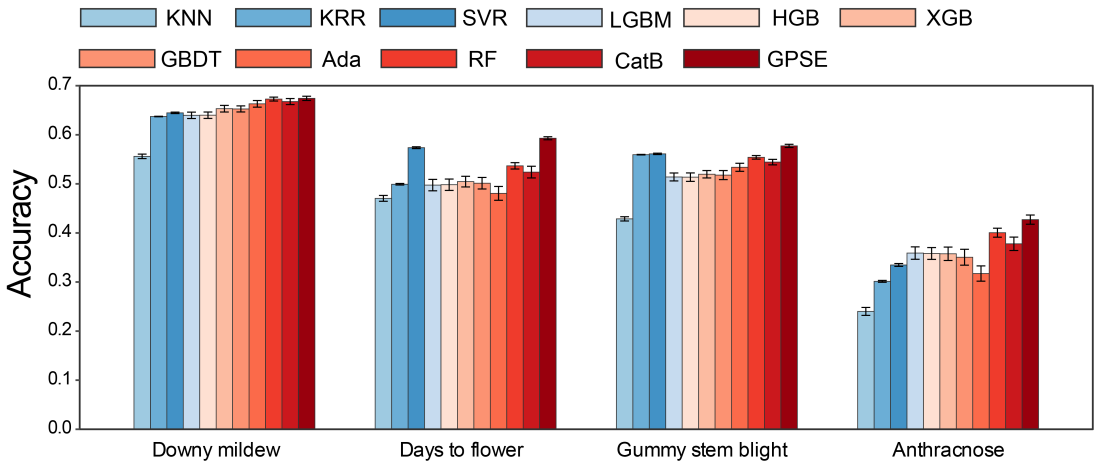

图 5 不同机器学习模型对黄瓜四个性状的预测准确性对比

图中柱状图展示了 GPSE 框架与其他十种机器学习算法在霜霉病抗性、开花期、蔓枯病抗性以及炭疽病抗性四个性状上的表现。柱状图的颜色代表不同的机器学习模型，柱形高度对应模型在各表型上的预测准确度。顶部误差线指示了交叉验证过程中的标准差。

Fig. 5 Comparison of prediction accuracies among different machine learning models for four traits in cucumber

The bar chart illustrates the performance of the GPSE framework and ten other machine learning algorithms across four traits: downy mildew, days to flower, gummy stem blight, and anthracnose. Different colors represent distinct machine learning models, and the bar height corresponds to the prediction accuracy of the model for each trait. The error bars at the top indicate the standard deviation during the cross-validation process.

为进一步研究 GPSE 模型在黄瓜 3 个高预测精度性状霜霉病抗性、开花期与蔓枯病抗性中的预测值与真实值的预测规律，通过对回归拟合及分布规律的分析，发现 GPSE 模型存在以下规则：

整体而言，GPSE 模型在霜霉病抗性、开花期以及蔓枯病抗性三个性状的验证集与测试集中均保持了高度一致的预测趋势，数据点沿回归线呈现出显著的正相关分布，证明该模型未发生明显的过拟合现象（图 6）。其中模型对霜霉病抗性的测试集预测相关系数（r）达到 0.67 表现最为突出（图 6 A），而开花期与蔓枯病抗性也分别保持在 0.59 和 0.58 的较高水平（图 6 B, C）。进一步剖析线性拟合特征发现，三个性状的回归斜率高度集中在 0.36 至 0.37 之间。该斜率相较于理想等值线存在一定偏移，客观反映了模型在处理极端观测值时具备内在的保守性，倾向于使预测结果向群体均值靠拢。尽管极端值预测存在一定程度的收缩，但紧凑的置信区间以及验证集与测试集相关系数的稳定同向性，充分印证了 GPSE 模型在跨表型预测任务中具备可靠的泛化表现。

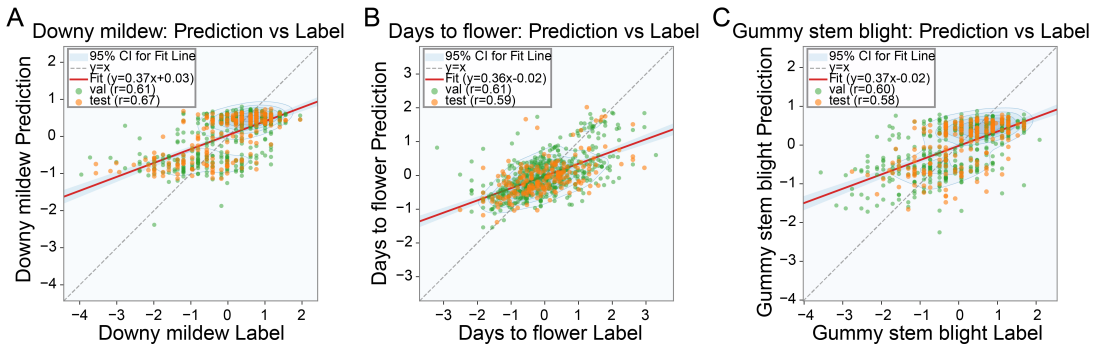

图 6 GPSE 模型对黄瓜三个性状预测值与真实值的散点图

图中展示了模型在验证集（val，绿色点）和测试集（test，橙色点）上的预测表现，并利用皮尔逊相关系数（r）评估预测准确度。A、B、C 分别代表霜霉病抗性、开花期和蔓枯病抗性。红色实线为实际数据的线性拟合线（Fit），浅蓝色阴影区域表示 95%置信区间（95% CI），灰色虚线代表理想预测的等值线（y=x）。

Fig. 6 Scatter plots of predicted versus observed values for three traits in cucumber using the GPSE model

The plots display the prediction performance on the validation (val, green dots) and test (test, orange dots) sets, with the Pearson correlation coefficient (r) used to evaluate prediction accuracy. A, B, and C represent downy mildew, days to flower, and gummy stem blight, respectively. The solid red line indicates the linear fit (Fit) for the actual data, the light blue shaded area represents the 95% confidence interval (95% CI), and the dashed gray line indicates the ideal 1:1 prediction line (y=x).

对甜瓜的 4 个核心性状百粒重（100-seed weight）、果宽（Fruit width）、果重（Fruit weight）以及可溶性固形物含量（Soluble solids content）进行预测（图 7）。在所评估的性状中，百粒重呈现出极高的可预测性，而可溶性固形物含量的整体预测效果普遍较低。在所有机器学习算法中，GPSE 模型展现出跨表型的绝对优势，表现全面领先于其余模型。具体而言，在预测难度居中的果宽与果重性状中，GPSE 模型的准确度分别达到 0.800 和 0.716，较次优的 SVR 模型分别实现了 2.40%和 2.29%的性能提升。面对预测基准极高的百粒重、预测难度较大的可溶性固形物含量，GPSE 模型依然分别以 0.902 和 0.446 的准确度稳居第一。从基准算法的表现规律观察，SVR 展现出极强的拟合能力，在四项评估中均位列次优，整体表现显著优于多数树基集成算法。与之相对，LGBM、HGB、XGB 以及 GBDT 等集成模型的预测表现高度趋同且居于中等水平，而 KNN 与 KRR 等基础模型在处理可溶性固形物含量等复杂特征时泛化能力明显受限。综合上述数据，GPSE 模型不仅能够有效解析各类表型特征，更在不同难度的预测任务中保持了卓越的精确度与跨性状适应性。

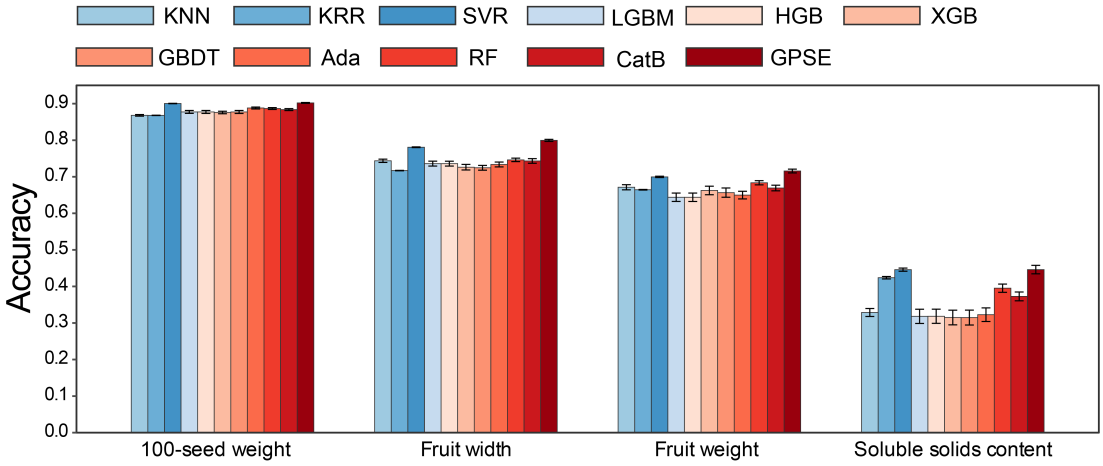

图 7 不同机器学习模型对甜瓜四个性状的预测准确性对比

图中柱状图展示了 GPSE 框架与其他十种机器学习算法在百粒重、果宽、果重以及可溶性固形物含量四个性状上的表现。柱状图的颜色代表不同的机器学习模型，柱形高度对应模型在各表型上的预测准确度。顶部误差线指示了交叉验证过程中的标准差。

Fig. 7 Comparison of prediction accuracies among different machine learning models for four traits in melon

The bar chart illustrates the performance of the GPSE framework and ten other machine learning algorithms across four traits: 100-seed weight, fruit width, fruit weight, and soluble solids content. Different colors represent distinct machine learning models, and the bar height corresponds to the prediction accuracy of the model for each trait. The error bars at the top indicate the standard deviation during the cross-validation process.

为直观展现 GPSE 模型在甜瓜核心性状上的拟合效果，本研究绘制了百粒重、果宽以及果重 3 个表型的预测值与真实观测值散点分布图（图 8）。从总体趋势观察，验证集与测试集的数据点均紧密围绕拟合线分布，且三个性状测试集的相关系数均高于验证集，这有力证明了模型在跨样本集评估中具有优异的泛化能力，未出现过拟合现象。在所有评估性状中，百粒重的预测准确性最为卓越，其测试集相关系数（r）高达 0.90（图 8 A），拟合回归斜率达到 0.76，数据分布最为收敛且紧密贴近理想等值线。值得注意的是，模型在不同表型间的预测效能呈现出明显的梯度变化规律。果宽与果重的测试集相关系数虽然分别维持在 0.80 和 0.72 的较高水平（图 8 B, C），但两者的拟合斜率却分别回落至 0.56 与 0.37。这种回归斜率的梯次衰减现象揭示了模型在解析果重等特定性状时，对表型极端观测值产生了更为显著的预测收缩效应。整体而言，高度正相关的散点分布同向性与紧凑的置信区间共同表明，GPSE 模型在甜瓜多表型预测任务中能够稳定提取并拟合关键遗传特征，展现出高度可靠的预测表现。

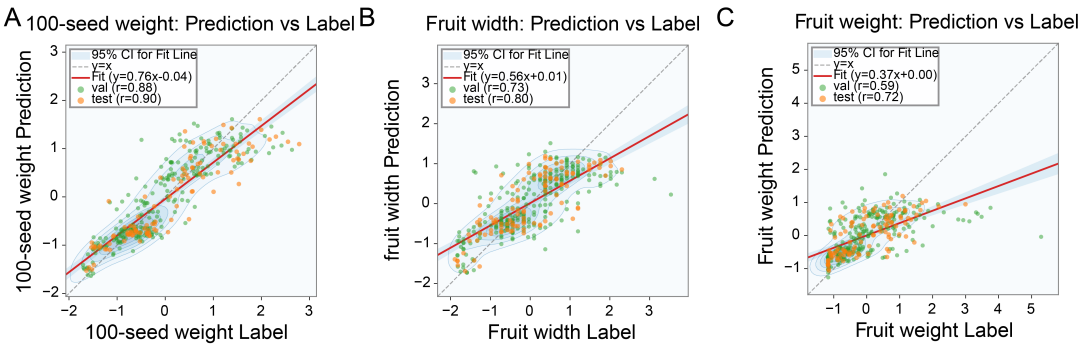

图 8 GPSE 模型对甜瓜三个性状预测值与真实值的散点图

图中展示了模型在验证集（val，绿色点）和测试集（test，橙色点）上的预测表现，并利用皮尔逊相关系数（r）评估预测准确度。A、B、C 分别代表果宽、果重和可溶性固形物含量。红色实线为实际数据的线性拟合线（Fit），浅蓝色阴影区域表示 95%置信区间（95% CI），灰色虚线代表理想预测的等值线（y=x）。

Fig. 8 Scatter plots of predicted versus observed values for three traits in melon using the GPSE model

The plots display the prediction performance on the validation (val, green dots) and test (test, orange dots) sets, with the Pearson correlation coefficient (r) used to evaluate prediction accuracy. A, B, and C represent fruit width, fruit weight, and soluble solids content, respectively. The solid red line indicates the linear fit (Fit) for the actual data, the light blue shaded area represents the 95% confidence interval (95% CI), and the dashed gray line indicates the ideal 1:1 prediction line (y=x).

对西瓜的 3 个核心性状茎部白粉病抗性（PM race stem）、叶片白粉病抗性（PM race leaf）以及果实果斑病抗性（BFB fruit）进行预测（图 9）。不同侵染部位与病害类型的表型在基因组预测难度上呈现出明显的层级分化规律。整体而言，模型针对茎部与叶片白粉病抗性的预测能力相对均衡且处于较高基准，而果实果斑病抗性的预测准确度则面临显著的瓶颈挑战。在参与比较的 11 种算法中，GPSE 模型有着绝对的优势，在三项抗病表型中均取得了全局最优的预测效果。特别是在预测难度极大的果实果斑病抗性中，GPSE 模型的准确性达到 0.342，相较于该表型下表现次优的 CatB 模型实现了 4.74%的性能跃升，凸显了其在解析复杂抗病遗传结构时的核心优势。在茎部白粉病抗性与叶片白粉病抗性的预测任务中，GPSE 模型同样以 0.667 和 0.662 的最高准确度排名第一。观察其他模型的横向表现可以发现，CatB 模型展现出高度稳定的次优拟合效能，在所有参评表型中均紧随 GPSE 之后。多数树基集成算法如 RF、LGBM 以及 GBDT 等在两类白粉病抗性预测中表现出高度趋同的稳健性。相比之下基础算法的泛化能力严重受限于特定性状，比如 KNN 在预测白粉病抗性时表现欠佳，而 SVR 在处理果实果斑病抗性数据时拟合效果触底，准确度仅为 0.216。

综合评价表明，面对西瓜不同抗病表型固有的预测难度差异，GPSE 模型能够最有效地挖掘特征标志物与表型间的复杂映射关系，展现出卓越且稳定的跨性状预测精度。

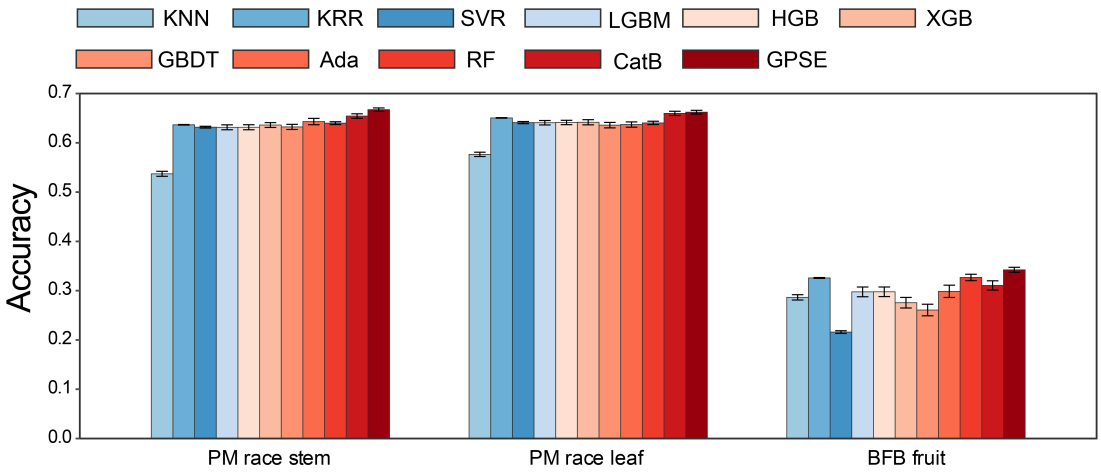

图 9 不同机器学习模型对西瓜三个性状的预测准确性对比

图中柱状图展示了 GPSE 框架与其他十种机器学习算法在茎部白粉病抗性、叶片白粉病抗性以及果实果斑病抗性三个性状上的表现。柱状图的颜色代表不同的机器学习模型，柱形高度对应模型在各表型上的预测准确度。顶部误差线指示了交叉验证过程中的标准差。

Fig. 9 Comparison of prediction accuracies among different machine learning models for three traits in watermelon

The bar chart illustrates the performance of the GPSE framework and ten other machine learning algorithms across three traits: PM race stem, PM race leaf, and BFB fruit. Different colors represent distinct machine learning models, and the bar height corresponds to the prediction accuracy of the model for each trait. The error bars at the top indicate the standard deviation during the cross-validation process.

为直观评估 GPSE 模型在西瓜抗病性状上的预测稳定性，对茎部白粉病抗性、叶片白粉病抗性以及果实果斑病抗性的真实标签与预测值散点分布进行了深入剖析（图 10）。西瓜的抗病预测散点图揭示了模型在不同病害间显著的性能分化规律。在处理茎部与叶片白粉病抗性时（图 10 A, B），模型展现出高度一致且稳健的预测效能，两者的测试集相关系数分别稳定在 0.67 与 0.66 的较高基准，数据分布紧凑同向，回归斜率分别达到 0.36 和 0.43，这表明模型能比较有效捕获这两类性状的关键遗传信息。但是面对预测难度较大的果实果斑病抗性（图 10 C），散点分布呈现出急剧的收缩态势。该性状的测试集相关系数大幅回落至 0.34，且线性拟合斜率极度扁平化至 0.11。这种显著的数据压缩现象直观反映了模型在解析果实果斑病时遭遇了严重的预测收敛，意味着算法难以有效区分该表型的极端观测值，从而倾向于输出高度趋近群体均值的保守结果。

综合散点特征可以发现，GPSE 模型在白粉病抗性预测中具备优异的特征拟合能力与鲁棒性，而果实果斑病抗性的严重收缩则客观展现了该病害较高的遗传解析难度。

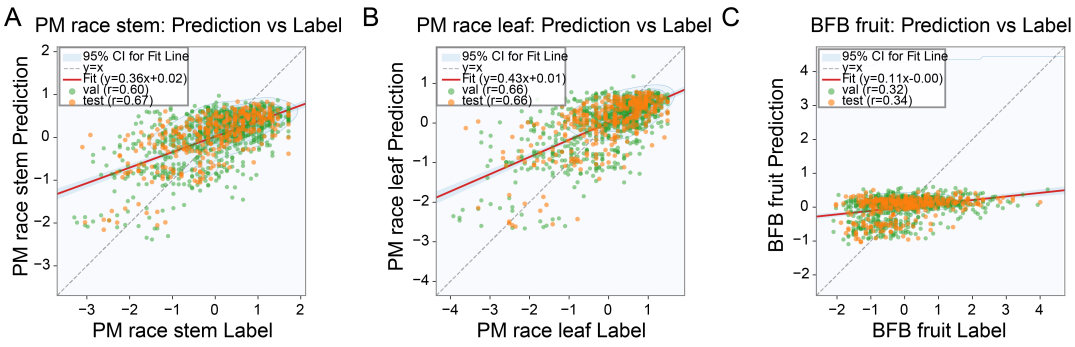

图 10 GPSE 模型对西瓜三个性状预测值与真实值的散点图

图中展示了模型在验证集（val，绿色点）和测试集（test，橙色点）上的预测表现，并利用皮尔逊相关系数（*r*）评估预测准确度。A、B、C 分别代表茎部白粉病抗性、叶片白粉病抗性和果实果斑病抗性。红色实线为实际数据的线性拟合线（Fit），浅蓝色阴影区域表示 95%置信区间（95% CI），灰色虚线代表理想预测的等值线（y=x）。

Fig. 10 Scatter plots of predicted versus observed values for three traits in watermelon using the GPSE model

The plots display the prediction performance on the validation (val, green dots) and test (test, orange dots) sets, with the Pearson correlation coefficient (*r*) used to evaluate prediction accuracy. A, B, and C represent stem powdery mildew (PM race stem), leaf powdery mildew (PM race leaf), and bacterial fruit blotch (BFB fruit), respectively. The solid red line indicates the linear fit (Fit) for the actual data, the light blue shaded area represents the 95% confidence interval (95% CI), and the dashed gray line indicates the ideal 1:1 prediction line (y=x).

3.2.2 GPSE 与传统统计模型的预测精度比较

为进一步评估 GPSE 模型预测性能，本研究将其与基因组预测领域广泛应用的传统统计学模型 GBLUP 和 rrBLUP 进行了预测准确性对比（表 3）。包括黄瓜、甜瓜及西瓜三大园艺作物共计 11 项表型的综合分析，清晰揭示了不同算法架构在拟合遗传效应时的性能分化规律。

从传统统计模型的内部评估来看，GBLUP 与 rrBLUP 在所有性状中的预测准确性表现出极高的一致性，客观反映了这两种基于线性混合模型的方法在识别遗传效应时具有高度相似的底层数学逻辑。将 GPSE 框架引入模型对比后可以发现，该模型在多数性状中有效突破了传统线性模型的预测瓶颈，展现出更为突出的准确性跃升。在预测难度较大的黄瓜炭疽病抗性和甜瓜果重性状中，GPSE 的预测精度分别达到了 0.427 和 0.716，相较于 GBLUP 在对应表型下 0.394 和 0.665 的表现，分别实现了 8.38%和 7.67%的显著性能增益。类似的数据优势同样体现在西瓜果实果斑病抗性中，GPSE 以 0.342 的准确度较 GBLUP 提升了 7.89%，这充分证明 GPSE 能够更深层次地挖掘并整合全基因组标记中的复杂非线性特征映射关系。然而基因组预测模型的效能高度依赖于目标表型的固有遗传结构，传统统计模型在特定表型上依然具备不可替代的拟合优势。在黄瓜开花期与蔓枯病抗性、甜瓜可溶性固形物含量以及西瓜叶片白粉病抗性这四项特征的评估中，GBLUP 和 rrBLUP 展现出了微弱的局

部优势。以预测难度极高的甜瓜可溶性固形物含量为例，rrBLUP 的预测精度稳定在 0.480，优于 GPSE 的 0.446。

综合上述多维度的对比数据表明，尽管传统统计模型在处理部分具有特定遗传基础的性状时依然保持着出色的稳健性，但 GPSE 框架凭借其强大的算法架构，在整体跨物种与多表型的预测任务中展现出了更为广阔的泛化潜力与更高的预测上限。

表 3 基于低维数据的 GPSE 与 GBLUP、rrBLUP 模型基因组预测准确性比较
Table 3 Comparison of genomic prediction accuracies among GPSE, GBLUP and rrBLUP models based on low-dimensional data

物种	性状	GBLUP	rrBLUP	GPSE
黄瓜	霜霉病抗性	0.645	0.644	0.674
	开花期	0.610	0.612	0.593
	蔓枯病抗性	0.603	0.605	0.577
	炭疽病抗性	0.394	0.392	0.427
甜瓜	百粒重	0.894	0.894	0.902
	果宽	0.772	0.770	0.800
	果重	0.665	0.663	0.716
	可溶性固形物含量	0.477	0.480	0.446
西瓜	茎部白粉病抗性	0.635	0.635	0.667
	叶片白粉病抗性	0.674	0.676	0.662
	果实果斑病抗性	0.317	0.316	0.342

3.3 GPSE 在园艺作物高维基因组数据中的预测效果验证

本节在番茄（*S. lycopersicum*）和莴苣（*L. sativa*）两个园艺作物高维基因组数据集上验证 GPSE 集成模型的预测效果。高维数据标记数量远超样本量，本研究分别采用基于连锁不平衡（LD）策略和基于全基因组关联分析 *P* 值（GWAS-*P*）策略对原始标记进行降维筛选，各物种性状组合同样通过熵权 TOPSIS 综合排名筛选前三的算法作为基学习器，采用 Stacking 策略构建 GPSE 集成模型。

3.3.1 两种降维策略的标记分布特征分析

在高维度基因组预测中，降维策略不仅决定了计算效率，更直接影响了输入特征的信息密度。为深入探究基于连锁不平衡（LD）与基于全基因组关联分析 *P* 值

（GWAS-*P*）两种降维策略的差异，本研究首先对番茄和莴苣在高维标记筛选后的分布规律进行了可视化表征（图 11）。

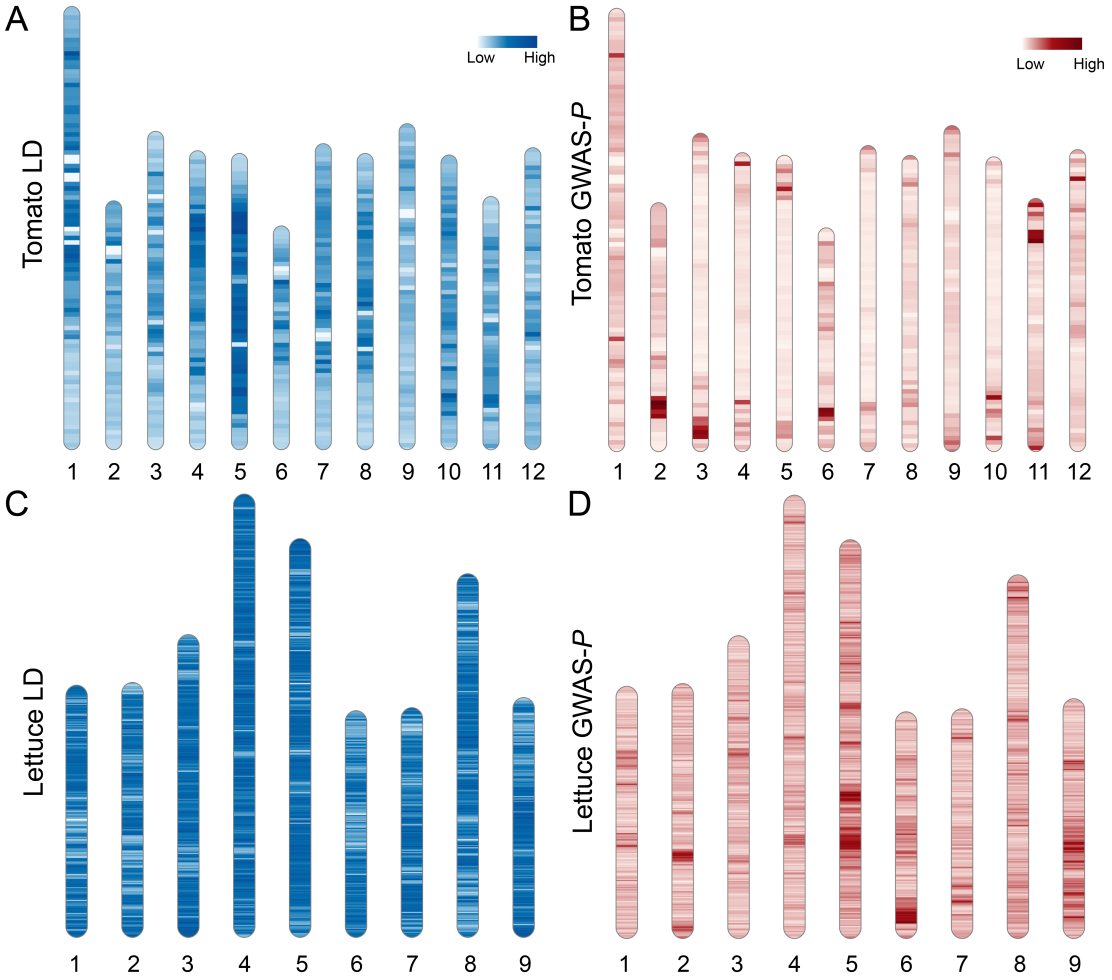

图 11 番茄与莴苣染色体 SNP 密度分布

（A,B）番茄 12 条染色体上用于 LD 策略（A）和 GWAS-*P* 策略（B）的 SNP 密度分布。（C,D）生菜 9 条染色体上用于 LD 策略（C）和 GWAS-*P* 策略（D）的 SNP 密度分布。图中的颜色梯度表示对应区域的 SNP 密度，颜色越深代表该物理区间内的 SNP 密度越高。

Fig. 11 Chromosomal distribution of SNP density in tomato and lettuce

(A, B) Density distribution of SNPs utilized for the LD strategy (A) and the GWAS-P strategy (B) across the 12 tomato chromosomes. (C, D) Density distribution of SNPs utilized for the LD strategy (C) and the GWAS-P strategy (D) across the 9 lettuce chromosomes. The color gradients indicate the SNP density in the corresponding regions, with darker colors representing higher SNP density within the physical intervals.

在番茄 12 条染色体和莴苣 9 条染色体的基因组降维过程中，LD 与 GWAS-*P* 两种 SNP 筛选策略表现出截然不同的特征。在标记保留总量上，LD 策略主要受物理连锁结构影响，容易保留大量冗余 SNP；而 GWAS-*P* 策略以表型关联信号为导向，降维效果更显著。番茄中 LD 保留的 SNP 数量（84,727 个）约为 GWAS-*P*（69,652 个）的 1.2 倍；而在 LD 衰减较慢的莴苣中，两者的差异扩大至 3.2 倍（223,462 个和 68,923 个）。

从空间分布特征来看，密度图直观揭示了两种策略的筛选偏好。LD 策略倾向于在全基因组范围内连续、均匀地保留标记，导致大面积的高密度覆盖，例如莴苣的 3、4、5 号及 8 号染色体几近全长覆盖。相比之下，GWAS-*P* 策略表现出极强的靶向性和区域特异性。它有效剔除了大量背景冗余，将标记精准锚定至与目标性状关联较强的局部热点区域，如番茄的 2、3、11 号以及莴苣的 4、5、8 号染色体特定区段，在显著降低数据维度的同时，突出了潜在的关键候选基因。

3.3.2 LD 与 GWAS-*P* 降维策略的全基因组预测效果对比

为探究不同降维策略对预测效能的具体影响，本研究分别在包含番茄 10 个性状以及莴苣 6 个性状的高维遗传数据集上，系统对比了 LD 与 GWAS-*P* 策略下 11 种机器学习模型的准确性与稳定性表现。

如图 12 所示，番茄 10 个农艺性状的评估结果中，GWAS-*P* 策略相较于传统的 LD 策略展现出压倒性的优势，各模型预测精度的提升幅度介于 3.6%-11.8%。GPSE 集成模型在两种降维策略下均取得最优预测精度，其中在 LD 策略下为 0.765±0.061，在切换至 GWAS-*P* 策略后显著提升至 0.805±0.050。这表明 GPSE 不仅能通过 Stacking 策略捕捉不同算法提取的遗传特征，还能在特征质量提升时表现出更优的上限空间。SVR 模型是 GWAS-*P* 筛选策略的最大受益者，其预测准确性从 0.670 大幅跃升至 0.749，相对增幅高达 11.8%。小提琴图显示，SVR 的结果分布明显上移且带宽收窄，证明其核函数映射机制对标记质量极度敏感。通过 GWAS-*P* 剔除冗余背景噪声，显著降低了特征空间的过参数化风险，释放了该算法的预测潜力。CatB（0.785±0.060）与 RF（0.777±0.052）模型位列单一模型性能前茅。而包括 LGBM、HGB、XGB 和 GBDT 在内的梯度提升类算法在 GWAS-*P* 策略下表现出高度的一致性，各模型的预测精度均稳定在 0.774 至 0.775 之间，体现了基于树的集成算法在处理结构化遗传数据时的强稳定性。KRR 模型在两种策略下均处于垫底位置，尤其在 LD 策略下其小提琴形态呈现宽幅且向低值延伸的特征（仅为 0.564±0.158），表明其核岭回归算法在面对高维噪声数据时缺乏有效的正则化约束，难以建立稳健的预测映射。

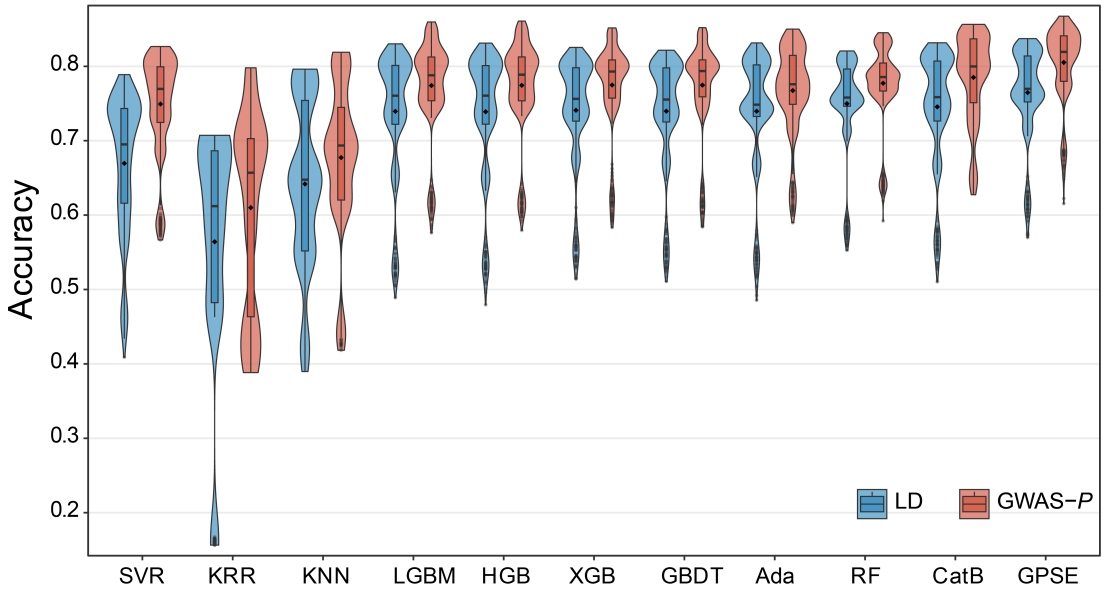

图 12 不同特征降维策略下的番茄基因组预测模型性能评估

小提琴图展示了各模型在 LD（蓝色）与 GWAS-*P*（橙红色）策略下的预测准确度分布。小提琴内部嵌套的箱线图中，黑色圆点和横线分别代表预测准确度的均值和中位数，箱体范围表示四分位距。

Fig. 12 Performance evaluation of tomato genomic prediction models under different feature dimensionality reduction strategies

Violin plots show the distribution of prediction accuracy for each model using LD (blue) and GWAS-*P* (orange-red) strategies. Within each violin, the inlaid boxplot displays the mean (black dot) and median (horizontal line) prediction accuracies, with the box spanning the interquartile range.

如图 13 所示，在对莴苣的 6 个农艺性状评估中，LD 与 GWAS-*P* 策略带来的预测差异较番茄数据集更为显著。这种剧烈的性能分化主要源于莴苣基因组中极高的标记冗余度，导致传统的 LD 降维难以将数据维度压缩至机器学习模型可高效处理的范畴。LD 过滤策略因特征空间充斥大量冗余噪声而导致所有模型预测准确性普遍低迷。

GPSE 虽然在所有模型中表现最优，但准确性仅为 0.413±0.099。SVR 的预测精度为 0.282±0.125，KNN 的精度为 0.246±0.102，表现最差的 KRR 仅为 0.197±0.133。这些模型均显示出在极端冗余数据下的脆弱性，几乎无法捕捉有效遗传信号。相比之下，采用 GWAS-*P* 策略通过精准锚定关键的相关位点，使模型性能实现了质的飞跃。GPSE 的预测准确性从 0.413±0.099 大幅跃升至 0.830±0.041，提升幅度超过一倍，其标准差的骤降也说明在有效信号达到峰值后 GPSE 具备极高的预测稳定性。与此同时树类模型亦稳步提升，LGBM 和 HGB 的精度均达到 0.630±0.039，CatB 与 RF 紧随其后，精度分别为 0.616±0.034 和 0.588±0.049，证明基于表型关联的筛选策略能显著优化决策树的分裂效率。多个梯度提升树模型在 GWAS-*P* 策略下的标准差均缩小至 0.04 左右，展现出高度的预测一致性与抗噪能力。不同算法的响应也表现

出明显的特异性分化，SVR 在 GWAS 策略下精度均值虽然达到 0.683，但其高达 0.238 的标准差反映了该算法对输入标记靶向性的极度依赖以及在部分性状上的预测失灵现象，小提琴图极其宽泛的长尾分布也直观印证了这一点。KRR 尽管精度提升至 0.330±0.075，但仍位列末席，再次印证了简单线性映射关系在高维特征密度场景中难以建立稳健预测逻辑的瓶颈。

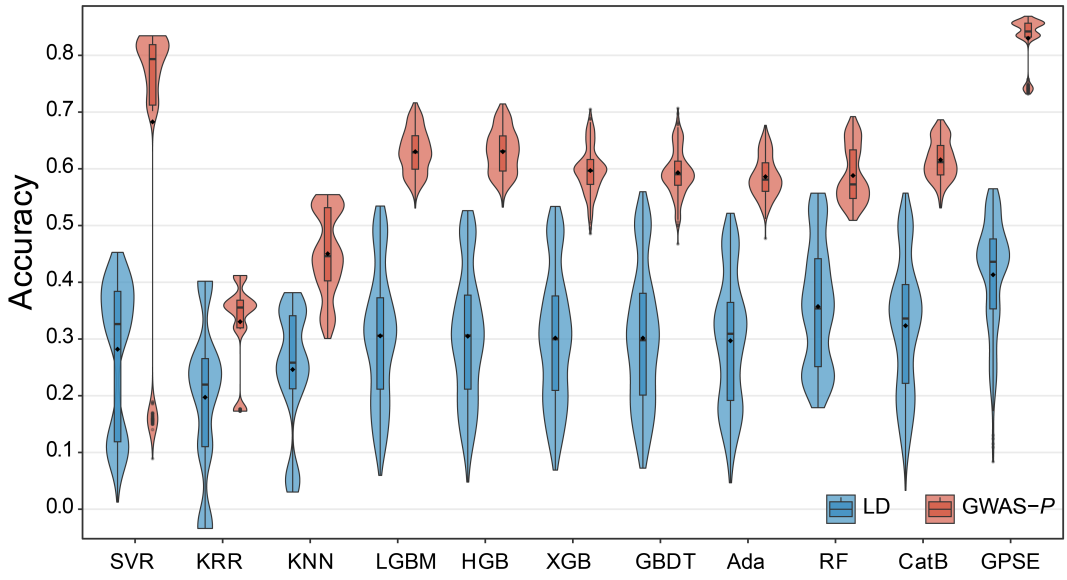

图 13 不同特征筛选策略下的莴苣基因组预测模型性能评估

小提琴图展示了各模型在 LD（蓝色）与 GWAS-*P*（橙红色）策略下的预测准确度分布。小提琴内部嵌套的箱线图中，黑色圆点和横线分别代表预测准确度的均值和中位数，箱体范围表示四分位距。

Fig. 13 Performance evaluation of lettuce genomic prediction models under different feature selection strategies

Violin plots show the distribution of prediction accuracy for each model using LD (blue) and GWAS-*P* (orange-red) strategies. Within each violin, the inlaid boxplot displays the mean (black dot) and median (horizontal line) prediction accuracies, with the box spanning the interquartile range.

3.3.3 基于 GWAS-*P* 策略的 GPSE 与机器学习模型预测精度比较

评估不同机器学习模型对雄蕊长度(STAL)、子房纵径(OLD)、果柄粗度(FSD)、子房横径(OTD)、萼片与花瓣长度比(SPR)、果柄长度(FSL)、花瓣长度(PL)、第二果穗果实数(FRNS)、花瓣数量(PN)以及节间长度(IL)共十种番茄表型的预测准确性(图 14)，结果呈现显著的算法分化与性状特异性规律。

从整体看，LGBM、HGB、XGB、GBDT、Ada、RF 与 CatB 等树形集成模型性能高度一致，普遍优于 KNN 与 KRR 等单一基础线性模型，展现出更强的高维特征提取能力。GPSE 模型展现出绝对的预测优势与跨表型鲁棒性，在 10 项表型预测中均获得最高的准确性。多数模型在子房纵径和雄蕊长度等稳定性状上表现出较好的预测性。以子房纵径为例，GPSE 预测精度高达 0.856，相较于较次优模型 CatB 的

0.849 提升幅度较小，主流集成模型在此类环境敏感度低的性状上性能高度趋同。在子房横径和萼片与花瓣长度比的预测中，GPSE 模型优势更为清晰，其子房横径预测精度达到 0.833，较 CatB 的 0.817 提升约 2.0%；萼片与花瓣长度比以 0.820 的精度较 GBDT 的 0.802 提升了 2.2%。在进行第二果穗果实数、花瓣数量与节间长度等易受环境互作影响的复杂数量性状预测时，所有模型预测性能均出现一致性衰减，模型间分化严重。第二果穗果实数预测中，GPSE 精度达到 0.777，较 RF 模型的 0.757 有明显提升；传统算法 KRR 则发生断崖式下跌至 0.394，预测基本失效，与 GPSE 存在 0.383 的巨大差距。果柄粗度预测同样暴露出基础模型的局限性，KNN 准确率仅 0.745，与 GPSE 高达 0.842 的精度还是存在差距。面对预测难度最高且环境互作效应强烈的节间长度表型，GPSE 的底层架构优势得以充分展现，实现 0.680 的精度，较次优模型 CatB 的 0.650 显著提升 4.6%。在这一极端困难的预测场景下，KNN 与 KRR 分别仅取得 0.441 与 0.463 的极低值。

综上所述，在简单性状上主流算法表现相近，但在解析具有非线性特征的复性状时，GPSE 模型能够有效突破常规算法的拟合瓶颈，展现出更为优异的预测上限。

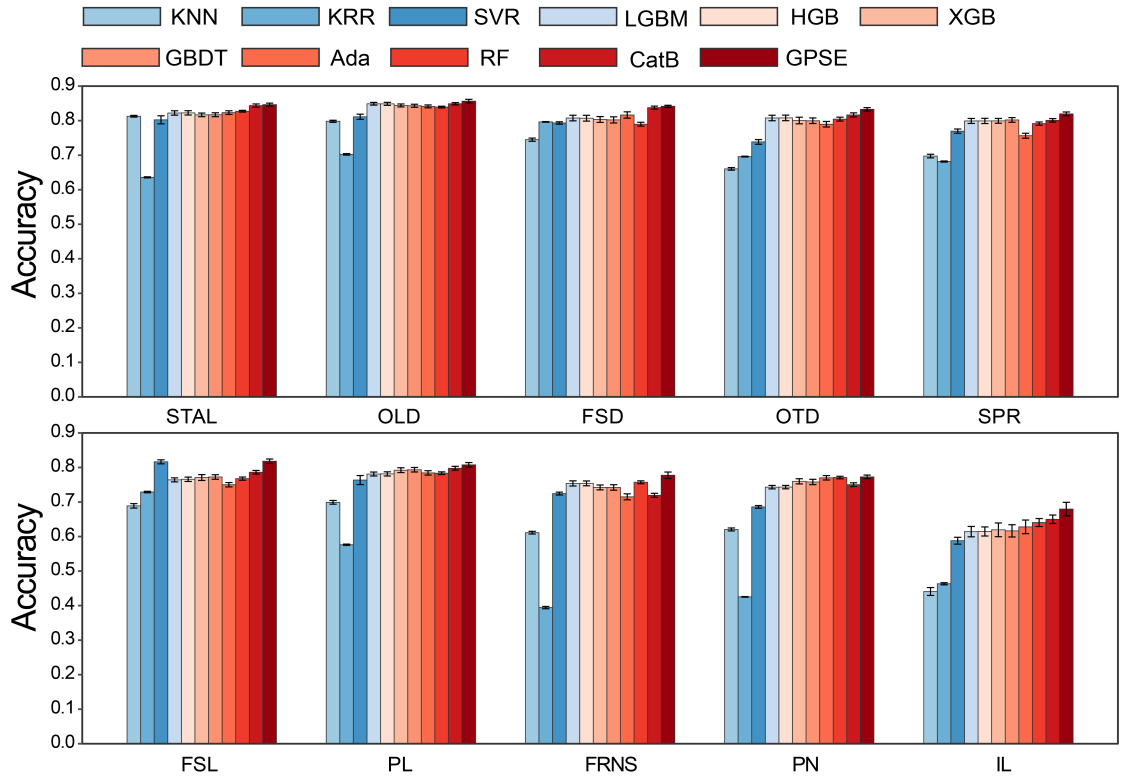

图 14 不同机器学习模型对番茄十个性状的预测准确性对比

图中柱状图展示了 GPSE 框架与其他十种机器学习算法在雄蕊长度、子房纵径、果柄粗度、子房横径、萼片与花瓣长度比、果柄长度、花瓣长度、第二果穗果实数、花瓣数量以及节间长度十个性状上的表现。柱状图的颜色代表不同的机器学习模型，柱形高度对应模型在各表型上的预测准确度。顶部误差线指示了交叉验证过程中的标准差。

Fig. 14 Comparison of prediction accuracies among different machine learning models for ten traits in tomato

The bar chart illustrates the performance of the GPSE framework and ten other machine learning algorithms across ten traits: STAL, OLD, FSD, OTD, SPR, FSL, PL, FRNS, PN, and IL. Different colors represent distinct machine learning models, and the bar height corresponds to the prediction accuracy of the model for each trait. The error bars at the top indicate the standard deviation during the cross-validation process.

为直观揭示 GPSE 模型的预测效能，本研究详细分析了子房纵径、雄蕊长度、果柄粗度、子房横径、萼片与花瓣长度比及果柄长度六个关键形态表型的预测分布特征。结果表明，各项表型的预测值与实际值均呈现极显著的正相关关系。散点图中的绝大多数数据点紧密围绕 Y=X 参考线集中分布，且核心区域密度极高，展现出优异的拟合效果。各表型验证集与测试集的相关系数（r）普遍维持在 0.80 以上的高水平（图 15）。

具体而言，子房纵径测试集相关系数达 0.86，果柄粗度验证集相关系数高达 0.89，萼片与花瓣长度比在测试集中也取得了 0.82 的相关系数。高度集中的数据分布与极强的相关性指标，充分印证了 GPSE 模型在解析番茄性状时具备稳定且强大的预测能力。尽管整体预测效果良好，深入分析各表型的拟合线斜率，可以发现模型存在一定的系统性预测偏差。所有性状的拟合斜率普遍小于 1，表明模型在处理性状的极端值时能力相对较弱。子房纵径与雄蕊长度的拟合斜率分别仅为 0.64 与 0.65，存在明显的低估极高值和高估极低值的趋势，表现为预测值向均值回归（图 15 A, B）。果柄粗度性状的拟合效果相对较好，拟合斜率达到 0.80，更接近 Y=X 的参考斜率（图 15 C）。

综合上述各表型的预测规律可以发现，尽管 GPSE 模型在整体预测精度上确立了显著的领先优势，能够高度拟合绝大多数番茄表型，但在处理具有较大变异且分布极端的表型数据时，模型仍存在一定的局限性，倾向于做出更为保守的均值化预测。这一现象深刻揭示了极端生物学性状背后非线性遗传特征的复杂性，也表明现有模型在面对极端高值和低值时存在预测能力瓶颈。因此，如何克服这一效应将是未来算法优化与框架迭代的重点方向。在后续的完善过程中，可考虑针对极端样本引入差异化的权重分配策略，或探索更为灵活的非线性补偿机制。总体而言，当前版本的 GPSE 模型已在复杂表型解析中展现出强大的稳定性。

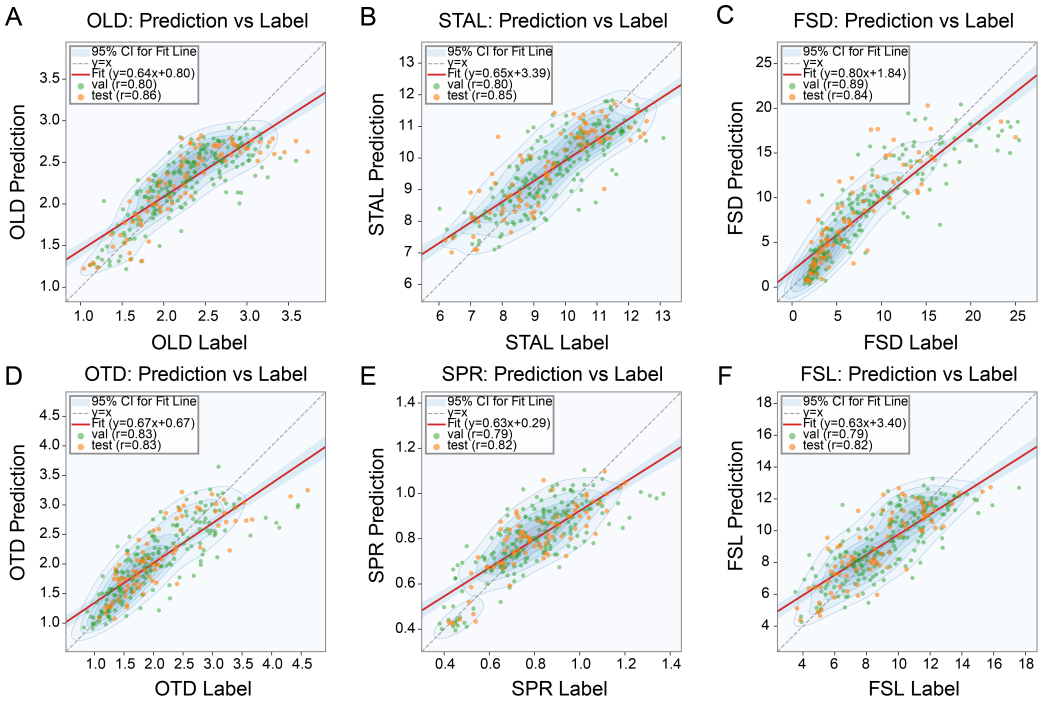

图 15 GPSE 模型对番茄六个性状预测值与真实值的散点图

绿色和橙色散点分别代表验证集（val）和测试集（test），预测准确度由皮尔逊相关系数（r）评估。(A-F)依次对应子房纵径、雄蕊长度、果柄粗度、子房横径、萼片与花瓣长度比和果柄长度。红色实线与浅蓝色阴影分别为线性拟合线及其 95%置信区间（CI），灰色虚线为理想预测线（y=x）。

Fig. 15 Scatter plots of predicted versus observed values for six traits in tomato using the GPSE model

Green and orange dots represent the validation (val) and test sets, respectively, with prediction accuracy evaluated by Pearson's r. (A-F) denote OLD, STAL, FSD, OTD, SPR, and FSL. The solid red line and light blue shadow indicate the linear fit and its 95% confidence interval (CI), while the dashed gray line represents the 1:1 ideal prediction (y=x).

对叶片长度(Length)、叶片宽度(Width)、叶片表面积(Surface Area)、叶片卷曲度(Curliness)、叶夹角(Angle p1)以及叶片平整度(Flatness)共 6 项莴苣性状的预测评估表明，各类机器学习算法展现出高度异质化的拟合特征。GPSE 模型在所有评估任务中均保持绝对领先，在六个性状中均取得最优的预测效果（图 16），凸显了其在解析莴苣叶片形态类表型时的稳定性。

观察具体算法表现，SVR 模型在处理多数叶片相关性状时展现出强劲的预测潜力。在叶片宽度、表面积、卷曲度、叶夹角与平整度这五类性状中，SVR 的准确性紧随 GPSE 之后，显著优于 LGBM 与 HGB 等一众树形集成算法。以叶片表面积为例，GPSE 取得了 0.856 的最优精度，较次优模型 SVR 的 0.831 提升了 3.0%，且两者均大幅跨越了其余集成模型 0.600 至 0.640 的较低精度区间。在叶夹角预测任务中，GPSE 的准确率达到 0.859，较 SVR 的 0.767 实现了 12.0%的显著提升，进一步拉开了与传统框架的性能差距。然而面对叶片长度这个特殊性状时，模型间的性能表现发生剧烈反转。SVR 与 KRR 模型暴露出严重的底层适用性缺陷，其准确率分

别骤降至 0.159 与 0.175 的极低谷值。相比之下，主流集成模型在叶片长度上维持了 0.573 至 0.645 的中等表现。在这一传统算法大面积失效的极端场景下，GPSE 模型依然逆势斩获 0.854 的高精度预测，较表现最优的集成模型 LGBM 大幅提高了 32.4%，彻底克服了单一基础算法在特定维度上的性能崩溃。叶片平整度作为预测效果最差的表型，基础算法 KNN 准确率探底至 0.333，综合性能最优的 GPSE 模型其表现也相应回落至 0.742，但仍较 KNN 实现了高达一倍的性能飞跃。

上述多元化的数据充分证明，常规算法在莴苣复杂表型空间中的泛化能力极为脆弱且易受具体性状干扰，而 GPSE 能够自适应弥补各类传统架构的短板，为植物形态特征提供了更为稳健的预测范式。

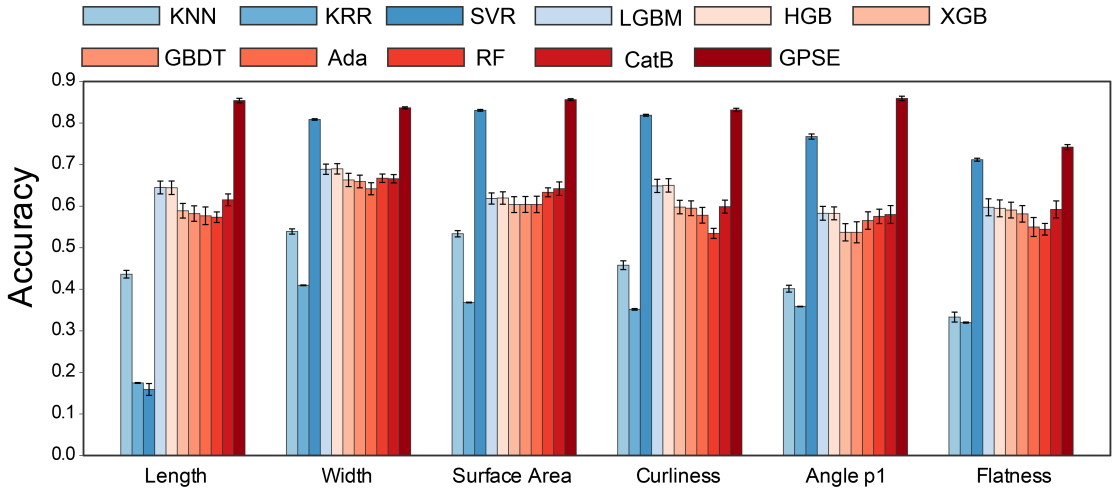

图 16 不同机器学习模型对莴苣六个性状的预测准确性对比

图中柱状图展示了 GPSE 框架与其他十种机器学习算法在叶片长度、宽度、表面积、卷曲度、叶夹角以及平整度六个性状上的表现。柱状图的颜色代表不同的机器学习模型，柱形高度对应模型在各表型上的预测准确度。顶部误差线指示了交叉验证过程中的标准差。

Fig. 16 Comparison of prediction accuracies among different machine learning models for six traits in lettuce

The bar chart illustrates the performance of the GPSE framework and ten other machine learning algorithms across six traits: Length, Width, Surface Area, Curliness, Angle p1, and Flatness. Different colors represent distinct machine learning models, and the bar height corresponds to the prediction accuracy of the model for each trait. The error bars at the top indicate the standard deviation during the cross-validation process.

为深入评估 GPSE 模型的预测效能，本研究聚焦于叶夹角（Angle p1）、叶片表面积（Surface Area）与叶片宽度（Width）的预测结果散点分布（图 17）。各项表型预测值与实际值均呈极显著正相关，绝大多数数据点紧密聚集于 Y=X 参考线两侧。相关系数（r）在验证集与测试集中普遍维持在高水平。叶片表面积验证集相关系数高达 0.88，且其与叶夹角的测试集相关系数同时达到 0.86，充分印证了该模型极高的拟合精度与泛化能力。

深入分析拟合线特征可以发现，三项表型拟合斜率普遍小于 1，存在一定程度的均值回归偏差。模型直观表现出低估极端高值与高估极端低值的倾向。叶片表面积拟合效果相对最优，拟合斜率达到 0.80，回归线最贴近理想状态（图 17 B）。叶夹角拟合斜率仅为 0.59，极端数据偏离现象更为明显（图 17 A）。由此可见，GPSE 模型较为契合莴苣群体的大部分变异特征，但在解析极端表型时，预测结果不可避免地受到均值平滑效应的制约，呈现出向中心靠拢的收缩趋势。

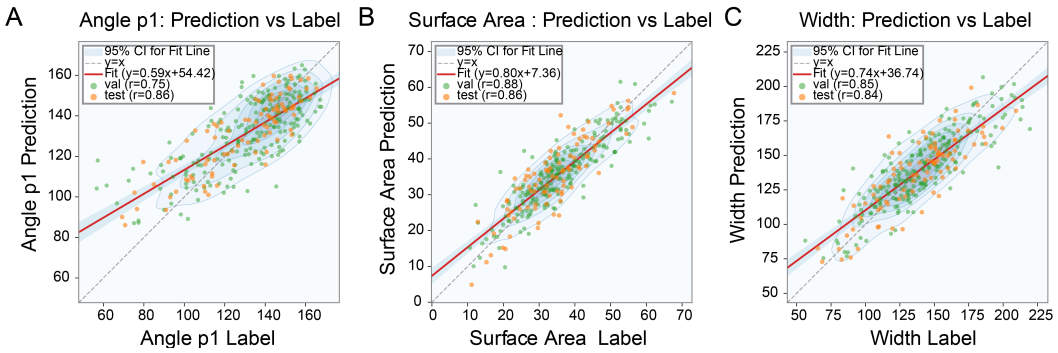

图 17 GPSE 模型对莴苣三个性状预测值与真实值的散点图

图中展示了模型在验证集（val，绿色点）和测试集（test，橙色点）上的预测表现，并利用皮尔逊相关系数（*r*）评估预测准确度。A、B、C 分别代表叶夹角、叶片表面积和叶片宽度。红色实线为实际数据的线性拟合线（Fit），浅蓝色阴影区域表示 95%置信区间（95% CI），灰色虚线代表理想预测的等值线（y=x）。

Fig. 17 Scatter plots of predicted versus observed values for three traits in lettuce using the GPSE model

The plots display the prediction performance on the validation (val, green dots) and test (test, orange dots) sets, with the Pearson correlation coefficient (*r*) used to evaluate prediction accuracy. A, B, and C represent Angle p1, Surface Area, and Width, respectively. The solid red line indicates the linear fit (Fit) for the actual data, the light blue shaded area represents the 95% confidence interval (95% CI), and the dashed gray line indicates the ideal 1:1 prediction line (y=x).

3.3.4 基于 GWAS-*P* 策略的 GPSE 与传统统计模型预测精度比较

评估 GPSE 与传统基因组选择模型 GBLUP 及 rrBLUP 在番茄十个表型上的预测精度发现(表 4)，GPSE 模型整体展现出显著的性能优势。传统模型 GBLUP 与 rrBLUP 在各项番茄性状预测中的表现高度趋同，预测准确性几乎完全一致。在子房纵径与雄蕊长度等多数形态指标中，GPSE 的准确性均超越两种传统算法。当面对预测难度较高的复杂性状时，GPSE 的多维特征挖掘优势得以充分显现。以节间长度为例，GBLUP 与 rrBLUP 的预测精度仅徘徊在 0.588 左右，而 GPSE 则取得了 0.680 的优异成绩，相对传统模型实现了约 15.6%的提升幅度。在第二果穗果实数与花瓣数量的预测中，GPSE 同样打破了传统算法 0.730 附近的精度瓶颈，将准确性分别提升至 0.777 与 0.773。这表明针对番茄复杂的农艺性状，GPSE 架构能够有效捕捉传统线性模型难以拟合的数据变异信息。

在莴苣六个形态表型的预测评估中，模型间的性能对比呈现出与番茄截然不同的分布规律。传统线性模型 GBLUP 与 rrBLUP 在莴苣数据集上展现出了极高的预测水准，两者在多数叶片相关性状的表现均超越 GPSE 模型。在叶片表面积与叶片长度的预测效果中，GBLUP 与 rrBLUP 的准确性均高于 0.900，显示出极强的拟合优势，而 GPSE 在这两项指标上的精度则徘徊在 0.850 左右。尽管传统模型在常规叶片形态上占据主导地位，GPSE 在解析特定空间构型特征时依然具有独特优势。在叶夹角表型的预测中，GPSE 以 0.859 的最高准确性打破了 GBLUP 与 rrBLUP 在此处 0.798 的性能上限，相对提升幅度达到 7.6%。

综合两个物种性状预测结果可以看出，GBLUP 与 rrBLUP 在处理莴苣叶片等线性规律明显的表型时能够提供高效精准的预测，而 GPSE 模型则在攻克番茄复杂数量性状及莴苣特殊空间性状的非线性解析中提供了更为稳健的预测效果。

表 4 结合 GWAS-*P* 策略的高维数据下 GPSE 与 GBLUP、rrBLUP 模型预测准确性比较
Table 4 Comparison of prediction accuracies among GPSE, GBLUP and rrBLUP models based on high-dimensional data combined with GWAS-*P* strategy

物种	性状	GBLUP	rrBLUP	GPSE
番茄	雄蕊长度	0.829	0.831	0.846
	子房纵径	0.818	0.816	0.856
	果柄粗度	0.864	0.862	0.842
	子房横径	0.817	0.821	0.833
	萼片与花瓣长度比	0.801	0.799	0.82
	果柄长度	0.816	0.818	0.818
	花瓣长度	0.757	0.756	0.808
	第二果穗果实数	0.726	0.725	0.777
	花瓣数量	0.736	0.735	0.773
	节间长度	0.588	0.587	0.68
莴苣	叶片长度	0.902	0.902	0.854
	叶片宽度	0.878	0.879	0.837
	叶片表面积	0.904	0.905	0.856
	叶片卷曲度	0.862	0.863	0.832
	叶夹角	0.797	0.798	0.859
	叶片平整度	0.772	0.775	0.742

3.4 GPSE 在多分类任务的预测表现

除了对连续型数量性状的预测之外，模型针对质量性状的判别能力，同样也是完善全基因组选择体系的核心关键，本研究借助 GPSE 框架，对莴苣的二分类、三分类以及四分类性状开展了系统性的预测评估，同时选取了在多分类领域中表现一向稳健的 RF 模型作为对照模型，通过绘制对应的性状特征 ROC 曲线并计算曲线下 AUC 面积，来定量衡量各类模型的分类判别效能，具体的试验结果如图 18 所示。

在结构相对简单的二分类任务当中，GPSE 模型展现出了极高的分类判别准确度（图 18 A, D）。在 2020 年叶片花青素显色（LAC）性状的预测试验中，GPSE 模型的曲线下面积达到 0.954，显著优于 RF 模型的 0.926，对应的特征曲线极度贴近坐标轴左上角，这也直接表明该模型在这一性状上具备近乎完美的判别能力。对于叶片质地（LT）这一性状，GPSE 与 RF 模型的曲线下面积分别为 0.834 和 0.820，二者整体性能表现十分接近；该性状的判别能力略低于叶片花青素显色性状，主要原因可能是脆（Crisp）与柔软（Soft）两类叶片之间的表型界限相对模糊。随着分类类别数量逐步增加，性状间的过渡特征会对模型分类能力提出更高挑战。在三分类任务的叶缘缺刻（LL）表型预测中，GPSE 模型在无（A）、浅裂（L）、深裂（P）三个类别上的曲线下面积依次为 0.955、0.881 和 0.976（图 18 B），各项数值全线超越 RF 模型对应的 0.893、0.773 和 0.923；其中深裂类别的区分度最高，浅裂类别区分度相对偏低，这也反映出模型对不同几何形态特征的捕获能力存在明显差异性。在结球性（HF）表型预测试验中，GPSE 与 RF 模型的表现高度趋同（图 18 E, F）；两个年份的试验数据均显示，松散结球（L）的曲线下面积始终处于最低水平，数值区间维持在 0.650 至 0.688 之间，这也证实中间过渡表型兼具不结球（N）与紧实结球（T）的双重特征，进而导致模型分类边界极易发生重叠。在包含外叶颜色（OLT）的无（A）、黄绿色（Y）、灰绿色（G）、红色（R）四种色调的复杂四分类性状中（图 18 C），GPSE 模型在多数类别上均保持领先优势；其中红色性状的识别效果最佳，曲线下面积为 0.897，而灰绿色类别的曲线下面积仅为 0.560，对应 RF 模型数值为 0.494，这一结果说明灰绿色与其他色调间存在剧烈的表型覆盖，使得模型对该特定颜色的辨识度受到明显限制。

综合各项试验结果来看，GPSE 模型在多数分类场景下的判别效能，都要优于或是基本持平于对照的 RF 模型，结合全部预测结果能够发现，模型的整体分类性能

不光会受到自身算法结构的限制，更会直接取决于目标性状本身的可区分程度，随着分类类别数量的不断增加，再加上各类中间过渡类型性状的引入，模型的整体判别难度也会呈现出梯度上升的趋势。

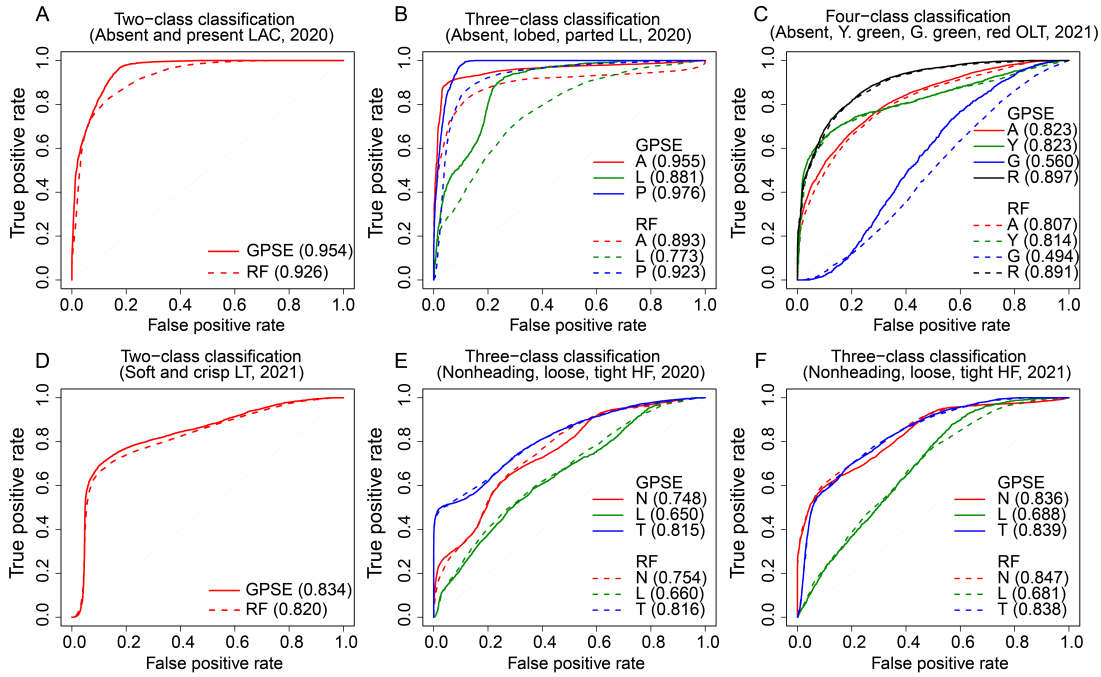

图 18 GPSE 与 RF 模型对不同质量性状的分类预测 ROC 曲线

（A）2020 年叶片花青素显色（LAC）的二分类预测；（B）2020 年叶缘缺刻（LL）的三分类预测；（C）2021 年外叶颜色（OLT）的四分类预测；（D）2021 年叶片质地（LT）的二分类预测；（E-F）分别为 2020 年（E）和 2021 年（F）结球性（HF）的三分类预测。图中实线代表 GPSE 模型，虚线代表随机森林（RF）模型，图例括号内的数值为曲线下面积（AUC）。表型及分类缩写说明：LAC（叶片花青素显色）：无，有；LL（叶缘缺刻）：A=无，L=浅裂，P=深裂；OLT（外叶颜色）：A=无，Y=黄绿色，G=灰绿色，R=红色；LT（叶片质地）：柔软，脆；HF（结球性）：N=不结球，L=松散结球，T=紧实结球。

Fig. 18 ROC curves of GPSE and RF models for predicting different qualitative traits

(A) Two-class classification for leaf anthocyanin coloration (LAC) in 2020. (B) Three-class classification for leaf lobes of margin (LL) in 2020. (C) Four-class classification for outer leaf color (OLT) in 2021. (D) Two-class classification for leaf texture (LT) in 2021. (E-F) Three-class classification for head formation (HF) in 2020 (E) and 2021 (F). Solid lines represent the GPSE model, and dashed lines represent the Random Forest (RF) model. Values in parentheses indicate the Area Under the Curve (AUC). Abbreviations for phenotypic traits and classes: LAC: Absent, Present; LL: A = Absent, L = Lobed, P = Parted; OLT: A = Absent, Y = Yellowish green, G = Grayish green, R = Red; LT: Soft, Crisp; HF: N = Nonheading, L = Loose heading, T = Tight heading.

3.5 SNP 数量对 GPSE 预测准确性的影响

为了探索 SNP 标记数量对模型预测准确性的具体影响规律，本研究针对 GPSE 以及 SVR、KRR、KNN、LGBM 等共计 10 种机器学习模型，在黄瓜霜霉病抗性（Cucumber Downy Mildew）、甜瓜果实重量（Melon Fruit Weight）以及西瓜白粉病抗性（Watermelon PM race leaf）三个核心表型上的预测表现做了全面测试与评估（图 19）。从整体试验趋势来看，随着 SNP 标记比例的逐步提升，多数模型的预测准确性会呈现出先快速上升、随后逐渐趋于平稳的动态变化特征，在针对不同表型的各

类预测任务中，GPSE 模型都展现出了极为出色且稳定的预测优势，即便在标记密度较低的条件下，该模型也能有效捕捉到关键的遗传信息，进而实现高效且可靠的预测。以黄瓜霜霉病抗性的预测任务为例（图 19 A），当 SNP 比例仅为 20%时，GPSE 模型的预测准确性就已经达到了 0.699 的较高水平，这一数值显著优于同一试验条件下，预测准确性仅为 0.480 的 KRR 模型。随着 SNP 比例进一步提升至 40%及以上，各模型的预测性能普遍趋于平稳，这也能够说明，中等规模的标记子集已经能够解释大部分的表型遗传变异。在甜瓜果实重量的预测中（图 19 B），GPSE 模型在 40%的 SNP 比例下就达到了 0.700 的预测准确性峰值，充分展现出了极高的标记利用效率；更为突出的是，在极低标记覆盖率的极端试验条件下，GPSE 模型依然能保持强大的特征提取鲁棒性。在西瓜白粉病抗性的数据集中（图 19 C），当 SNP 比例低至 5%时，GPSE 的预测准确性仍能稳定维持在 0.638，而同期参与测试的 SVR 模型，预测准确性则大幅骤降至 0.208。

这些详实的试验数据充分说明，GPSE 模型不仅在全量标记的常规条件下具备出色的预测能力，在低密度标记的受限场景中，同样能够凭借自身优质的算法机制，保持高度的预测准确性与运行稳定性，整体预测性能要显著优于其他参与对比的各类机器学习模型。

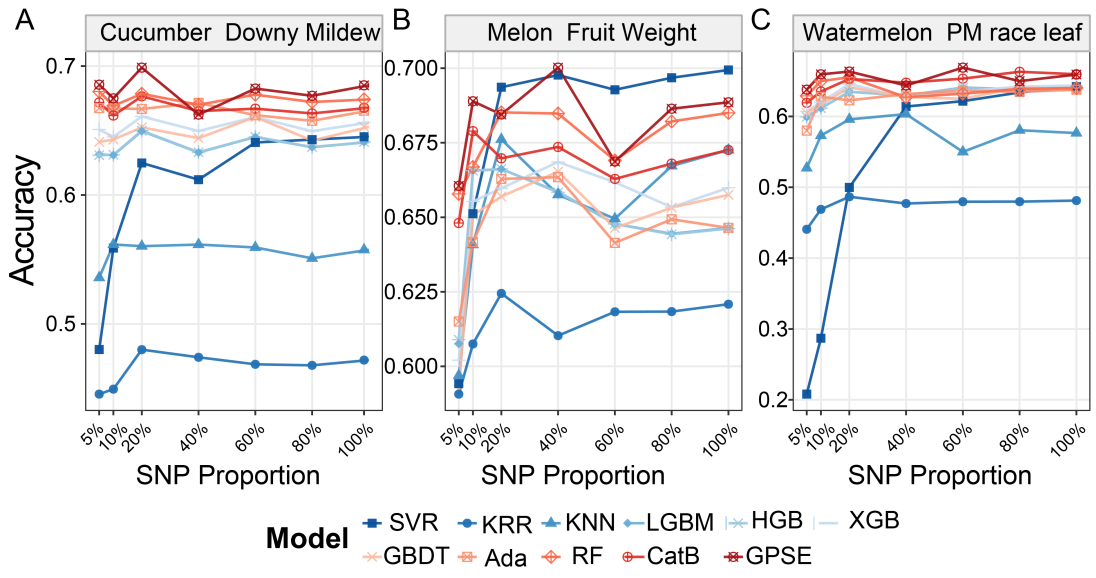

图 19 标记密度对不同机器学习模型预测准确性的影响

黄瓜霜霉病抗性（A）、甜瓜果实重量（B）与西瓜白粉病抗性（C）在不同 SNP 比例（5%~100%）下的预测准确性变化趋势。不同颜色和标记的折线分别代表 GPSE 及其对比模型。

Fig. 19 Effect of marker density on the prediction accuracy of different machine learning models

Trends in prediction accuracy for Cucumber Downy Mildew (A), Melon Fruit Weight (B), and Watermelon PM race leaf (C) under varying SNP proportions (5%–100%). Lines with different colors and markers represent the GPSE framework and its comparative models.

4 讨论

4.1 单一基因组预测模型缺乏普遍适用性

单一的基因组预测模型间不存在万能模型，如图 3 结果所展示的没有一个模型针对任何性状均表现出最优的预测效果，这恰恰证明了没有免费午餐定理（Wolpert and Macready 2002）在基因组预测领域也同样的适用。正如本研究结果所示，模型的预测性能高度依赖于目标物种及特定的表型性状。即使是同一个预测模型，在跨越玉米和云杉等不同物种，或是面对生长和发育等不同类型性状时，其预测表现也会出现显著的波动，且不同场景下的最优模型往往不尽相同（图 3）。

这种现象在其他领域也被证明了，通过对 121 个数据集上的 179 个预测模型进行测试，得出 RF 算法取得了整体最优的表现。但是这实验并未关注到 RF 算法针对排名第二的 SVM 模型更具有统计学上的优势，其实模型间的差异十分微小（Fernández-Delgado et al 2014）。并没有任何一个单一模型能够明显优于其它模型（Gómez and Rojas 2016）。同样的在基因组预测领域，预测模型并不能对数据噪音，数据不平衡等所有的负面因素保持免疫。综上所述，可能部分模型在特定的物种或特定的表型预测效果超越其他模型，但是并不具备普遍适配性。

4.2 基于熵权 TOPSIS 的算法综合评估

在全基因组预测这一研究领域中，长期存在着只聚焦单一评价指标的普遍现象，当前业内最为常用的常规评价指标是皮尔逊相关系数。这一指标能较为直观地衡量出表型预测值与真实值之间的线性关联程度，可皮尔逊相关系数也有着明显的应用短板，它只会关注整体数据的线性关联走向，即便模型的预测结果相较于真实值整体偏高或是整体偏低，这一指标依旧有可能给出较高的评分，这样的评价偏差也会直接掩盖算法本身在预测精度上存在的严重缺陷。相关研究已经明确表明，把这一系数当作性状预测的唯一评价指标会存在较大的局限性，这类指标无法反映数据间的非线性关联关系，盲目依赖还容易引发后续育种决策的失误问题（Pan et al 2024）；均方误差与均方根误差也是基因组预测领域较为常用的评价指标，这两类指标能精准反映出预测值与真实值之间的偏离幅度，可对应的弱点也十分突出，就是对数据中的异常值过于敏感。因此本文引入了基于熵权的 TOPSIS 综合评价算法，能依托

多个指标对各类预测模型开展更为全面的综合评估，本文也主要从预测准确性与稳定性两个核心维度，来全面衡量模型的实际表现。正如本研究在模型评估中所观察到的，某些预测模型虽然能够取得最优的预测精度，但往往伴随着较大的波动幅度；相反，部分模型即使在绝对精度上略逊一筹，却能凭借极高的预测稳定性，反而能在基于熵权 TOPSIS 的综合评价中取得最优排名（图 4 C）。这一结果充分说明，在全基因组预测领域中，仅凭较高的预测精度，完全无法全面衡量模型在实际应用中的综合表现。对于这类预测精度偏高但稳定性偏弱的模型来说，或许能在测试集当中展现出较好的预测效果，可投入到全新的预测任务中时，就极有可能出现预测失效的问题；在实际的育种应用场景里，育种工作者往往需要全面衡量对应的预测风险，把这种多指标综合评价体系引入到全基因组预测领域中，能够让育种家结合自身的实际育种需求，对各类核心预测指标开展综合考量与权衡，进而筛选出更贴合实际育种应用的优质预测模型。

4.3 GPSE 集成学习的精度与多样性权衡

本研究针对 GPSE 框架的实际测试流程，特意把基于熵权的 TOPSIS 算法融入模型前置筛选环节，先对所有候选模型开展前置综合评分与逐层择优筛选，再把筛选合格的模型逐一送入 Stacking 元模型完成后续训练，这一优化策略有效拉高了模型整体的预测精度与运行稳定性。本研究全程兼顾准确性与稳定性两大核心评价维度，借助 TOPSIS 算法精准剔除了仅在单一皮尔逊相关系数指标下表现亮眼、实际预测过程却波动剧烈的劣质模型，这样严格的前置质量把控，也让后续入选的基学习器同时具备了优质的预测潜力和较强的抗干扰能力，在本研究针对园艺作物多个性状的全基因组评估测试中，这套优化后的模型体系也均展现出了优异的预测效果。

虽说这套筛选模式的实际应用效果已经得到了充分验证，但从理论层面来看，直接把 TOPSIS 绝对得分当作模型唯一入选标准，也潜藏着陷入同质集成多样性陷阱的风险。本研究在模型筛选阶段并没有针对线性模型、核方法、树模型等不同算法家族开展分层独立的优选，而是采用了基于综合评分的全局截断筛选方式，这也会导致最终入选的基学习器在底层建模逻辑上呈现高度同质化的问题，相关领域已有研究（Brown et al 2005）明确指出，集成学习能够发挥有效作用的核心前提，是基学习器之间具备误差独立性，也就是说入选模型既要拥有良好的预测性能，也要具备彼此差异化的建模特质，尽量避免出现高度趋同的建模思路。

从算法本质来讲，TOPSIS 属于依托多维距离完成模型性能绝对排序的评价手段；如果后续泛化应用时，仍旧只依托综合评分做严苛的一刀切筛选，处理特定群体数据集的过程中，依托梯度提升框架衍生出的各类算法，大概率会在综合评分中集体占据前列，可一旦将这类评分相近、犯错倾向高度一致的同质模型用于 Stacking 集成，元学习器就很难从多样化的误差分布中获取额外的预测增益，更难以充分发挥异质集成学习优势互补的核心机制（Zhang et al 2022）。已有研究也早已证实（Kuncheva and Whitaker 2003），这类缺乏非线性模型差异碰撞的同质集成，不仅无法为预测精度带来实质性的突破，还会额外耗费大量计算资源，甚至会加剧模型在适配全新测试群体时的过拟合风险，反而拉低整体的预测鲁棒性。

依靠 TOPSIS 算法结合综合评分完成基学习器的优选工作，确实能大幅提升全基因组预测的整体表现，但研究过程中必须警惕唯分数论带来的模型同质化隐患，切忌单纯看重综合得分，反而忽略模型多样性这一核心前提；未来针对这套算法的优化方向，可以尝试在现有评价体系中加入模型相关性惩罚项，或是真正推行针对不同算法家族的分层独立优选方案，这样才能让 Stacking 集成模型在追求极致预测性能的同时，保留基学习器必备的多样性，进而在模型偏差与方差的动态博弈中，实现全基因组预测效果的最优平衡。

4.4 特征选择策略对全基因组预测效果的影响

本研究依托番茄与莴苣的多性状高维遗传数据集开展了系统的对比试验，切实揭示出了不同特征选择策略对全基因组预测效能以及底层机器学习算法响应机制的核心影响。传统的 LD 策略只能依托群体结构剔除掉存在相关性的遗传标记，却没办法保证筛选后保留的特征能和目标性状之间形成真实的生物学因果关联，这一短板在基因组冗余度极高的莴苣数据集里被彻底暴露了出来，还会把所有参与测试的预测模型都拖入维度灾难与背景噪声的双重干扰当中，与之相比，GWAS-*P* 策略能够精准锁定和目标性状相关的关键位点，也实现了对特征空间的有效净化处理，这一策略在番茄和莴苣两类数据集当中都全面提升了对应的预测精度。这样的试验结果和 Spindel 等人针对作物复杂性状的相关研究结论高度契合，也就是把全基因组关联分析筛选出的关键标记融入到预测模型当中，不仅能有效规避传统无监督降维方法的盲目性，还能进一步拉高模型整体的预测上限（Spindel et al 2015）。Zhang 等人后续在多倍体作物的全基因组预测研究中，也进一步证实了把关联分析筛选出的显

著标记和机器学习算法结合起来，预测效果能明显超过使用全基因组标记的常规模型（Zhang et al 2023）。

但在特征冗余度极高的莴苣数据集当中，即便前期已经完成了特征精简处理，SVR 等模型依旧暴露出极高的预测波动性，且预测结果呈现出明显的分布偏差；而 KRR 模型在两种特征筛选策略下，预测表现更是一直处于所有模型的垫底位置，这一点也充分印证了 Azodi 等人对机器学习预测模型做基准测试时提出的核心观点，也就是缺乏有效正则化约束的简单核方法或是线性映射模型，在高维特征密集的试验场景中很容易出现过拟合问题，很难搭建出稳健的非线性预测逻辑（Azodi et al 2019）。和这类模型的表现形成鲜明对比的是，RF 模型以及各类集成学习模型，在不同数据集和不同特征筛选策略的测试中，都展现出了极强的抗干扰能力和超高的预测稳定性。

本研究搭建的 GPSE 集成模型在剔除掉全部冗余遗传信息之后，不仅牢牢守住了模型的预测下限，依托 Stacking 框架融合不同算法优势的能力，也在高质量的特征空间中得到了最大化的发挥，进而在莴苣数据集的测试中，不仅实现了预测精度的跨越式提升，更显著收敛了预测误差，达成了准确性与稳定性的双重突破。这一结果也有力支撑了 Liang 等人构建全基因组选择 Stacking 集成框架时得出的研究结论，也就是通过元学习器对多个基学习器进行科学整合，能有效平抑单一算法的预测波动，还能突破单个模型的预测瓶颈（Liang et al 2021a）。结合全部试验结果能够看出，在复杂园艺作物的分子育种实践过程中，放弃盲目依托连锁不平衡的过滤方式，转而选用基于表型靶向的精准特征选择策略，同时搭配能够适配高维特征的集成学习框架，是突破高维遗传数据冗余瓶颈、实现稳健高效全基因组选择的最优路径。

4.5 GPSE 在园艺作物应用的可行性与局限

本研究依托 GPSE 框架，在低维的瓜类数据集以及高维的番茄、莴苣数据集上均取得了优异的预测结果，这也进一步证实，融合先进机器学习算法的全基因组选择技术，在园艺作物复杂性状辅助育种领域，具备极高的技术可行性与广阔的产业应用潜力。

尽管全基因组选择技术具备可观的应用前景，但该技术在园艺领域的全面推广落地，仍面临特有的遗传与环境双重局限。一方面，园艺作物的遗传背景远复杂于

禾本科粮食作物，多数物种具备高度杂合或多倍体特征，这种复杂的基因组结构大幅提升了等位基因剂量效应的评估难度，也导致常规预测模型在处理高杂合度遗传数据时，极易出现性能衰减、预测效果触及瓶颈的问题（Endelman et al 2018）；另一方面，园艺作物核心经济性状对环境变化极度敏感，基因与环境互作效应极强，无论是温室设施栽培还是露地常规栽培，微小的环境波动都可能引发目标性状的大幅变动。

针对上述核心局限，后续可从两大关键方向对 GPSE 模型进行优化升级：一是在现有预测模型中整合环境协变量，相关研究已证实，环境因素对模型跨环境、跨年份的预测准确性影响极为显著（Crossa et al 2017），通过融入环境变量能有效弱化基因与环境互作带来的预测波动；二是将园艺作物现有多组学数据作为基因型数据的有效补充，以此破解高密度基因分型成本高昂、具备广泛代表性的大型参考群体构建困难等现实瓶颈，进一步推动全基因组选择技术在园艺作物中实现商业化落地。

参考文献

1. Ahmed S, Roy S, Alam GR. Benchmarking and selecting optimal diabetic retinopathy detecting machine learning model using entropy and TOPSIS method. International Conference on Electrical, Computer, Communications and Mechatronics Engineering, 2021, Mauritius
2. Alzubi R, Ramzan N, Alzoubi H, Katsigiannis S. SNPs-based hypertension disease detection via machine learning techniques. 24th International Conference on Automation and Computing, 2018, Newcastle upon Tyne, UK
3. Arora G, Aidhy DS. Machine learning enabled prediction of stacking fault energies in concentrated alloys. *Metals*, 2020, 10:1072
4. Azodi CB, Bolger E, McCarren A, Roantree M, de Los Campos G, Shiu S-H. Benchmarking parametric and machine learning models for genomic prediction of complex traits. *G3: Genes, Genomes, Genetics*, 2019, 9:3691-3702
5. Bernardo R. Genomewide selection when major genes are known. *Crop Science*, 2014, 54:68-75
6. Bernardo R. Reinventing quantitative genetics for plant breeding: something old, something new, something borrowed, something BLUE. *Heredity*, 2020, 125:375-385
7. Bernardo R, Yu J. Prospects for genomewide selection for quantitative traits in maize. *Crop Science*, 2007, 47:1082-1090
8. Biswas A, Wechter P, Ganaparthi V, Jarquin D, Kousik S, Branham S, Levi A. Comparative genomic prediction of resistance to Fusarium wilt (*Fusarium oxysporum* f. sp. niveum race 2) in watermelon: parametric and nonparametric approaches. *Theoretical and Applied Genetics*, 2025, 138:35
9. Biswas PS, Ahmed ME, Afrin W, Rahman A, Shalahuddin A, Islam R, Akter F, Syed MA, Sarker MRA, Ifterkharuddaula K. Enhancing genetic gain through the application of genomic selection in developing irrigated rice for the favorable ecosystem in Bangladesh. *Frontiers in Genetics*, 2023, 14:1083221
10. Breiman L. Bagging predictors. *Machine learning*, 1996, 24:123-140
11. Breiman L. Random Forests. *Machine Learning*, 2001, 45:5-32
12. Brown G, Wyatt J, Harris R, Yao X. Diversity creation methods: a survey and categorisation. *Information fusion*, 2005, 6:5-20
13. Browning BL, Zhou Y, Browning SR. A one-penny imputed genome from next-generation reference panels. *The American journal of human genetics*, 2018, 103:338-348
14. Burgueño J, de los Campos G, Weigel K, Crossa J. Genomic prediction of breeding values when modeling genotype× environment interaction using pedigree and dense molecular markers. *Crop Science*, 2012, 52:707-719
15. Chen PY. Effects of normalization on the entropy-based TOPSIS method. *Expert Systems with Applications*, 2019, 136:33-41
16. Chen PY. Effects of the entropy weight on TOPSIS. *Expert Systems with Applications*, 2021, 168:114186
17. Chen YR, Frei UK, Lübberstedt T. Multi-trait ridge regression BLUP with de novo GWAS improves genomic prediction for haploid induction ability of haploid inducers in maize. *Frontiers in Plant Science*, 2025, 16:1614457
18. Colantonio V, Ferrão LFV, Tieman DM, Bliznyuk N, Sims C, Klee HJ, Munoz P, Resende Jr MF. Metabolomic selection for enhanced fruit flavor. *Proceedings of the National Academy of Sciences*, 2022, 119:e2115865119
19. Cortes C, Vapnik V. Support-vector networks. *Machine learning*, 1995, 20:273-297
20. Cover T, Hart P. Nearest neighbor pattern classification. *IEEE transactions on information theory*, 1967, 13:21-27
21. Crisci C, Ghattas B, Perera G. A review of supervised machine learning algorithms and their applications to ecological data. *Ecological Modelling*, 2012, 240:113-122
22. Crossa J, Campos Gdl, Pérez P, Gianola D, Burgueno J, Araus JL, Makumbi D, Singh RP, Dreisigacker S, Yan J. Prediction of genetic values of quantitative traits in plant breeding using pedigree and molecular markers. *Genetics*, 2010, 186:713-724

23. Crossa J, Pérez-Rodríguez P, Cuevas J, Montesinos-López O, Jarquín D, De Los Campos G, Burgueño J, González-Camacho JM, Pérez-Elizalde S, Beyene Y. Genomic selection in plant breeding: methods, models, and perspectives. *Trends in plant science*, 2017, 22:961-975
24. Cuevas J, Crossa J, Montesinos-López OA, Burgueño J, Pérez-Rodríguez P, de Los Campos G. Bayesian genomic prediction with genotype× environment interaction kernel models. *G3: Genes, Genomes, Genetics*, 2017, 7:41-53
25. de Los Campos G, Vazquez AI, Fernando R, Klimentidis YC, Sorensen D. Prediction of complex human traits using the genomic best linear unbiased predictor. *PLoS genetics*, 2013, 9:e1003608
26. Deng XS, Li M, Deng SB, Wang L. Hybrid gene selection approach using XGBoost and multi-objective genetic algorithm for cancer classification. *Medical & Biological Engineering & Computing*, 2022, 60:663-681
27. Endelman JB, Carley CAS, Bethke PC, Coombs JJ, Clough ME, da Silva WL, De Jong WS, Douches DS, Frederick CM, Haynes KG. Genetic variance partitioning and genome-wide prediction with allele dosage information in autotetraploid potato. *Genetics*, 2018, 209:77-87
28. Exterkate P, Groenen PJ, Heij C, van Dijk D. Nonlinear forecasting with many predictors using kernel ridge regression. *International Journal of Forecasting*, 2016, 32:736-753
29. Farooq M, van Dijk AD, Nijveen H, Mansoor S, de Ridder D. Genomic prediction in plants: opportunities for ensemble machine learning based approaches. *F1000Research*, 2023, 11:802
30. Fernández-Delgado M, Cernadas E, Barro S, Amorim D. Do we need hundreds of classifiers to solve real world classification problems? *The journal of machine learning research*, 2014, 15:3133-3181
31. Freund Y, Schapire RE. A decision-theoretic generalization of on-line learning and an application to boosting. *Journal of computer and system sciences*, 1997, 55:119-139
32. Gan Y, Liu ZY, Zhang F, Xu Q, Wang X, Xue H, Su XN, Ma WQ, Long QM, Ma AQ. Deep learning empowers genomic selection of pest-resistant grapevine. *Horticulture Research*, 2025, 12:uhaf128
33. Gianola D, Okut H, Weigel KA, Rosa GJ. Predicting complex quantitative traits with Bayesian neural networks: a case study with Jersey cows and wheat. *BMC genetics*, 2011, 12:87
34. Gill M, Anderson R, Hu H, Bennamoun M, Petereit J, Valliyodan B, Nguyen HT, Batley J, Bayer PE, Edwards D. Machine learning models outperform deep learning models, provide interpretation and facilitate feature selection for soybean trait prediction. *BMC plant biology*, 2022, 22:180
35. Goldberger AS. Best linear unbiased prediction in the generalized linear regression model. *Journal of the American Statistical Association*, 1962, 57:369-375
36. Gómez D, Rojas A. An empirical overview of the no free lunch theorem and its effect on real-world machine learning classification. *Neural computation*, 2016, 28:216-228
37. González-Camacho JM, Ornella L, Pérez-Rodríguez P, Gianola D, Dreisigacker S, Crossa J. Applications of machine learning methods to genomic selection in breeding wheat for rust resistance. *The plant genome*, 2018, 11:170104
38. Grinberg NF, Orhobor OI, King RD. An evaluation of machine-learning for predicting phenotype: studies in yeast, rice, and wheat. *Machine Learning*, 2020, 109:251-277
39. Gu LL, Yang RQ, Wang ZY, Jiang D, Fang M. Ensemble learning for integrative prediction of genetic values with genomic variants. *BMC bioinformatics*, 2024, 25:120
40. Habier D, Fernando RL, Kizilkaya K, Garrick DJ. Extension of the Bayesian alphabet for genomic selection. *BMC bioinformatics*, 2011, 12:186
41. Hassanali M, Soltanaghaei M, Javdani Gandomani T, Zamani Boroujeni F. Exploring stacking methods for software effort estimation with hyperparameter tuning. *Cluster Computing*, 2025, 28:241
42. Hayes BJ, Pryce J, Chamberlain AJ, Bowman PJ, Goddard ME. Genetic architecture of complex traits and accuracy of genomic prediction: coat colour, milk-fat percentage, and type in Holstein cattle as contrasting model traits. *PLoS genetics*, 2010, 6:e1001139
43. Heilmann PG, Frisch M, Abbadi A, Kox T, Herzog E. Stacked ensembles on basis of parentage information can predict hybrid performance with an accuracy comparable to marker-based GBLUP. *Frontiers in Plant Science*, 2023, 14:1178902
44. Henderson CR. Best linear unbiased estimation and prediction under a selection model. *Biometrics*, 1975:423-447
45. Heslot N, Yang HP, Sorrells ME, Jannink JL. Genomic selection in plant breeding: a comparison of models. *Crop science*, 2012, 52:146-160

46. Hoerl AE, Kennard RW. Ridge regression: applications to nonorthogonal problems. *Technometrics*, 1970, 12:69-82
47. Howard R, Lipka AE. Genomic selection and reproducibility: are complex models distracting us from true scientific validity in the presence of genotype-by-environment interaction? *G3: Genes, Genomes, Genetics*, 2025, 15:jkaf244
48. Hwang CL, Yoon K. Multiple Attribute Decision Making: Methods and Applications - A State-of-the-Art Survey. Berlin: Springer, 1981. 58-191
49. Ibtisham F, Zhang L, Xiao M, An LL, Ramzan MB, Nawab A, Zhao Y, Li GH, Xu YM. Genomic selection and its application in animal breeding. *The Thai Journal of Veterinary Medicine*, 2017, 47:301-310
50. Jang YJ, Yun D, Shin W, Goo C, Song CM, Han K, Kim S, Kim DS, Lee S, Oh Y. Integrative Machine Learning Approaches for Identifying Loci Associated with Anthracnose Resistance in Strawberry. *Plants*, 2025, 14:2889
51. Jha R, Singh VP. Evaluation of riverwater quality by entropy. *KSCE Journal of Civil Engineering*, 2008, 12:61-69
52. Jordan MI, Mitchell TM. Machine learning: Trends, perspectives, and prospects. *Science*, 2015, 349:255-260
53. Kaelbling LP, Littman ML, Moore AW. Reinforcement learning: A survey. *Journal of artificial intelligence research*, 1996, 4:237-285
54. Kang HM, Sul JH, Service SK, Zaitlen NA, Kong S-y, Freimer NB, Sabatti C, Eskin E. Variance component model to account for sample structure in genome-wide association studies. *Nature genetics*, 2010, 42:348-354
55. Karacaören B. An evaluation of machine learning for genomic prediction of hairy syndrome in dairy cattle. *Animal Science Papers and Reports*, 2022, 40:45-58
56. Kearsey MJ, Farquhar A. QTL analysis in plants; where are we now? *Heredity*, 1998, 80:137-142
57. Kick DR, Washburn JD. Ensemble of best linear unbiased predictor, machine learning and deep learning models predict maize yield better than each model alone. *in silico Plants*, 2023, 5:diad015
58. Kremer A, Casasoli M, Barreneche T, Bodénès C, Sisco P, Kubisiak T, Scalfi M, Leonardi S, Bakker E, Buiteveld J. Genome mapping and molecular breeding in plants. *Forest trees*, 2007, 7:161-187
59. Kuncheva LI, Whitaker CJ. Measures of diversity in classifier ensembles and their relationship with the ensemble accuracy. *Machine learning*, 2003, 51:181-207
60. Li K, Huang HK, Ye XC, Cui LJ. A selective approach to neural network ensemble based on clustering technology. International Conference on Machine Learning and Cybernetics, 2004, Shanghai, China
61. Liang M, Chang TP, An BX, Duan XH, Du LL, Wang XQ, Miao J, Xu LY, Gao X, Zhang LP. A stacking ensemble learning framework for genomic prediction. *Frontiers in genetics*, 2021a, 12:600040
62. Liang M, Miao J, Wang XQ, Chang TP, An BX, Duan XH, Xu LY, Gao X, Zhang LP, Li JY. Application of ensemble learning to genomic selection in chinese simmental beef cattle. *Journal of Animal Breeding and Genetics*, 2021b, 138:291-299
63. Libbrecht MW, Noble WS. Machine learning applications in genetics and genomics. *Nature Reviews Genetics*, 2015, 16:321-332
64. Liu C, Liu XX, Han YK, Wang XA, Ding YY, Meng HW, Cheng ZH. Genomic prediction and the practical breeding of 12 quantitative-inherited traits in cucumber (*Cucumis sativus* L.). *Frontiers in Plant Science*, 2021, 12:729328
65. Liu JQ, Yan XC, Li WZ, Xue SH, Wang ZY, Su R. Genomic Selection for Cashmere Traits in Inner Mongolian Cashmere Goats Using Random Forest, Gradient Boosting Decision Tree, Extreme Gradient Boosting and Light Gradient Boosting Machine Methods. *Animals*, 2025, 15:2940
66. Liu TY, Li GZ. Fault diagnosis by using selective ensemble learning based on mutual information. The Second International Symposium on Optimization and Systems Biology, 2008, Lijiang, China
67. Liu XG, Wang HW, Wang H, Guo ZF, Xu XJ, Liu JC, Wang SH, Li WX, Zou C, Prasanna BM, Olsen MS, Huang CL, Xu YB. Factors affecting genomic selection revealed by empirical evidence in maize. *The Crop Journal*, 2018, 6:341-352
68. Luo Z, Tian J, Zeng J, Pilla F. Flood risk evaluation of the coastal city by the EWM-TOPSIS and machine learning hybrid method. *International Journal of Disaster Risk Reduction*, 2024, 106:104435

69. Mahesh B. Machine Learning Algorithms - A Review. *International Journal of Science and Research (IJSR)*, 2020, 9:381-386
70. Meharie MG, Mengesha WJ, Gariy ZA, Mutuku RN. Application of stacking ensemble machine learning algorithm in predicting the cost of highway construction projects. *Engineering, Construction and Architectural Management*, 2022, 29:2836-2853
71. Meuwissen TH, Hayes BJ, Goddard M. Prediction of total genetic value using genome-wide dense marker maps. *genetics*, 2001, 157:1819-1829
72. Mila A, Ngugi H. A Bayesian approach to meta-analysis of plant pathology studies. *Phytopathology*, 2011, 101:42-51
73. Mohammed MA, Abdulkareem KH, Al-Waisy AS, Mostafa SA, Al-Fahdawi S, Dinar AM, Alhakami W, Baz A, Al-Mhiqani MN, Alhakami H. Benchmarking methodology for selection of optimal COVID-19 diagnostic model based on entropy and TOPSIS methods. *Ieee Access*, 2020, 8:99115-99131
74. Momen M, Bhatta M, Hussain W, Yu H, Morota G. Modeling multiple phenotypes in wheat using data-driven genomic exploratory factor analysis and Bayesian network learning. *Plant Direct*, 2021, 5:e00304
75. Montesinos-López A, Montesinos-López OA, Ramos-Pulido S, Mosqueda-González BA, Guerrero-Arroyo EA, Crossa J, Ortiz R. Artificial intelligence meets genomic selection: comparing deep learning and GBLUP across diverse plant datasets. *Frontiers in Genetics*, 2025, 16:1568705
76. Montesinos-López OA, Montesinos-López A, Crossa J, Toledo FH, Pérez-Hernández O, Eskridge KM, Rutkoski J. A genomic Bayesian multi-trait and multi-environment model. *G3: Genes, Genomes, Genetics*, 2016, 6:2725-2744
77. Montesinos-López OA, Gonzalez HN, Montesinos-López A, Daza-Torres M, Lillemo M, Montesinos-López JC, Crossa J. Comparing gradient boosting machine and Bayesian threshold BLUP for genome-based prediction of categorical traits in wheat breeding. *The plant genome*, 2022, 15:e20214
78. Munkvold JD, Tanaka J, Benscher D, Sorrells ME. Mapping quantitative trait loci for preharvest sprouting resistance in white wheat. *Theoretical and applied genetics*, 2009, 119:1223-1235
79. Nakaya A, Isobe SN. Will genomic selection be a practical method for plant breeding? *Annals of botany*, 2012, 110:1303-1316
80. Nascimento M, Nascimento ACC, Azevedo CF, Oliveira ACBd, Caixeta ET, Jarquin D. Enhancing genomic prediction with stacking ensemble learning in Arabica coffee. *Frontiers in Plant Science*, 2024, 15:1373318
81. Neftci EO, Averbeck BB. Reinforcement learning in artificial and biological systems. *Nature Machine Intelligence*, 2019, 1:133-143
82. Nukui T, Onogi A. An R package for ensemble learning stacking. *Bioinformatics Advances*, 2023, 3:vbad139
83. Onogi A, Ideta O, Inoshita Y, Ebana K, Yoshioka T, Yamasaki M, Iwata H. Exploring the areas of applicability of whole-genome prediction methods for Asian rice (*Oryza sativa* L.). *Theoretical and applied genetics*, 2015, 128:41-53
84. Pan S, Liu Z, Han Y, Zhang D, Zhao X, Li J, Wang K. Using the Pearson's correlation coefficient as the sole metric to measure the accuracy of quantitative trait prediction: is it sufficient? *Frontiers in Plant Science*, 2024, 15:1480463
85. Pandey V, Komal, Dincer H. A review on TOPSIS method and its extensions for different applications with recent development: V. Pandey et al. *Soft Computing*, 2023, 27:18011-18039
86. Pereira FC, Borysov SS. Machine learning fundamentals. In: Antoniou C, Dimitriou L and Pereira FC eds., Mobility patterns, big data and transport analytics. Amsterdam: Elsevier, 2019. 9-29
87. Purcell S, Neale B, Todd-Brown K, Thomas L, Ferreira MA, Bender D, Maller J, Sklar P, De Bakker PI, Daly MJ. PLINK: a tool set for whole-genome association and population-based linkage analyses. *The American journal of human genetics*, 2007, 81:559-575
88. Ragot M, Biasiolli M, Delbut M, Dell'Orco A, Malgarini L, Thevenin P, Vernoy J, Vivant J, Zimmermann R, Gay G. Marker-assisted backcrossing: a practical example. *Techniques et utilizations des marqueurs moleculaires. Montpellier, France*, 1994:45-56
89. Ray S, Jarquin D, Howard R. Comparing artificial-intelligence techniques with state-of-the-art parametric prediction models for predicting soybean traits. *The Plant Genome*, 2023, 16:e20263
90. Ribaut JM, Hoisington D. Marker-assisted selection: new tools and strategies. *Trends in plant science*, 1998, 3:236-239

91. Sahoo JP, Dash D, Moharana A, Mahapatra M, Sahoo AK, Samal KC. The role of transcription factors in response to biotic stresses in Maize. In: Wani SH, Nataraj V and Singh GP eds., Transcription factors for biotic stress tolerance in plants. Cham: Springer, 2022a. 175-194
92. Sahoo JP, Mishra P, Mishra AP, Panda KK, Samal KC. Physiological, biochemical, and molecular responses of rice (*Oryza sativa* L.) towards elevated ozone tolerance. *Cereal Research Communications*, 2023, 51:315-324
93. Sahoo JP, Mohapatra U, Saha D, Mohanty IC, Samal KC. Linkage disequilibrium mapping: a journey from traditional breeding to molecular breeding in crop plants. *Indian Journal of Traditional Knowledge*, 2022b, 21:434-442
94. Samal KC, Sahoo JP, Behera L, Dash T. Understanding the BLAST (Basic Local Alignment Search Tool) program and a step-by-step guide for its use in life science research. *Bhartiya Krishi Anusandhan Patrika*, 2021, 36:55-61
95. Shannon CE, Weaver W. A mathematic theory of communication. *Bell Syst. Tech. J*, 1948, 27:379-423
96. Sharma D, Kumar N. A review on machine learning algorithms, tasks and applications. *International Journal of Advanced Research in Computer Engineering & Technology (IJARCET)*, 2017, 6:2278-1323
97. Spindel J, Begum H, Akdemir D, Virk P, Collard B, Redona E, Atlin G, Jannink J-L, McCouch SR. Genomic selection and association mapping in rice (*Oryza sativa*): effect of trait genetic architecture, training population composition, marker number and statistical model on accuracy of rice genomic selection in elite, tropical rice breeding lines. *PLoS genetics*, 2015, 11:e1004982
98. Tessema BB, Liu H, Sørensen AC, Andersen JR, Jensen J. Strategies using genomic selection to increase genetic gain in breeding programs for wheat. *Frontiers in Genetics*, 2020, 11:578123
99. Tong H, Nankar AN, Liu J, Todorova V, Ganeva D, Grozeva S, Tringovska I, Pasev G, Radeva-Ivanova V, Gechev T. Genomic prediction of morphometric and colorimetric traits in Solanaceous fruits. *Horticulture Research*, 2022, 9:uhac072
100. Torfi F, Farahani RZ, Rezapour S. Fuzzy AHP to determine the relative weights of evaluation criteria and Fuzzy TOPSIS to rank the alternatives. *Applied soft computing*, 2010, 10:520-528
101. Van de Schoot R, Depaoli S, King R, Kramer B, Märtens K, Tadesse MG, Vannucci M, Gelman A, Veen D, Willemsen J. Bayesian statistics and modelling. *Nature Reviews Methods Primers*, 2021, 1:1
102. VanRaden PM. Efficient methods to compute genomic predictions. *Journal of dairy science*, 2008, 91:4414-4423
103. Waldmann P. On the use of the Pearson correlation coefficient for model evaluation in genome-wide prediction. *Frontiers in genetics*, 2019, 10:899
104. Wang K, Abid MA, Rasheed A, Crossa J, Hearne S, Li H. DNNGP, a deep neural network-based method for genomic prediction using multi-omics data in plants. *Molecular Plant*, 2023, 16:279-293
105. Wang P, Lehti-Shiu MD, Lotreck S, Segura Abá K, Krysan PJ, Shiu S-H. Prediction of plant complex traits via integration of multi-omics data. *Nature Communications*, 2024, 15:6856
106. Wang T, Zhang KF, Thé J, Yu HS. Accurate prediction of band gap of materials using stacking machine learning model. *Computational Materials Science*, 2022, 201:110899
107. Wang X, Xu Y, Hu ZL, Xu CW. Genomic selection methods for crop improvement: Current status and prospects. *The Crop Journal*, 2018, 6:330-340
108. Wang X, Yang Z, Xu C. A comparison of genomic selection methods for breeding value prediction. *Science Bulletin*, 2015, 60:925-935
109. Wang Y, Mette MF, Miedaner T, Gottwald M, Wilde P, Reif JC, Zhao Y. The accuracy of prediction of genomic selection in elite hybrid rye populations surpasses the accuracy of marker-assisted selection and is equally augmented by multiple field evaluation locations and test years. *BMC genomics*, 2014, 15:556
110. Wolpert DH. Stacked generalization. *Neural networks*, 1992, 5:241-259
111. Wolpert DH, Macready WG. No free lunch theorems for optimization. *IEEE transactions on evolutionary computation*, 2002, 1:67-82
112. Yan J, Xu YT, Cheng Q, Jiang SQ, Wang Q, Xiao YJ, Ma C, Yan JB, Wang XF. LightGBM: accelerated genomically designed crop breeding through ensemble learning. *Genome biology*, 2021, 22:271

113. Yoon T, Kang D. Multi-modal stacking ensemble for the diagnosis of cardiovascular diseases. *Journal of Personalized Medicine*, 2023, 13:373
114. Yu TX, Zhang WP, Han JW, Li FZ, Wang ZH, Cao CQ. An ensemble learning approach for predicting phenotypes from genotypes. 20th International Conference on Ubiquitous Computing and Communications, 2021, London, UK
115. Zhang F, Kang J, Long R, Li M, Sun Y, He F, Jiang X, Yang C, Yang X, Kong J. Application of machine learning to explore the genomic prediction accuracy of fall dormancy in autotetraploid alfalfa. *Horticulture Research*, 2023, 10:uhac225
116. Zhang Y, Ma J, Liang S, Li X, Liu J. A stacking ensemble algorithm for improving the biases of forest aboveground biomass estimations from multiple remotely sensed datasets. *GIScience & Remote Sensing*, 2022, 59:234-249
117. Zhou ZH, Wu JX, Tang W. Ensembling neural networks: many could be better than all. *Artificial intelligence*, 2002, 137:239-263
118. Zou J, Huss M, Abid A, Mohammadi P, Torkamani A, Telenti A. A primer on deep learning in genomics. *Nature genetics*, 2019, 51:12-18

附录

附表 1 机器学习模型默认参数配置

Table S1 Default Parameter Configurations for Machine Learning Models

机器学习	算法实现	参数	默认值
SVR	LinearSVR	loss	epsilon_insensitive
		C	1
		tol	0.0001
KRR	KernelRidge	alpha	1
		kernel	rbf
		gamma	None
KNN	KNeighborsRegressor	n_neighbors	5
		weights	uniform
		leaf_size	30
RF	RandomForestRegressor	n_estimators	100
		max_depth	None
		min_samples_split	2
		min_samples_leaf	1
		bootstrap	TRUE
Ada	AdaBoostRegressor	n_estimators	50
		learning_rate	1
		loss	linear
GBDT	GradientBoostingRegressor	n_estimators	100
		learning_rate	0.1
		max_depth	3
		min_samples_split	2
		min_samples_leaf	1
		subsample	1
HGB	HistGradientBoostingRegressor	max_depth	None
		max_iter	100
		max_leaf_nodes	31
		min_samples_leaf	20
		learning_rate	0.1

附表 1 机器学习模型默认参数配置（续表）
Table S1 Default Parameter Configurations for Machine Learning Models

XGB	XGBRegressor	n_estimators	100
		max_depth	3
		learning_rate	0.1
		booster	gbtree
LGBM	LGBMRegressor	n_estimators	100
		num_leaves	31
		learning_rate	0.1
		min_child_samples	20
		objective	regression
CatB	CatBoostRegressor	iterations	100
		depth	6
		learning_rate	0.1
		l2_leaf_reg	3

华中农业大学研究生学位论文图表原始记录存查表

华中农业大学研究生学位论文图表原始记录存查表

（自然科学类）

序号	学位论文图表序号及对应页	科研实验记录出处（第 X 册，XX 页）	实验完成日期（年、月、日）	核查人员签名
1	图 3	第 1 册，124 页，对应电子文档名：/data/xiaoliu/gpse_6pecies_model，E:\R_new_project\gpse_6specise	实验日期：2025 年 10 月 17 日，电子文档建档日期：2026 年 2 月 4 日	张建
2	图 4A-F	第 1 册，125 页，对应电子文档名：/data/xiaoliu/gpse_6pecies_model，/data/xiaoliu/gpse_6pecies_model/extracted_pearson_results/topsis_box	实验日期：2025 年 10 月 23 日，电子文档建档日期：2026 年 3 月 17 日	张建
3	图 5	第 1 册，146 页，对应电子文档名：/home/xiaoliu/data/gpse_3species/cucumber_n/cucumber_multi_traits_results，/home/xiaoliu/data/gpse_3species/bar_chart	实验日期：2026 年 1 月 15 日，电子文档建档日期：2026 年 3 月 12 日	张建
4	图 6A-C	第 1 册，147 页，对应电子文档名：/home/xiaoliu/data/gpse_3species/cucumber_n/cucumber_multi_traits_results，/home/xiaoliu/data/gpse_3species/line_chart/scatter_plots/cucumber_n	实验日期：2026 年 1 月 15 日，电子文档建档日期：2026 年 3 月 12 日	张建
5	图 7	第 1 册，147 页，对应电子文档名：/home/xiaoliu/data/gpse_3species/melon/melon_multi_traits_results，/home/xiaoliu/data/gpse_3species/bar_chart	实验日期：2026 年 1 月 20 日，电子文档建档日期：2026 年 3 月 12 日	张建
6	图 8A-C	第 1 册，148 页，对应电子文档名：/home/xiaoliu/data/gpse_3species/melon/melon_multi_traits_results，/home/xiaoliu/data/gpse_3species/line_chart/scatter_plots/melon	实验日期：2026 年 1 月 20 日，电子文档建档日期：2026 年 3 月 12 日	张建
7	图 9	第 1 册，148 页，对应电子文档名：/home/xiaoliu/data/gpse_3species/watermelon/watermelon_multi_traits_results，/home/xiaoliu/data/gpse_3species/bar_chart	实验日期：2026 年 1 月 25 日，电子文档建档日期：2026 年 3 月 12 日	张建
8	图 10A-C	第 1 册，149 页，对应电子文档名：/home/xiaoliu/data/gpse_3species/watermelon/watermelon_multi_traits_results，/home/xiaoliu/data/gpse_3species/line_chart/scatter_plots/watermelon	实验日期：2026 年 1 月 25 日，电子文档建档日期：2026 年 3 月 12 日	张建

9	表 3	第 1 册，149 页，对应电子文档名：/home/xiaoliu/data/gpse_3species/3pecies，/home/xiaoliu/data/gpse_3species/bar_blup	实验日期：2026 年 2 月 1 日，电子文档建档日期：2026 年 3 月 12 日	张建
10	图 11A	第 1 册，86 页，对应电子文档名：/home/xiaoliu/data/gpse_26_tomato_gwas /P2. StructureLD/00. prepare，/home/xiaoliu/data/gpse_gwas_ld/tomato	实验日期：2025 年 3 月 25 日，电子文档建档日期：2026 年 3 月 10 日	张建
11	图 11B	第 1 册，89 页，对应电子文档名：/home/xiaoliu/data/gpse_26_tomato_gwas /P3. GWAS/02. emmax/final_results/03. results，/P2. StructureLD/00. prepare /home/xiaoliu/data/gpse_gwas_ld/tomato	实验日期：2025 年 3 月 29 日，电子文档建档日期：2026 年 3 月 10 日	张建
12	图 11C	第 1 册，108 页，对应电子文档名：/home/xiaoliu/data/gpse_magic_gwas /00. data/LD_1000_1_0. 02，/home/xiaoliu/data/gpse_gwas_ld /tomato/lettuce	实验日期：2025 年 7 月 2 日，电子文档建档日期：2026 年 3 月 10 日	张建
13	图 11D	第 1 册，111 页，对应电子文档名：/home/xiaoliu/data/gpse_magic_gwas/02. gwas /3d_phe. pruned. gwas. result /03. result/02. result. raw. ps，/home/xiaoliu/data/gpse_gwas_ld /tomato/lettuce	实验日期：2025 年 7 月 28 日，电子文档建档日期：2026 年 3 月 10 日	张建
14	图 12	第 1 册，103 页，对应电子文档名：/home/xiaoliu/data/gpse_tomato_15models /26finalresult/multi_traits_results，/home/xiaoliu/data/gpse_gwas_ld_compare	实验日期：2025 年 6 月 24 日，电子文档建档日期：2026 年 3 月 11 日	张建
15	图 12	第 1 册，128 页，对应电子文档名：/home/xiaoliu/data/gpse_tomato_gwas_model /multi_traits_results，/home/xiaoliu/data/gpse_gwas_ld_compare	实验日期：2025 年 7 月 6 日，电子文档建档日期：2026 年 3 月 11 日	张建
16	图 13	第 1 册，109 页，对应电子文档名：/home/xiaoliu/data/gpse_magic_15models，/home/xiaoliu/data/gpse_gwas_ld_compare	实验日期：2025 年 7 月 25 日，电子文档建档日期：2026 年 3 月 11 日	张建
17	图 13	第 1 册，112 页，对应电子文档名：/home/xiaoliu/data/gpse_magic_15models /multi_traits_result_gwas，/home/xiaoliu/data/gpse_gwas_ld_compare	实验日期：2025 年 8 月 3 日，电子文档建档日期：2026 年 3 月 11 日	张建
18	图 14	第 1 册，128 页，对应电子文档名：/home/xiaoliu/data/gpse_tomato_gwas_model /multi_traits_results，/home/xiaoliu/data/gpse_gwas_ld_compare /bar_chart	实验日期：2025 年 7 月 6 日，电子文档建档日期：2026 年 3 月 11 日	张建

19	图 15A-F	第 1 册，128 页，对应电子文档名：/home/xiaoliu/data/gpse_tomato_gwas_model/multi_traits_results，/home/xiaoliu/data/gpse_gwas_ld_compare/line_chart/scatter_plots	实验日期：2025 年 7 月 6 日，电子文档建档日期：2026 年 3 月 11 日	张建
20	图 16	第 1 册，112 页，对应电子文档名：/home/xiaoliu/data/gpse_magic_15models/multi_traits_result_gwas，/home/xiaoliu/data/gpse_gwas_ld_compare/bar_chart	实验日期：2025 年 8 月 3 日，电子文档建档日期：2026 年 3 月 11 日	张建
21	图 17A-C	第 1 册，112 页，对应电子文档名：/home/xiaoliu/data/gpse_magic_15models/multi_traits_result_gwas，/home/xiaoliu/data/gpse_gwas_ld_compare/line_chart/lettuce_scatter_plots	实验日期：2025 年 8 月 3 日，电子文档建档日期：2026 年 3 月 11 日	张建
22	表 4	第 1 册，150 页，对应电子文档名：/home/xiaoliu/data/GBLUP_RRBLUP_tomato/tomato_gwas，/home/xiaoliu/data/gpse_gwas_ld_compare/bar_chart/comparison_accuracy_table.csv	实验日期：2026 年 2 月 7 日，电子文档建档日期：2026 年 3 月 20 日	张建
23	表 4	第 1 册，150 页，对应电子文档名：/home/xiaoliu/data/GBLUP_RRBLUP_lettuce/lettuce_gwas，/home/xiaoliu/data/gpse_gwas_ld_compare/bar_chart/comparison_accuracy_table.csv	实验日期：2026 年 2 月 7 日，电子文档建档日期：2026 年 3 月 20 日	张建
24	图 18A-F	第 1 册，117 页，对应电子文档名：/home/xiaoliu/data/gpse_lettuce_class/all_results，E:\lettuce_class\gpse_lettuce_class\roc_panels_all1	实验日期：2025 年 9 月 12 日，电子文档建档日期：2026 年 3 月 14 日	张建
25	图 19A-C	第 1 册，对应电子文档名：/home/xiaoliu/data/gpse_3species/snp_influnence_p/snp_influence_results，E:\snp_3pecies\snp_influnence_p\snp_influence_results	实验日期：2026 年 2 月 13 日，电子文档建档日期：2026 年 3 月 15 日	张建

我承诺上述列表中学位论文所使用的图和表均为本人研究生在读期间独立完成，以上信息准确真实。

研究生签名：刘晓 2026年 6月 2日

经核查，上述列表清单中的图和表与原始记录相符。

导师签名：王 2026年 6月 3日

致谢

岁月不居，时节如流。三年的硕士生涯在日复一日的写代码与文献翻阅中，悄然步入了尾声。当这篇论文最终定稿，即将迎来最终的答辩时，看着屏幕上密密麻麻的文字和图表，我的内心交织着释然与不舍。这三年里，我穿梭于浩瀚的生物数据之间，试图在枯燥的数字中探寻作物育种的内在规律。那些为了跑通一段程序、优化一个模型而熬过的长夜，那些面对报错代码与预期不符的实验结果时所产生的焦虑与迷茫，如今都已化作了我青春岁月里最珍贵的注脚。

求知之路虽漫长且充满挑战，但我却从未感到孤单。回首这段从懵懂青涩走向沉稳坚定、从初窥门径到能够独立搭建预测框架的蜕变历程，我深知，这篇论文的完成绝非我一人之功。它凝聚了无数师长的悉心教诲、同门的鼎力相助以及家人的默默托举。正是这一路上遇到的点滴温暖与善意，化作了光亮，驱散了我科研道路上的迷雾，也给了我迎难而上的底气。千言万语皆化作最诚挚的感恩。

首先，我要向我的导师王昕老师致以最诚挚的谢意。初入师门时，我在时间规划与科研效率上尚有不足，对项目推进也时常伴有自我怀疑。是您在我初涉生物信息学领域时，给予了极大的耐心与包容。您毫无保留的信任与支持，引领我参与并完成各项课题，不仅锤炼了我的专业技能，更帮我重塑了科研自信。在这一过程中，您给予了我充分的时间与科研探索自由，引导我逐步培养起独立思考与自我管理的能力。正是得益于您的悉心栽培，我才得以突破自我，成为了更好的自己。此外，由衷感谢您对我毕业论文字斟句酌的修改与细致入微的指导，您在送审前对我的坚定肯定，极大地缓解了我在等待期间的焦虑。

我还要特别感谢匡汉晖老师和陈炯炯老师，感谢两位老师在论文选题、课题设计及具体实施过程中给予我的宝贵建议与悉心指导。诸位恩师的谆谆教诲如春风化雨，时刻提醒着我在未来的道路上戒骄戒躁，一步一个脚印，踏踏实实地前行。

其次，我要向罗广保、涂振、张建和胡彦龙四位师兄表达最深的谢意。在我初入师门、对研究生生活既充满好奇又略感迷茫之际，是罗广保大师兄在选课、学习与生活等方方面面给予了我细致的指导。面对我初涉生物信息学时的种种疑问，大师兄不仅孜孜不倦地为我答疑解惑，更授人以渔，教会了我如何建立科研思维与学习方法，为我后续的课题开展打下了坚实的基础。涂振师兄则在我遭遇学术瓶颈时，

总是不厌其烦地为我指点迷津，即便是再琐碎的细节，他也都耐心且细致地倾囊相授。张健师兄在我研三时加入课题组，他在生物信息学领域有着极高的专业素养。面对我提出的各类难题，他总能给出极具启发性的解答，并为我指明了进一步钻研的方向，他始终是我科研道路上的榜样。特别感谢张健师兄在我的毕业论文初稿尚显稚嫩时，主动抽出宝贵时间帮我进行深度的润色与修改。胡彦龙师兄则带我深入田间地头，悉心传授了我田间试验与作物种植的相关技术，补齐了我农业实践操作的短板。师兄们的同门情谊与无私帮助，我将铭记于心。

我也十分感谢组里的同门周许依然，以及肖莉、余媛、张雨婷、孟紫钎等师弟师妹。科研的道路时常伴随着枯燥与挑战，但正因为有你们的陪伴，实验室里总是充满着欢声笑语与温情。感谢我们在一起探讨学术、攻克繁杂数据时的思想碰撞，也感谢大家在日常生活中每一次真诚的互帮互助。你们的活力与热忱，为我的研究生岁月增添了无数鲜活的色彩。祝愿大家在未来的科研与人生道路上都能得偿所愿、前程似锦，在各自的领域里闪闪发光。

此外，我要将最深沉的谢意献给我的家人。家，永远是我心灵深处最温暖的港湾，更是我不断前行的坚实后盾。求学数载，未能时刻陪伴在你们身边，但你们从未有过半句怨言，始终以默默的付出、无限的包容与无条件的信任支持着我的每一个决定。正是这份深厚的爱与期盼，让我始终拥有迎难而上的底气与勇气。今日之学业成果，离不开你们的辛勤托举，这份荣誉不仅属于我，更属于你们。

我还要感谢那个平凡而始终未曾放弃努力的自己。回首这段求学时光，从最初的懵懂迷茫，到无数个日夜在庞杂的数据与代码中抽丝剥茧，再到一次次推翻重来的模型优化与论文打磨，这一路走来交织着汗水与挑战。感谢自己在那些焦虑与自我怀疑的时刻没有选择退缩，而是用一步一个脚印的踏实，走出了属于自己的路。凡是过往，皆为序章。愿未来的自己继续保持对未知的敬畏与对生活的热爱，怀揣这份坚韧与初心，勇敢地迈向人生的下一段征程。

最后本论文的相关研究工作是在国家重点研发计划农作物重要农艺性状基因组大数据辅助设计育种项目（项目编号：403824152）的支持下完成的。感谢该项目提供的经费保障与科研平台，为本研究各项工作的顺利开展奠定了坚实的基础，在此一并致以诚挚的感谢。

刘晓

2026 年 5 月